Машинное обучение

Книга II. Практика

Задачи, разобранные примеры,
решения и вычислительные работы

Самостоятельное учебное изложение
по материалам `spbu-math-cs/ml-course`
Раздел `2021-fall-part-1`

Учебная редакция 1.0 · 29 октября 2026

Как работать с практикумом

Практикум сопровождает книгу I и основан на лекциях, семинарах и домашних заданиях раздела `2021-fall-part-1` репозитория `spbu-math-cs/ml-course`. Он объединяет математическое решение задач и проверку алгоритмов на данных. Обозначения и нормировки согласованы с теоретической книгой: $X \in \mathbb{R}^{n \times d}$, объекты хранятся по строкам, y есть вектор ответов, log означает натуральный логарифм.

Первая часть содержит разобранные примеры и 45 самостоятельных задач. Задачи, непосредственно развивающие исходные задания H02 и H07, отмечены в тексте главы. Формулировки переработаны, неоднозначности нормировок и поведения при равных оценках устранены. Остальные задачи составлены для этой книги по темам курса. Полные решения находятся в третьей части; их рекомендуется читать после собственной попытки.

Вторая часть содержит девять вычислительных работ. Они задают данные, протокол эксперимента, проверяемые результаты и требования к отчёту. В приложении приведены небольшие эталонные реализации вычислительных ядер. Это самостоятельные блоки, а не автоматические решения всех исходных домашних заданий. Полные исследования предполагают реализацию, измерение, сравнение и интерпретацию результатов.

Уровни работы

Перед вычислением выпишите пространство параметров, точную функцию потерь и её нормировку. При выводе градиента укажите размерности; при применении теоремы проверьте предпосылки. В численном эксперименте сначала проверьте маленький пример с известным ответом, затем переходите к синтетической выборке и только после этого к реальным данным.

Отчёт должен позволять другому человеку повторить вывод: достаточно определения данных, разбиения, seed, версий библиотек, сетки гиперпараметров, критериев остановки, таблицы метрик и объяснения наблюдавшихся различий. Итоговый тест не участвует в выборе модели. График обучающей ошибки без контрольной ошибки не подтверждает обобщающую способность.

Связь с исходным курсом

Использован commit `31773dc85ce30b55b93400dc835362b2b867e296`. Исходные авторы и команда курса указаны в книге I; исходный репозиторий распространяется по MIT License, уведомление приведено в конце обеих книг. Это самостоятельная учебная переработка, не официальное издание СПбГУ. Организационные сроки и внешние соревнования 2021 года не трактуются как действующие требования.

Код проверяется в окружении Python 3.12, NumPy 2.3.5, SciPy 1.17.0, pandas 2.2.3 и scikit-learn 1.8.0. Внешние данные не требуются для аналитических задач и контрольных синтетических запусков. Если оригинальные наблюдения недоступны, это отмечено в соответствующей работе; синтетический результат не выдаётся за анализ реальных наблюдений.

Оглавление

Как работать с практикумом **i**

I Аналитический практикум **1**

1 Матрицы, данные и риск **2**

1.1 Разобранный пример: производная через дифференциал 2

1.2 Задачи 2

1.3 Проверка результата 3

2 Линейная регрессия и оптимизация **4**

2.1 Разобранный пример: ортогональная проекция 4

2.2 Задачи 4

2.3 Вычислительный ориентир 5

3 Вероятностная классификация **6**

3.1 Разобранный пример: потери по логиту 6

3.2 Задачи 6

3.3 Проверка результата 6

4 Решающие деревья **7**

4.1 Разобранный пример: взвешенный выигрыш 7

4.2 Задачи 7

4.3 Проверка реализации 8

5 Ближайшие соседи и локальная регрессия **9**

5.1 Разобранный пример: окно как взвешенный МНК 9

5.2 Задачи 9

5.3 Вычислительный ориентир 10

6 Метрики, пороги и валидация **11**

6.1 Разобранный пример: дисбаланс 11

6.2 Задачи 11
6.3 Графическая проверка 12

7 Взвешенный и нелинейный МНК 13
7.1 Разобранный пример: две точности 13
7.2 Задачи 13
7.3 Вычислительный ориентир 14

8 Зазор, двойственность и ядра 15
8.1 Разобранный пример: полиномиальный признак 15
8.2 Задачи 15
8.3 Проверка результата 16

9 Бэггинг и бустинг 17
9.1 Разобранный пример: корреляция ограничивает выигрыш 17
9.2 Задачи 17
9.3 Вычислительный ориентир 18

10 Нейронные сети 19
10.1 Разобранный пример: формы матриц 19
10.2 Задачи 19
10.3 Проверка результата 20

11 Кластеризация и графовые метки 21
11.1 Разобранный пример: почему нужен критерий 21
11.2 Задачи 21
11.3 Вычислительный ориентир 21

12 Байесовские оценки и моделирование 23
12.1 Разобранный пример: сопряжённость 23
12.2 Задачи 23
12.3 Проверка результата 24

13 KL-дивергенция и смеси 25
13.1 Разобранный пример: скрытая метка 25
13.2 Задачи 25

13.3 Вычислительный ориентир 25

14 Главные компоненты и PPCA **27**

14.1 Разобранный пример: большая дисперсия не равна полезности . 27

14.2 Задачи 27

14.3 Проверка результата 28

II Вычислительные работы **29**

15 Девять вычислительных работ **30**

15.1 Работа 1. NumPy, pandas и подготовка данных 30

15.2 Работа 2. Собственное дерево 31

15.3 Работа 3. Оптимизаторы линейной регрессии 31

15.4 Работа 4. Протокол классификационного исследования 32

15.5 Работа 5. Взвешивание, нелинейность и астрономия 32

15.6 Работа 6. Нейросеть на NumPy 33

15.7 Работа 7. SVM и ансамбли 34

15.8 Работа 8. K-means, EM и PCA 34

15.9 Работа 9. Байесовское обновление и Gibbs 35

15.10 Шаблон отчёта и итоговая проверка 35

III Решения и проверка **36**

16 Решения аналитических задач **37**

16.1 Матрицы, данные и риск 37

16.2 Линейная регрессия 37

16.3 Логистическая регрессия 38

16.4 Деревья 39

16.5 Метрические методы 39

16.6 Метрики 40

16.7 Взвешенный и нелинейный МНК 41

16.8 SVM 41

16.9 Ансамбли 42

16.10 Нейронные сети 42

16.11 Кластеризация 43
16.12 Байесовские методы 44
16.13 EM и KL 44
16.14 PCA и PPCA 45

A Вычислительные ядра **47**
A.1 Результаты контрольного выполнения 49

B Маршрут по исходным заданиям **50**

Источники и лицензия **51**
Лицензия исходного репозитория 53

Часть I

Аналитический практикум

ГЛАВА 1

Матрицы, данные и риск

Материалы курса: семинары 1--2, лекции 1 и 5 [S01, S02, L01, L05]. Теория: главы 1--2 книги I..

1.1 Разобранный пример: производная через дифференциал

Пусть $X \in \mathbb{R}^{n \times d}$, $w \in \mathbb{R}^d$, $y \in \mathbb{R}^n$ и $F(w) = \|Xw - y\|^2 / (2n)$. Положим $r = Xw - y$. Тогда

$$dF = \frac{1}{n} r^{\mathsf{T}} dr = \frac{1}{n} r^{\mathsf{T}} X \, dw, \qquad \nabla F = \frac{1}{n} X^{\mathsf{T}} r \in \mathbb{R}^d.$$

При $X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$, $y = (1, 2, 2)^{\mathsf{T}}$ и $w = 0$ градиент равен $(-5/3, -2)^{\mathsf{T}}$. Шаг длины 0.1 приводит к $(1/6, 1/5)^{\mathsf{T}}$. Это пример проверки сразу трёх деталей: транспонирования, знака и деления на n.

1.2 Задачи

Задача 1.1 (Матричный градиент)**.** Пусть $X \in \mathbb{R}^{n \times d}$, $W \in \mathbb{R}^{d \times m}$, $Y \in \mathbb{R}^{n \times m}$ и $\lambda > 0$. Для $F(W) = \|XW - Y\|_F^2 / (2n) + \lambda \|W\|_F^2 / 2$ найдите градиент и вторую вариацию в направлении H. Докажите единственность минимума независимо от ранга X.

Задача 1.2 (Утечка через предобработку)**.** Обучающие значения единственного признака равны $0, 2$, тестовое значение равно 100. Вычислите обучающее среднее и среднее объединённого набора. Объясните, почему заполнение пропусков и стандартизация по объединённому набору меняют алгоритм оценки. Предложите корректный протокол для K-блочной CV с заполнением пропусков, стандартизацией и отбором признаков по меткам. Нужно ли заново учить преобразования в каждом блоке?

Задача 1.3 (Цена выбора среди моделей)**.** Имеется фиксированный класс из $M = 100$ моделей, потери лежат в $[0, 1]$, наблюдения независимы. Найдите достаточ-

ное n, чтобы одновременно для всех моделей выполнялось $|R - \widehat{R}| \leq 0.05$ с вероятностью не менее 0.95. Какую оценку избыточного риска это даёт точному эмпирическому минимизатору? Можно ли заменить M на число гиперпараметров?

1.3 Проверка результата

В задаче о градиенте итоговая матрица имеет размер $d \times m$. В задаче о риске оценка должна зависеть от $\log M$, а не от M линейно. В протоколе CV каждое действие, использующее статистику данных или метки, должно иметь явно указанную обучающую часть.

ГЛАВА 2

Линейная регрессия и оптимизация

Материалы курса: лекции 2 и 14; семинар 3; задание 4 [L02, L14, S03, H04]. Теория: главы 3--4..

2.1 Разобранный пример: ортогональная проекция

Пусть $X = (1, 1, 1)^\mathsf{T}$ и $y = (1, 2, 6)^\mathsf{T}$. Модель предсказывает одну константу. Нормальное уравнение $3w = 9$ даёт $w = 3$, остаток $r = (-2, -1, 3)^\mathsf{T}$. Проверка $X^\mathsf{T} r = 0$ подтверждает оптимальность. Сумма квадратов равна 14. При произвольном h новая ошибка равна $14 + 3h^2$, что доказывает минимум без второго дифференцирования.

2.2 Задачи

Задача 2.1 (Прямая и остаток)**.** Для $x = (-1, 0, 1)$ и $y = (0, 1, 3)$ найдите МНК-прямую $a + bx$. Вычислите остатки, SSE, MSE и несмещённую оценку дисперсии шума при линейной модели с одинаковыми дисперсиями. Какие предположения нужны для слова «несмещённая»?

Задача 2.2 (Неединственность весов)**.** Пусть $X = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}$, $y = (1, 2)^\mathsf{T}$. Найдите все МНК-решения, решение минимальной нормы и ridge-решение для цели $\|Xw - y\|^2 / 2 + \lambda \|w\|^2 / 2$. Найдите предел ridge при $\lambda \downarrow 0$.

Задача 2.3 (Мягкое и плавное сокращение)**.** Пусть $X^\mathsf{T} X / n = I_3$, $z = X^\mathsf{T} y / n = (3, -1, 0.2)^\mathsf{T}$. Найдите ridge- и LASSO-решения при $\lambda = 0.5$ для нормировок из книги I. Объясните, почему LASSO обнуляет третью координату, а ridge нет.

Задача 2.4 (Полный и стохастический шаг)**.** Для $F(w) = \frac{1}{2}[(w - 1)^2 + (2w - 2)^2]/2$ вычислите полный градиент и два возможных стохастических градиента. Из $w_0 = 0$ сделайте шаг $\eta = 0.1$ каждым способом. Проверьте несмещённость случайного шага при равномерном выборе объекта. Найдите интервал постоянных шагов, при которых полный градиентный спуск сходится.

2.3 Вычислительный ориентир

Сравнивая МНК, QR, SVD и градиентный метод, сравнивайте одну и ту же функцию. Значение $\|Xw - y\|^2 / n$ отличается от $\|Xw - y\|^2 / (2n)$ вдвое; минимум тот же, а градиент и допустимый шаг различаются. При вырожденности сравнивайте прогнозы и норму решения, а не требуйте совпадения любого набора коэффициентов.

ГЛАВА 3

Вероятностная классификация

Материалы курса: лекции 2--3, задачи 2--4 задания H02 [L02, L03, H02]. Теория: глава 7..

3.1 Разобранный пример: потери по логиту

Для метки $y = 1$ и логита $s = \log 3$ вероятность равна $p = 3/4$, потеря $-\log(3/4) = \log(4/3)$, производная по s равна $p - y = -1/4$. Если $s = w^{\mathsf{T}}x$, градиент по w равен $-x/4$. Для той же вероятности и метки $y = 0$ производная равна $3/4$. Ошибка уверенного прогноза даёт больший по модулю градиент, чем правильный прогноз.

3.2 Задачи

Задача 3.1 (Инфимум без минимума)**.** Дана выборка $(x, y) = (-1, 0), (1, 1)$ и модель $p_w(x) = \sigma(wx)$ без свободного члена. Выпишите средний log-loss и докажите, что минимум не достигается при конечном w. После добавления $\lambda w^2/2$, $\lambda > 0$, докажите существование единственного минимума и запишите уравнение для него. Объясните, почему оптимальный вес положителен.

Задача 3.2 (Два класса softmax)**.** Покажите, что $p_1(x) = e^{w_1^{\mathsf{T}}x}/(e^{w_1^{\mathsf{T}}x} + e^{w_2^{\mathsf{T}}x})$ зависит только от $v = w_1 - w_2$. Для заданного v найдите пару (w_1, w_2) минимальной суммы квадратов норм. Какой штраф по v получается из $\lambda(\|w_1\|^2 + \|w_2\|^2)/2$?

Задача 3.3 (Две разные функции потерь)**.** Для $p = \sigma(w^{\mathsf{T}}x)$ сравните градиенты $\ell_1 = -y \log p - (1 - y) \log(1 - p)$ и $\ell_2 = (p - y)^2/2$. Вычислите их при $x = (1, 2)^{\mathsf{T}}$, $w = 0$, $y = 1$. Почему насыщенная сигмоида при неправильной метке может замедлить обучение по ℓ_2 сильнее, чем по ℓ_1?

3.3 Проверка результата

В первом упражнении следует различать предел функции и точку минимума. Во втором избыточность параметризации не исчезает просто потому, что выборка неразделима. В третьем нельзя подменять потерю по логиту потерей по вероятности: цепное правило определяет разницу.

ГЛАВА 4

Решающие деревья

Материалы курса: лекции 3--4, задания H02 и H03 [L03, L04, H02, H03]. Теория: глава 8..

4.1 Разобранный пример: взвешенный выигрыш

В узле лежат четыре метки $(0, 0, 1, 1)$, поэтому $G = 1 - 2(1/2)^2 = 1/2$. Разбиение на $(0, 0)$ и $(1, 1)$ даёт нулевую нечистоту обоих потомков и выигрыш $1/2$. Разбиение на (0) и $(0, 1, 1)$ даёт

$$\Delta G = \frac{1}{2} - \frac{1}{4} \cdot 0 - \frac{3}{4} \cdot \frac{4}{9} = \frac{1}{6}.$$

Разбиение на два одинаковых по составу узла $(0, 1)$ имеет нулевой выигрыш. Эти числа удобно использовать в тесте функции поиска порога.

4.2 Задачи

Задача 4.1 (Оптимальный лист)**.** Для ответов $y = (0, 0, 0, 1, 10)$ найдите минимизирующие константы и значения среднего квадрата и среднего модуля ошибки. Для бинарных меток $(0, 0, 0, 1, 1)$ найдите оптимальную вероятность по log-loss, энтропию и индекс Джини. Объясните, почему предсказание класса и вероятности в листе различается.

Задача 4.2 (Лучший порог и сложность)**.** Даны значения признака $x = (1, 2, 2, 4, 5)$ и ответы $y = (0, 0, 2, 4, 4)$. Найдите все допустимые разные пороги, SSE двух потомков и лучший порог для регрессии. Затем опишите алгоритм для одного признака через префиксные суммы и докажите его сложность после сортировки. Можно ли делить между двумя равными значениями $x = 2$?

Задача 4.3 (Локальный критерий и XOR)**.** На вершинах $\{0, 1\}^2$ задана разметка XOR. Вычислите энтропийный и Gini-выигрыш любого разбиения корня по одному признаку. Постройте дерево глубины два с нулевой ошибкой. Как поведёт себя правило «остановиться, если лучший выигрыш не положителен»? Почему это не противоречит оптимальности порога в каждом узле?

4.3 Проверка реализации

Проверьте константный признак, одинаковые метки, равные значения признака с разными метками, ограничения минимального размера листа и воспроизводимость ничьих. Ни один допустимый порог не должен создавать пустого потомка.

ГЛАВА 5

Ближайшие соседи и локальная регрессия

Материалы курса: лекция 4, задачи 1--3 задания H07 [L04, H07]. Теория: глава 9..

5.1 Разобранный пример: окно как взвешенный МНК

Для трёх ответов $y = (1, 3, 8)$ и весов в точке запроса $w = (1, 2, 0)$ оценка Надарая--Ватсона равна $7/3$. Вариация константы на h увеличивает взвешенную сумму квадратов на $(1 + 2)h^2$. Третий объект не влияет на ответ: его вес нулевой. При всех нулевых весах такой вывод неприменим, и алгоритм должен явно изменить окно или сообщить об отсутствии соседей.

5.2 Задачи

Задача 5.1 (Шумовой признак)**.** Имеются объекты $(0.1, U)$ первого класса и $(0.5, V)$ второго класса, где U, V независимы и равномерны на $[0, 1]$. Новый объект равен $(0, 0)$. Найдите точную вероятность того, что после добавления шумового признака второй объект окажется ближе в евклидовой метрике. Выведите одномерный интеграл и вычислите его. Что получится без шумового признака?

Задача 5.2 (Медиана ближайшего расстояния)**.** В единичном d-мерном шаре независимо равномерно расположены n точек. Выведите медиану расстояния от центра до ближайшей точки. Найдите её при $n = 500$, $d = 10$ и достаточное n для медианы не выше $1/2$. Исследуйте зависимость требуемого числа точек от d.

Задача 5.3 (Константное и линейное сглаживание)**.** Наблюдаются точки $(0, 1), (1, 3), (2, 5)$ без шума. В точке запроса $x = 0$ всем наблюдениям приписан вес 1. Найдите прогноз локальной константы и локальной прямой $a + b(t - x)$. Докажите, что локальная прямая точно воспроизводит любую аффинную зависимость при полном ранге взвешенной матрицы плана. Может ли её прогноз выйти за диапазон наблюдённых ответов?

5.3 Вычислительный ориентир

Масштабирование признаков должно предшествовать сравнению расстояний и обучаться только на train. Для совпадающих точек и переменного окна нужен отдельный случай. В задачах о размерности полезно вычислять $1 - 2^{-1/n}$ через устойчивое выражение $-\operatorname{expm1}(-\log 2/n)$.

ГЛАВА 6

Метрики, пороги и валидация

Материалы курса: лекция 5 и задачи 4--7 задания H07 [L05, H07]. Теория: главы 2 и 10..

6.1 Разобранный пример: дисбаланс

В тесте 1000 объектов, из них 10 положительных. Классификатор, предсказывающий всем 0, имеет accuracy 0.99 и recall 0. Его precision не определена, потому что положительных прогнозов нет. Замена неопределённости на нуль в программе является соглашением, которое нужно сообщить. Высокая accuracy здесь не подтверждает полезность для поиска положительного класса.

6.2 Задачи

Задача 6.1 (Равные оценки)**.** Пусть $s = (0.9, 0.8, 0.8, 0.4, 0.1)$, $y = (1, 0, 1, 0, 1)$. Постройте таблицу порогов с TP, FP, precision, recall и FPR, группируя равные оценки. Найдите ROC AUC, ступенчатую AP и трапецеидальную площадь под PR-ломаной с начальной точкой $(0, 1)$. Проверьте AUC парной формулой.

Задача 6.2 (Дефектные пары)**.** Пусть оценки различны и объекты отсортированы по возрастанию s. Определим

$$DP = \frac{2}{n(n-1)} \sum_{i<j} \mathbf{1}\{y_{(i)} > y_{(j)}\}.$$

Выразите DP через AUC, n_+ и n_-. Почему формула меняется, если равные оценки произвольно упорядочены? Предложите определение с половинным штрафом за межклассовую ничью.

Задача 6.3 (Разные метрики дают разные выводы)**.** Для каждой пары метрик постройте два прогноза на пяти объектах так, чтобы первый был лучше по первой метрике, а второй по второй: (а) AUC и log-loss; (б) precision при пороге 0.5 и AUC; (в) precision и recall при 0.5; (г) максимальный по порогу F_1 и AUC. Метки могут различаться между подпунктами, но должны совпадать для двух сравниваемых алгоритмов внутри каждого подпункта. Все неравенства проверьте численно или точно.

Задача 6.4 (MAE для вероятности)**.** Пусть $Y \sim \mathrm{Bernoulli}(\eta)$, а прогноз $p \in [0,1]$. Найдите минимум $\mathbb{E}|Y-p|$. Когда округление p по порогу $1/2$ уменьшает ожидаемую MAE, а когда увеличивает её? Приведите контрпример без предположения, что p находится по правильную сторону от $1/2$. Сравните с log-loss.

6.3 Графическая проверка

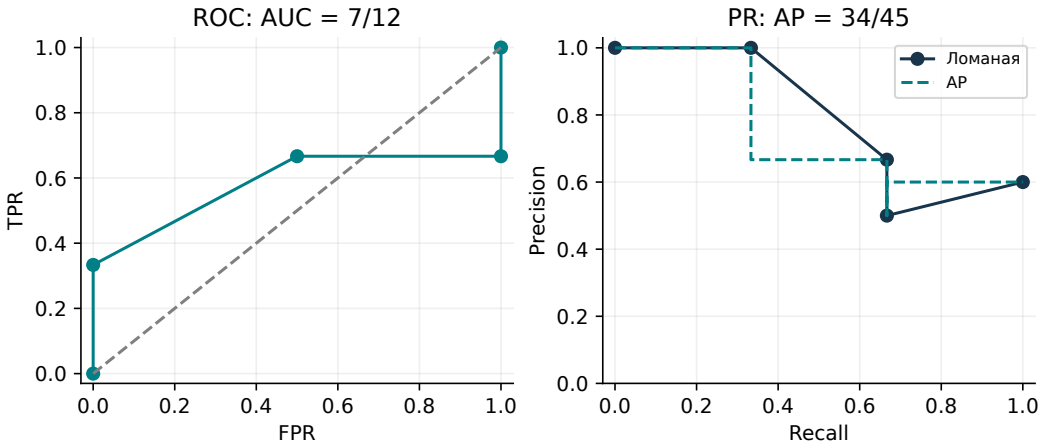


Рис. 6.1: Кривые для задачи 6.1. Равные оценки 0.8 обработаны совместно. На PR-графике показаны и ломаная, и ступенчатая интерпретация площади.

ГЛАВА 7

Взвешенный и нелинейный МНК

Материалы курса: лекции 6--7, астрономическое задание [L06, L07, H06a, H06b]. Теория: главы 5--6..

7.1 Разобранный пример: две точности

Одна величина измерена как $y_1 = 1$, $y_2 = 3$ с независимыми ошибками стандартных отклонений $\sigma_1 = 1$, $\sigma_2 = 2$. Взвешенное среднее равно

$$\hat{\beta} = \frac{1 + 3/4}{1 + 1/4} = 1.4, \qquad \operatorname{Var}\hat{\beta} = \frac{1}{1 + 1/4} = 0.8.$$

Обычное среднее равно 2, его дисперсия $(1 + 4)/4 = 1.25$. Обе оценки несмещённы при корректной модели одной константы, но их точность различается.

7.2 Задачи

Задача 7.1 (Веса и приведённый хи-квадрат)**.** Три измерения одной константы равны $(1, 2, 5)$, их известные стандартные отклонения $(1, 1, 2)$. Найдите WLS-оценку, её дисперсию, взвешенную сумму квадратов остатков и приведённый хи-квадрат с $n - d$ степенями свободы. Какие выводы нельзя делать только по одному такому числу?

Задача 7.2 (Холецкий без обратной матрицы)**.** Для $A = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$ и $b = (6, 5)^{\mathsf{T}}$ найдите L в $A = LL^{\mathsf{T}}$ и решите $A\beta = b$ двумя треугольными подстановками. Докажите, что A положительно определена через найденное разложение. Что изменится, если второй диагональный элемент A заменить на 1?

Задача 7.3 (Один шаг Гаусса--Ньютона)**.** Для модели $f(t; a, b) = ae^{bt}$ и двух наблюдений $(0, 1)$, $(\log 2, 4)$ начните с $(a, b) = (1, 1)$. Используйте $r = f - y$ и единичные веса. Найдите J, шаг Δ, предсказанную линейной моделью и фактическую новую невязку. Дополнительно выведите чувствительности решения $\dot{s} = ps$, $s(0) = s_0$ по s_0 и p и проверьте вариационное уравнение.

7.3 Вычислительный ориентир

Нельзя считать ковариацию как $(J^{\mathsf{T}}J)^{-1}$ без проверки масштаба и ранга. Для разностного якобиана нужны разумные относительные шаги по разным параметрам. Перед интерпретацией результатов полезно сравнить аналитический и численный якобианы на малой задаче.

ГЛАВА 8

Зазор, двойственность и ядра

Материалы курса: лекция 8 и задача 8 задания H07 [L08, H07]. Теория: глава 11..

8.1 Разобранный пример: полиномиальный признак

Для $x, z \in \mathbb{R}^2$ ядро $K(x,z) = (x^\mathsf{T} z)^2$ представимо как скалярное произведение

$$\phi(x) = (x_1^2, \sqrt{2}x_1x_2, x_2^2)^\mathsf{T}.$$

Средний коэффициент обязан быть $\sqrt{2}$, иначе перекрёстный член будет иметь неправильный множитель. Линейная гиперплоскость в этих трёх признаках задаёт квадратичную границу в исходном пространстве.

8.2 Задачи

Задача 8.1 (SVM на прямой)**.** Имеются точки $x = (-2, -1, 1, 2)$ с метками $(-1, -1, +1, +1)$. Найдите hard-margin SVM, ширину полосы и опорные точки. Найдите допустимые двойственные множители, удовлетворяющие KKT. Для каких C это же решение остаётся решением soft-margin SVM с целью $\|w\|^2/2 + C\sum_i \xi_i$?

Задача 8.2 (Квадрат hinge loss)**.** Рассмотрите

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_i \xi_i^2, \quad y_i(w^\mathsf{T}x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Исключите ξ из прямой задачи, выведите двойственную задачу и объясните, почему исчезает ограничение $\alpha_i \leq C$. Проследите коэффициент диагональной добавки в двойственной квадратичной форме.

Задача 8.3 (Проверка ядра)**.** На двух объектах задана симметричная функция с матрицей $G = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$. Может ли она быть матрицей Грама вещественных признаков? Докажите ответ квадратичной формой. Докажите допустимость $K_1 + 2K_2$ и $K_1 K_2$ для допустимых ядер и объясните, почему произвольная неотрицательная функция расстояния не обязана быть ядром SVM.

8.3 Проверка результата

В двойственной задаче свободный член создаёт одно линейное равенство. При изменении коэффициента перед $\sum \xi_i^2$ диагональная добавка меняется. Прямая и двойственная цели в найденном оптимуме должны совпадать в пределах численной погрешности.

ГЛАВА 9

Бэггинг и бустинг

Материалы курса: лекция и семинар 9 [L09, S09]. Теория: глава 12..

9.1 Разобранный пример: корреляция ограничивает выигрыш

Если дисперсия каждой модели равна 1, корреляция любых двух 0.2, а моделей $B = 20$, дисперсия среднего равна $0.2 + 0.8/20 = 0.24$. Увеличение B до 200 уменьшит её лишь до 0.204. Снижение корреляции до 0.05 при $B = 20$ даёт 0.0975, то есть может быть полезнее простого увеличения ансамбля.

9.2 Задачи

Задача 9.1 (Bootstrap и предел усреднения)**.** Выведите вероятность того, что фиксированный объект не попадёт в bootstrap-выборку размера n, и ожидаемое число различных объектов в ней. Найдите их пределы после деления на n. Для дисперсии базовой модели 4, корреляции 0.1 и $B = 10$ найдите дисперсию среднего. Может ли она стремиться к нулю при $B \to \infty$?

Задача 9.2 (Один шаг AdaBoost)**.** Четыре объекта имеют равные начальные веса. Базовый классификатор правильно классифицирует первые три и ошибается на четвёртом. Найдите ε, α, нормировочный множитель Z и новые веса. Докажите, что для этого выбора α суммарные новые веса верных и ошибочных объектов совпадают.

Задача 9.3 (Градиентный бустинг по листьям)**.** Для квадратной потери текущие прогнозы равны $(1, 1, 1, 1)$, ответы $(0, 2, 3, 5)$. Следующее дерево имеет листья $\{1, 2\}$ и $\{3, 4\}$. Найдите оптимальные значения поправки в листьях, новый прогноз при $\nu = 1$ и при $\nu = 0.1$, соответствующие SSE. Как изменится формула поправки для бинарной логистической потери при одном шаге Ньютона в листе с L_2-штрафом?

9.3 Вычислительный ориентир

Сравнивайте ансамбли на одинаковых внешних разбиениях. У AdaBoost контролируйте случаи нулевой ошибки и ошибки не меньше $1/2$. Для бустинга отличайте число деревьев от глубины базового дерева; изменение этих параметров воздействует на класс функций разными способами.

ГЛАВА 10

Нейронные сети

Материалы курса: лекция 10, задание H08 [L10, H08]. Теория: глава 13..

10.1 Разобранный пример: формы матриц

Пусть X имеет форму $b \times 2$, скрытый слой содержит четыре нейрона, выход один. Тогда W_1 имеет форму 2×4, b_1 длину 4, W_2 форму 4×1, а b_2 длину 1. При $\Delta_2 = (P - Y)/b$ матрица $H_1^\intercal \Delta_2$ имеет форму 4×1, а $X^\intercal[(\Delta_2 W_2^\intercal) \odot \phi'(Z_1)]$ форму 2×4. Проверка форм не доказывает правильность чисел, но исключает значительную часть ошибок обратного прохода.

10.2 Задачи

Задача 10.1 (Минимальная линейно неразделимая выборка)**.** Предполагаются различные объекты и требование строгого разделения двух непустых классов аффинной гиперплоскостью. Докажите, что любые два объекта разделимы. Приведите неразделимую выборку из трёх точек на прямой. Объясните, почему часто приводимый XOR из четырёх вершин квадрата не является минимальным примером без дополнительных требований общего положения.

Задача 10.2 (Ручной обратный проход)**.** Рассмотрим $h = \sigma(wx + b)$, $z = vh + c$, $p = \sigma(z)$ и бинарную log-loss. Для единственного наблюдения $x = 2$, $y = 1$ и начальных $w = b = v = c = 0$ найдите h, p, потерю и все четыре производные. Выполните один одновременный шаг длины η. Почему нельзя сначала обновить v, а затем использовать уже новое v для градиента по w?

Задача 10.3 (Симметрия и проверка градиента)**.** Два скрытых нейрона имеют одинаковые входные веса и смещения, а их выходные веса также одинаковы. Докажите, что при одинаковой активации и детерминированном градиентном обучении они остаются одинаковыми. Предложите проверку всего градиента сети по случайному направлению и объясните выбор h и роль негладких точек ReLU.

10.3 Проверка результата

Для нескольких объектов ошибка усреднения обычно обнаруживается при изменении размера батча: градиент повторённого дважды батча должен остаться тем же, если цель усредняется. Для проверки производной следует отключить dropout и зафиксировать все случайные состояния.

ГЛАВА 11

Кластеризация и графовые метки

Материалы курса: лекция и семинар 11 [L11, S11]. Теория: глава 14..

11.1 Разобранный пример: почему нужен критерий

Точки $(-3,0),(-2,0),(2,0),(3,0)$ естественно разбиваются на две пары по первой координате. Но без фиксированного числа кластеров минимум суммы квадратов равен нулю и достигается при четырёх одноэлементных кластерах. Аналогично минимум суммы весов разрезанных рёбер без ограничений равен нулю на одном общем кластере. Обе «идеальные ошибки» являются следствием незаданной задачи.

11.2 Задачи

Задача 11.1 (Две итерации Ллойда)**.** Для точек $0,1,4,5$ начните k-means с центров 0 и 1. Выполните две полные итерации присваивания и обновления. Вычислите начальную сумму квадратов и значение после каждой итерации. Докажите в общем случае, что обновление центра на среднее не увеличивает функционал.

Задача 11.2 (Пограничная точка DBSCAN)**.** На прямой даны точки

$$-0.9,-0.8,-0.7,0,0.7,0.8,0.9.$$

Пусть $\varepsilon = 0.75$, $\text{minPts} = 4$, сама точка входит в окрестность. Определите основные, граничные и шумовые точки. Какие компоненты основных точек получатся? Может ли кластер точки 0 зависеть от порядка обхода?

Задача 11.3 (Гармоническое продолжение)**.** В цепочке из четырёх вершин все соседние рёбра имеют вес 1. На концах заданы значения $f_1=0$, $f_4=1$. Найдите значения f_2, f_3, минимизирующие $\sum_{i=1}^{3}(f_{i+1}-f_i)^2$. Докажите единственность и объясните, что произойдёт, если убрать обе известные метки.

11.3 Вычислительный ориентир

Оценка кластеризации по известным меткам допустима для диагностики, если эти метки не использовались при настройке алгоритма под видом «неразмечен-

ного» обучения. Номера кластеров произвольны: accuracy по сырым номерам кластеров не является корректным инвариантным сравнением.

ГЛАВА 12

Байесовские оценки и моделирование

Материалы курса: лекция и семинар 12 [L12, S12]. Теория: глава 15..

12.1 Разобранный пример: сопряжённость

Пусть prior имеет плотность $\pi(\theta) = 1$ на $[0, 1]$, а в трёх испытаниях Бернулли наблюдались две единицы. Posterior пропорционален $\theta^2(1-\theta)$. Интеграл равен $1/12$, поэтому плотность $12\theta^2(1-\theta)$ нормирована. Её среднее равно $3/5$, мода $2/3$. Прогноз следующего исхода использует среднее $3/5$, а не моду.

12.2 Задачи

Задача 12.1 (Бета-бернуллиевское обновление)**.** При prior $\mathrm{Beta}(2, 2)$ наблюдаются семь единиц в десяти испытаниях. Найдите posterior, среднее, моду и предсказательную вероятность следующей единицы. Проверьте, что последовательное обновление после трёх единиц из первых четырёх и четырёх из следующих шести совпадает с однократным обновлением.

Задача 12.2 (Неопределённость среднего и наблюдения)**.** Пусть $Y_i \mid \mu \sim \mathcal{N}(\mu, 4)$, prior $\mu \sim \mathcal{N}(0, 1)$, данные $(1, 2, 3)$. Найдите среднее и дисперсию posterior, а также распределение нового наблюдения. Почему две дисперсии различаются? Сравните posterior mean с обычным средним.

Задача 12.3 (Условная независимость)**.** Априорные вероятности двух классов равны. Для двух бинарных признаков наивная модель задаёт вероятности единицы $(0.8, 0.7)$ в классе 1 и $(0.2, 0.3)$ в классе 0. Найдите $\mathbb{P}(Y = 1 \mid x = (1, 0))$. Затем рассмотрите другой случай: признаки являются точными копиями одного признака, вероятность единицы которого 0.8 в классе 1 и 0.2 в классе 0. Сравните правильный posterior при $(1, 1)$ с ошибочным наивным произведением двух факторов.

Задача 12.4 (Gibbs и зависимые отсчёты)**.** Пусть целевое распределение пары (U, V) нормально с нулевым средним, единичными дисперсиями и корреляцией ρ, $|\rho| < 1$. Выпишите условные распределения для Gibbs. Для порядка «сна-

чала U, затем V» покажите, что в стационарном режиме последовательность V_t имеет лаговую корреляцию ρ^2. Чему равен множитель асимптотической дисперсии среднего V_t?

12.3 Проверка результата

Сопряжённый вывод проверяется нормировкой плотности и крайними случаями. В МСМС нужно оценивать не только гистограмму, но и зависимость последовательных отсчётов. Совпадение среднего в одном коротком запуске не подтверждает хорошее перемешивание.

ГЛАВА 13

KL-дивергенция и смеси

Материалы курса: лекция и семинар 13 [L13, S13]. Теория: глава 16..

13.1 Разобранный пример: скрытая метка

Для смеси $\frac{1}{2}\mathcal{N}(-1,1)+\frac{1}{2}\mathcal{N}(1,1)$ отношение вероятностей двух компонент в точке x равно $\exp(-(x+1)^2/2+(x-1)^2/2)=e^{-2x}$. Поэтому ответственность первой компоненты есть $1/(1+e^{2x})$. При $x=0$ она равна $1/2$, а при $x=-1$ равна $\sigma(2)$. Скрытая метка не восстанавливается как достоверно известная: E-шаг использует распределение по возможным меткам.

13.2 Задачи

Задача 13.1 (Две ориентации KL)**.** Для $p=(1/2,1/2)$ и $q=(3/4,1/4)$ вычислите $\mathrm{KL}(p\|q)$ и $\mathrm{KL}(q\|p)$. Приведите пример, где одна ориентация конечна, а другая бесконечна. Объясните, почему слово «расстояние» может вводить в заблуждение.

Задача 13.2 (Одна итерация EM)**.** Для данных $x=(-1,1)$ возьмите смесь двух одномерных нормальных распределений с начальными весами $1/2$, средними $-1,1$ и дисперсиями $1,1$. Выполните точные E- и M-шаги, обновляя также дисперсии. Выразите новые средние и дисперсии через $a=\sigma(2)$. Проверьте нормировку ответственностей и весов.

Задача 13.3 (Что гарантирует EM)**.** Докажите монотонность наблюдаемого log-likelihood через вариационную нижнюю границу. Затем постройте путь параметров гауссовской смеси, вдоль которого likelihood конечной выборки становится неограниченным. Почему монотонность не исключает этот путь? Как меняется утверждение, если после M-шага произвольно добавить к ковариациям εI?

13.3 Вычислительный ориентир

Для проверки реализации сохраняйте значение наблюдаемого log-likelihood после каждого полного шага. При фиксированных дисперсиях точный EM должен его не уменьшать с учётом округления. Если ковариации ограничены, нужно

проверять, что М-шаг действительно максимизирует цель в принятом ограниченном классе.

ГЛАВА 14

Главные компоненты и PPCA

Материалы курса: лекции 13--14 и соответствующие семинары [L13, L14, S13, S14]. Теория: главы 16--17..

14.1 Разобранный пример: большая дисперсия не равна полезности

Пусть независимые признаки X_1 и X_2 центрированы, имеют дисперсии 100 и 1, а $Y = X_2$. Первая главная компонента выбирает X_1. Любой прогноз по ней имеет минимальный квадратичный риск $\mathrm{Var}(X_2) = 1$, хотя по двум исходным признакам риск нулевой. PCA оптимизирует восстановление X, не предсказание Y.

14.2 Задачи

Задача 14.1 (PCA вручную)**.** Для четырёх строк $(2,0), (-2,0), (0,1), (0,-1)$ найдите среднее, $X_c^{\mathsf{T}} X_c$, сингулярные значения, первую главную компоненту, координаты и восстановление ранга один. Вычислите SSE восстановления и долю объяснённой дисперсии. Что изменится после стандартизации обоих столбцов до единичной выборочной дисперсии?

Задача 14.2 (Проектор и лучший код)**.** Пусть $V^{\mathsf{T}} V = I_q$. Докажите, что для любого Z

$$\left\| X - Z V^{\mathsf{T}} \right\|_F^2 = \left\| X - X V V^{\mathsf{T}} \right\|_F^2 + \left\| X V - Z \right\|_F^2 .$$

Выведите оптимальный код $Z = XV$. Докажите, что ортогональный поворот базиса внутри выбранного подпространства не меняет восстановление.

Задача 14.3 (Второй момент в PPCA)**.** Используйте данные задачи 14.1, $\mu = 0$, $q = 1$, $W = (1,0)^{\mathsf{T}}$, $\sigma^2 = 1$. Выполните E-шаг PPCA: найдите все $m_i = \mathbb{E}[z_i \mid x_i]$ и $S_i = \mathbb{E}[z_i^2 \mid x_i]$. Затем найдите новое W и новую σ^2. Какой неверный результат для W получится, если заменить S_i на m_i^2?

14.3 Проверка результата

Сравнивая два PCA-разложения, сравнивайте проекторы VV^{T} или восстановленные матрицы, а не знаки отдельных векторов. При кратном спектре разные ортонормированные базисы могут быть одинаково правильными. Среднее и масштаб нового объекта берутся из обучения.

Часть II

Вычислительные работы

ГЛАВА 15

Девять вычислительных работ

Каждая работа завершается отчётом с определением цели, данных, алгоритма, протокола проверки и выводов. Для случайных экспериментов используйте несколько seed; для контрольных запусков ниже фиксированные seed позволяют повторить числа. Эталонные функции приведены в приложении А. Слово «сравнить» означает сравнение на одинаковых разбиениях и при явно указанном вычислительном бюджете.

15.1 Работа 1. NumPy, pandas и подготовка данных

Материалы курса: H01, S01 [H01, S01]..

Цель. Освоить индексацию, broadcasting, агрегации и отделение подготовки данных от оценки качества.

Данные. Используйте таблицу `titanic.csv` из каталога H01 исходного снимка. Для независимого контрольного примера создайте таблицу:

id	group	value	target
1	0	1	0
2	0	3	1
3	1	2	0
4	1	6	1

Средние `value` по группам должны быть 2 и 4, общая доля `target=1` равна $1/2$.

1. Опишите размеры, типы столбцов, пропуски, дубликаты и возможные идентификаторы. Различайте категорию и число с арифметическим смыслом.
2. Реализуйте векторизованные попарные квадраты расстояний через нормы и матричное произведение. Сравните с прямым вычислением на трёх точках. Небольшие отрицательные значения из-за округления обнулите только после проверки масштаба ошибки.
3. Разделите данные на train и test до оценки статистик. Постройте преобразование с заполнением числовых пропусков медианой и стандартизацией по train. Для постоянного столбца задайте масштаб 1.

4. Для категориальных признаков явно обработайте неизвестные категории. Обучите простой baseline и оцените accuracy и log-loss, если он выдаёт вероятности.

Критерии проверки. Ни одна строка test не участвует в оценке преобразований. Размерность после кодирования определена train; тест с новой категорией не падает. Не включайте идентификатор или производное от ответа в признаки без содержательного обоснования.

15.2 Работа 2. Собственное дерево

Материалы курса: H03 и S03 [H03, S03]..

Данные. Контрольный пример главы 4; затем двумерные `make_moons` и `make_circles` с $n = 600$, шумом 0.15 и seed 42. Разбиение $70 : 30$ фиксируется заранее.

1. Реализуйте лучший порог для бинарных меток по Джини, рекурсивное обучение и обход дерева. Используйте только границы разных значений.
2. Добавьте ограничения глубины и размера листа, остановку при чистых метках или отсутствии допустимого разбиения, детерминированный выбор ничьей.
3. Сравните глубины $1, 2, 4, 8$ и размеры листа $1, 5, 20$ по внутренней CV. Постройте границы решений выбранных вариантов.
4. Сравните с `DecisionTreeClassifier` при тех же ограничениях. Различия предсказаний при равных критериях не обязательно означают ошибку; сравните значения критериев.

Критерии проверки. На метках $(0, 0, 1, 1)$ при признаке $(1, 2, 3, 4)$ лучший порог 2.5, выигрыш 0.5. На постоянном признаке функция возвращает отсутствие разбиения. В отчёте отдельно обсуждаются обучающая и контрольная ошибки.

15.3 Работа 3. Оптимизаторы линейной регрессии

Материалы курса: H04 [H04]..

Создайте $X \in \mathbb{R}^{1000\times 10}$ со стандартными нормальными элементами, истинные веса $w_j^* = 1/j$, ответы $y = Xw^* + \varepsilon$ с $\varepsilon \sim \mathcal{N}(0, 0.1^2)$, seed 42. Отдельный тест генерируется независимо тем же механизмом.

1. Реализуйте GD, mini-batch SGD, Momentum и AdaGrad для $\|Xw - y\|^2/(2n)$. Проверьте градиент конечными разностями.

2. Сравните GD с МНК через `lstsq`; задайте шаг не больше $1/L$, $L = \|X\|_2^2/n$.
3. Для остальных методов подберите шаги по внутренней валидации. Для SGD исследуйте батчи $1, 16, 64, 256$. Сравнивайте число обработанных объектов, время и полную ошибку, а не только число шагов.
4. Повторите опыт после умножения первого столбца на 100 и после стандартизации. Добавьте ridge и сравните спектральную обусловленность.

Проверка. У GD с допустимым шагом полный функционал не возрастает. Это требование не распространяется на каждый шаг SGD. Критерий остановки содержит максимум итераций, конечность значений и проверку полного градиента или относительного улучшения. Для реального расширения можно использовать `autos.csv` из H04; логарифм цены меняет интерпретацию ошибки.

15.4 Работа 4. Протокол классификационного исследования

Материалы курса: H05, S05 [H05, S05]..

Используйте `train.csv` каталога H05 после чтения baseline и определения целевого столбца. Не используйте неизвестные метки исходного test. Альтернатива: синтетическая бинарная выборка с 2000 объектами и долей положительных 0.1.

Зафиксируйте внешний test 20%. На оставшейся части сравните логистическую регрессию, дерево, kNN и случайный лес. Все преобразования включите в `Pipeline`; для kNN и логистической модели используйте стандартизацию. Выберите основную метрику до исследования, например AP при редком положительном классе. На внутренней CV подберите гиперпараметры. Порог выбирайте на валидационных прогнозах с учётом заданной цены ошибок.

Результат. Таблица ROC AUC, AP, log-loss и матрицы ошибок выбранной модели; графики ROC и PR; описание выбора порога. Итоговый test оценивается после фиксации процедуры. Публичный leaderboard, если он доступен, не заменяет независимую оценку. Отбор признаков целиком повторяется внутри CV.

15.5 Работа 5. Взвешивание, нелинейность и астрономия

Материалы курса: H06a, H06b, L06, L07 [H06a, H06b, L06, L07]..

Обязательный синтетический вариант. На $t_i = \mathrm{linspace}(0, 2, 80)$ задайте $y_i = 2e^{-0.7t_i} + \varepsilon_i$, где $\sigma_i = 0.05 + 0.1t_i$ и независимый шум $\varepsilon_i \sim \mathcal{N}(0, \sigma_i^2)$, seed 42. Оцените два параметра по WLS и обычному МНК. Начните с $(a, b) =$

$(1, -0.2)$, проверьте аналитический якобиан и примените поиск шага. Сравните с `scipy.optimize.least_squares`, передавая нормированные остатки r_i/σ_i.

Вариант лазерной локации. Создайте 500 времён на $[-1, 1]$, сигнал $0.3 + 0.2t - 0.1t^2$, нормальный шум масштаба 0.02, а у 50 случайных точек добавьте равномерное загрязнение на $[-0.5, 0.5]$, seed 42. Сравните полиномы степеней $1, 2, 3$ и итерационное удаление больших остатков. Исследуйте чувствительность к начальному масштабу и порогу; отдельно сообщите RMS отдельных остатков и неопределённость полиномиального прогноза при $t = 0$.

Вариант определения орбиты. При наличии исходных наблюдений H06a реализуйте динамику, модель наблюдения и нелинейный WLS. Согласуйте единицы, шкалы времени, положение наблюдателя и время хода света. Проверьте чувствительности по начальным условиям на упрощённой задаче до использования полной модели. Синтетическая экспонента не считается решением реальной орбитальной задачи.

Доступность. В H06b сказано, что реальные данные выдавались преподавателем. Поэтому эта работа полностью воспроизводима на указанной синтетике; реальные результаты требуют отдельного получения наблюдений.

15.6 Работа 6. Нейросеть на NumPy

Материалы курса: H08, S10 [H08, S10]..

Реализуйте сеть $2 \to 4 \to 1$ с tanh и сигмоидным выходом. Входы XOR идут в порядке $(0,0), (0,1), (1,0), (1,1)$, ответы $(0, 1, 1, 0)$. Используйте среднюю log-loss и штраф $\lambda(\|W_1\|^2 + \|W_2\|^2)/2$, смещения не штрафуйте.

1. Проверьте каждый градиент на маленьком случайном батче центральными разностями при $h = 10^{-6}$. Сравните также направленную производную.
2. Используйте `default_rng(42)`, сначала $W_1 \sim \mathcal{N}(0, 0.7^2)$ формы 2×4, затем $W_2 \sim \mathcal{N}(0, 0.5^2)$ формы 4×1, нулевые смещения.
3. Обучите полным батчем 6000 шагов с $\eta = 0.3$, $\lambda = 10^{-4}$. Обновляйте все параметры одновременно.
4. Повторите для других seed и размеров скрытого слоя. Опишите неудачные запуски, если они есть.

Контрольный запуск эталонного ядра даёт вероятности примерно

$$(0.000739, 0.998266, 0.998929, 0.001910).$$

и цель 0.008192. Незначительное расхождение округлений допустимо. Проверка XOR характеризует способность реализации обучиться на четырёх точках, не тестовое качество.



Рис. 15.1: Фактически выполненный контрольный запуск работы 6.

15.7 Работа 7. SVM и ансамбли

Материалы курса: S08, S09 [S08, S09]..

На одной фиксированной выборке `make_moons` сравните линейный SVM, SVM с RBF-ядром, случайный лес и градиентный бустинг. Для SVM обучайте масштабы внутри CV; перебирайте C и γ по логарифмической сетке. Для ансамблей варьируйте глубину и число деревьев.

В отчёте укажите число опорных векторов, train/test ошибки, время обучения и предсказания, устойчивость к добавлению независимых шумовых признаков. Не трактуйте `decision_function` как вероятность. Если требуется log-loss, применяйте калибровку на обучающих разбиениях и отдельно объясните её вклад. Для AdaBoost на четырёх объектах проверьте численные веса задачи 9.2.

15.8 Работа 8. K-means, EM и PCA

Материалы курса: S11, S13, S14 [S11, S13, S14]..

Сначала сгенерируйте 300 точек из $\mathcal{N}(-2, 1)$ и 300 из $\mathcal{N}(2, 1)$ с `default_rng(73)`. Запустите EM с фиксированными дисперсиями 1, начальными средними $-1, 1$ и весами $1/2$. После 100 шагов контрольные средние примерно $(-1.991975, 2.006467)$, веса $(0.485943, 0.514057)$, log-likelihood -1221.397033. Начальное значение примерно -1506.660861. Допустимы колебания последних разрядов порядка 10^{-9}.

Затем сравните k-means, DBSCAN и гауссовскую смесь на двумерных компактных облаках и на двух окружностях. Для PCA проверьте равенство SSE хво-

стовой сумме квадратов сингулярных значений на данных задачи 14.1. Исследуйте, как стандартизация и добавление шумовых координат влияют на результаты. При сравнении кластеров используйте инвариантную к перестановкам метрику, например adjusted Rand index, и внутреннюю оценку силуэта, где она определена.

15.9 Работа 9. Байесовское обновление и Gibbs

Материалы курса: S12 [S12]..

Для задачи 12.1 постройте prior, likelihood с произвольным общим масштабом и нормированный posterior на $[0, 1]$. Проверьте интеграл posterior численной квадратурой и сопоставьте среднее с $9/14$.

Для двумерной нормальной модели задачи 12.4 реализуйте Gibbs при $\rho = 0, 0.5, 0.95$. Выполните несколько цепей из разных начальных состояний, сохраните трассы, автокорреляции и средние. Сравните дисперсию средних нескольких запусков с теоретическим множителем $(1+\rho^2)/(1-\rho^2)$. Число шагов, отбрасываемых как начальная часть, обоснуйте диагностикой; не объявляйте фиксированную длину универсальной гарантией.

15.10 Шаблон отчёта и итоговая проверка

Укажите задачу и оцениваемую величину; данные и механизм их получения; разбиение и правила обработки; точную цель, нормировку и алгоритм; проверки на малых примерах; основную таблицу результатов; ограничения вывода. Приложите seed и версии зависимостей. Отрицательный результат также содержателен, если показано, какой механизм его объясняет и какие проверки исключают ошибку реализации.

Часть III

Решения и проверка

ГЛАВА 16

Решения аналитических задач

Нумерация решений совпадает с нумерацией задач первой части. Численные округления приводятся после точных выражений.

16.1 Матрицы, данные и риск

Решение 1.1

Дифференциал квадратичной части равен $\operatorname{tr}((XW - Y)^{\mathsf{T}} X\, dW)/n$, поэтому $\nabla F = X^{\mathsf{T}}(XW - Y)/n + \lambda W$. Вторая вариация равна $\|XH\|_F^2/n + \lambda \|H\|_F^2 > 0$ при $H \neq 0$. Функция строго выпукла и коэрцитивна, значит, имеет единственный минимум.

Решение 1.2

Средние равны 1 и 34. Второе использует информацию теста. В каждом блоке CV на дополнении блока оценивают заполнение пропусков, масштабы, набор признаков и параметры модели; затем применяют уже фиксированные преобразования к отложенному блоку. После выбора настроек всю процедуру переобучают на полном train. Тест остаётся независимым.

Решение 1.3

Из $2Me^{-2n\varepsilon^2} \le \delta$ получаем $n \ge \log(4000)/0.005$, то есть $n = 1659$ достаточно. Избыточный риск эмпирического минимизатора не больше $2\varepsilon = 0.1$ на том же событии. Число гиперпараметров не характеризует число рассматриваемых моделей.

16.2 Линейная регрессия

Решение 2.1

Среднее y равно $4/3$, а $\sum x_i y_i / \sum x_i^2 = 3/2$. Поэтому $a = 4/3$, $b = 3/2$, остатки $y - \hat{y} = (1/6, -1/3, 1/6)$. $\mathrm{SSE} = 1/6$, $\mathrm{MSE} = 1/18$, оценка дисперсии $= 1/6$. Несмещённость последней требует корректного линейного среднего, нулевого среднего ошибок и ковариации $\sigma^2 I$ при фиксированном полном ранге плана.

Решение 2.2

Все решения удовлетворяют $w_1 + w_2 = 1$. Минимальная норма достигается при $w_1 = w_2 = 1/2$. Для ridge система имеет правую часть $(5, 5)^\mathsf{T}$ и матрицу с диагональю $5 + \lambda$ и внедиагональными элементами 5. Поэтому обе координаты равны $5/(10 + \lambda)$ и стремятся к $1/2$.

Решение 2.3

Ridge даёт $z/(1 + \lambda) = (2, -2/3, 2/15)$. LASSO даёт $(2.5, -0.5, 0)$ по мягкому порогу. В нуле субградиент модуля является интервалом, позволяющим компенсировать градиент ошибки; у квадратичного штрафа такого интервала нет.

Решение 2.4

$F = 5(w - 1)^2/4$, полный градиент $5(w - 1)/2$. Стохастические градиенты равны $w - 1$ и $4(w - 1)$. Из нуля получаются соответственно полный шаг 0.25 и случайные шаги $0.1, 0.4$; их среднее 0.25. Ошибка полного метода умножается на $1 - 2.5\eta$, поэтому сходимость при $0 < \eta < 0.8$.

16.3 Логистическая регрессия

Решение 3.1

Оба слагаемых дают $F(w) = \log(1 + e^{-w})$. Она положительна и стремится к нулю при $w \to \infty$. После штрафа производная равна $-1/(1 + e^w) + \lambda w$, вторая производная строго положительна, а функция коэрцитивна. Единственный корень удовлетворяет $\lambda w = 1/(1 + e^w)$ и положителен.

Решение 3.2

Деление числителя и знаменателя на $e^{w_2^\mathsf{T} x}$ даёт $\sigma(v^\mathsf{T} x)$. Представим $w_1 = a + v/2$, $w_2 = a - v/2$. Сумма норм равна $2\|a\|^2 + \|v\|^2/2$, минимальна при $a = 0$. Штраф становится $\lambda\|v\|^2/4$.

Решение 3.3

Градиенты равны $(p - y)x$ и $(p - y)p(1 - p)x$. При заданных данных это $(-1/2, -1)$ и $(-1/8, -1/4)$. При уверенно неправильной вероятности $p - y$ остаётся большим, но множитель $p(1 - p)$ стремится к нулю.

16.4 Деревья

Решение 4.1

Для квадратов оптимум $11/5$, MSE $384/25$. Для модулей медиана 0, MAE $11/5$. Для бинарных меток вероятность $2/5$, энтропия $-\frac{3}{5}\log\frac{3}{5}-\frac{2}{5}\log\frac{2}{5}$, Джини $12/25$. Классификационная метка при пороге $1/2$ равна нулю, но вероятность сохраняет информацию о составе листа.

Решение 4.2

Пороги $1.5, 3, 4.5$ дают суммы SSE $11, 8/3, 11$. Лучший порог 3. После сортировки поддерживаются суммы ответов и их квадратов; для группы размера k SSE равна $Q - S^2/k$. Все допустимые границы проверяются за $O(n)$, сортировка требует $O(n\log n)$. Равные значения нельзя разделить одним пороговым предикатом.

Решение 4.3

В корне доли классов равны; в каждом потомке после первого разбиения они также равны. Оба выигрыша нулевые. После разбиения каждого потомка по другому признаку листья чистые. Правило остановки по нулевому выигрышу остановится слишком рано. Локальный критерий не учитывает пользу следующего уровня.

16.5 Метрические методы

Решение 5.1

Второй объект ближе, когда $V^2 + 0.25 < U^2 + 0.01$, то есть $U > \sqrt{V^2 + 0.24}$. Положим $b = \sqrt{0.76}$. Искомая вероятность

$$\int_0^b (1 - \sqrt{v^2 + 0.24})\, dv = \frac{b}{2} - 0.12 \log \frac{1+b}{\sqrt{0.24}} \approx 0.275036.$$

Без нового признака первый объект всегда ближе, вероятность равна нулю.

Решение 5.2

Вероятность отсутствия точек в шаре радиуса r равна $(1 - r^d)^n$. Медиана $m = (1 - 2^{-1/n})^{1/d}$, в примере $m \approx 0.517792$. Для $m \le 1/2$ требуется $n \ge \lceil \log(1/2) / \log(1 - 2^{-d}) \rceil$. Асимптотически это $(\log 2) 2^d$, экспоненциальный рост.

Решение 5.3

Константа предсказывает среднее 3, прямая $1 + 2t$ предсказывает 1. При аффинных данных исходные коэффициенты дают нулевую взвешенную ошибку; полный ранг обеспечивает единственность. Экстраполяция, например в $t = -1$, даёт -1, вне диапазона $[1, 5]$.

16.6 Метрики

Решение 6.1

После порогов $0.9, 0.8, 0.4, 0.1$ пары (TP, FP) равны $(1, 0), (2, 1), (2, 2), (3, 2)$. Recall равна $1/3, 2/3, 2/3, 1$, precision $1, 2/3, 1/2, 3/5$, FPR $0, 1/2, 1, 1$. Парные вклады трёх положительных объектов равны $2, 1.5, 0$, поэтому AUC $= 3.5/6 = 7/12$. AP $= 1/3 + 2/9 + 1/5 = 34/45$. Трапецеидальная PR-площадь $= 1/3 + 5/18 + 11/60 = 143/180$.

Решение 6.2

Дефектные межклассовые пары составляют $n_+n_-(1 - AUC)$, откуда $DP = 2n_+n_-(1 - AUC)/(n(n - 1))$. При ничьей порядок произволен и число инверсий меняется. Нужно считать по половине за каждую межклассовую пару с равными оценками; тогда формула остаётся верной для AUC с половинным вкладом ничьей.

Решение 6.3

В подпунктах (а)--(в) возьмём $y = (1, 0, 1, 0, 0)$. (а) Первый прогноз $(.99, .98, .97, .96, .95)$ имеет AUC $5/6$, log-loss 2.033428; второй $(.8, .3, .2, .4, .1)$ имеет AUC $2/3$, log-loss 0.561089. (б) Первый $(.9, .4, .1, .2, .05)$ имеет precision 1, AUC $2/3$; второй $(.9, .7, .8, .6, .1)$ имеет precision $1/2$, AUC 1. (в) Первый $(.9, .4, .1, .2, .1)$ имеет precision 1, recall $1/2$; второй $(.9, .8, .7, .6, .1)$ имеет precision $1/2$, recall 1. Для (г) положим $y = (1, 1, 1, 0, 0)$. Первый прогноз $(.8, .7, .6, .9, .5)$ имеет максимальный $F_1 = 6/7$ и AUC $1/2$. Второй $(.9, .8, .5, .7, .6)$ имеет максимальный $F_1 = 4/5$ и AUC $2/3$. Максимумы проверяются перебором пяти возможных непустых префиксов ранжирования.

Решение 6.4

Ожидаемая ошибка равна $\eta + p(1 - 2\eta)$. При $\eta > 1/2$ минимум в $p = 1$, при $\eta < 1/2$ в $p = 0$, при равенстве все прогнозы равноценны. Округление улучшает ошибку, если направляет p к правильному для η концу. При $\eta = 0.8, p = 0.4$

округление к нулю увеличивает ошибку с 0.56 до 0.8. Log-loss минимальна при $p = \eta$.

16.7 Взвешенный и нелинейный МНК

Решение 7.1

Сумма весов $9/4$, взвешенная сумма ответов $17/4$, поэтому оценка $17/9$, дисперсия $4/9$. Взвешенная SSE $29/9$, приведённый хи-квадрат $29/18$. Это одно случайное значение; оно само не доказывает ни неверность модели, ни неверность заявленных дисперсий.

Решение 7.2

$L = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix}$. Решение $Lz = b$ равно $(3, \sqrt{2})$, решение $L^{\mathsf{T}}\beta = z$ равно $(1, 1)$. Невырожденность L даёт $u^{\mathsf{T}}Au = \left\|L^{\mathsf{T}}u\right\|^2 > 0$. После замены элемента на 1 определитель равен нулю; вектор $(1, -2)$ имеет нулевую квадратичную форму, положительной определённости нет.

Решение 7.3

$r = (0, -2)$, $J = \begin{pmatrix} 1 & 0 \\ 2 & 2\log 2 \end{pmatrix}$. Решение $J\Delta = -r$ равно $(0, 1/\log 2)$. Линеаризованная невязка нулевая, фактическая новая равна $(0, 2e - 4)$. Решение динамической задачи $s = s_0 e^{pt}$ имеет производные e^{pt} и ts_0e^{pt}. Их производные по времени удовлетворяют $\dot{S}_{s_0} = pS_{s_0}$ и $\dot{S}_p = pS_p + s$, с начальными значениями 1 и 0.

16.8 SVM

Решение 8.1

Ограничения в точках -1 и 1 дают $w \geq 1 + |b|$. Минимум $w = 1, b = 0$, полоса ширины 2. Опорные точки $-1, 1$ имеют множители по $1/2$, остальные множители нулевые. Они удовлетворяют стационарности и KKT. В soft-margin это решение допустимо в двойственной задаче при $C \geq 1/2$ и остаётся оптимальным. При меньшем C его KKT-множители не помещаются в допустимый интервал.

Решение 8.2

Исключение переменных даёт квадрат hinge $C\sum_i(1-M_i)_+^2$. Минимизация лагранжиана по w, b даёт $w=\sum_i\alpha_i y_i x_i$ и $\sum_i\alpha_i y_i=0$. Для $\alpha_i\ge 0$ минимум $C\xi_i^2-\alpha_i\xi_i$ на $\xi_i\ge 0$ достигается при $\xi_i=\alpha_i/(2C)$ и равен $-\alpha_i^2/(4C)$. Поэтому двойственная цель

$$\sum_i\alpha_i-\frac{1}{2}\sum_{ij}\alpha_i\alpha_j y_i y_j K_{ij}-\frac{1}{4C}\sum_i\alpha_i^2$$

максимизируется при $\alpha_i\ge 0$, $\sum_i\alpha_i y_i=0$, без верхнего ограничения. В матрицу квадратичной формы добавляется $I/(2C)$.

Решение 8.3

Для $c=(1,-1)$ имеем $c^{\mathsf T}Gc=-2$, поэтому это не матрица Грама. Сумме ядер отвечает объединённый признак $(\phi_1,\sqrt{2}\phi_2)$, произведению тензорный признак $\phi_1\otimes\phi_2$. Неотрицательные значения сами не обеспечивают неотрицательность всех квадратичных форм.

16.9 Ансамбли

Решение 9.1

Вероятность пропуска $(1-1/n)^n$. Ожидаемое число различных объектов $n[1-(1-1/n)^n]$ по сумме индикаторов. Пределы вероятности пропуска и доли различных равны e^{-1} и $1-e^{-1}$. Дисперсия среднего $4(0.1+0.9/10)=0.76$, предел 0.4.

Решение 9.2

$\varepsilon=1/4$, $\alpha=\frac{1}{2}\log 3$, $Z=\sqrt{3}/2$. Каждый верный объект получает вес $1/6$, ошибочный $1/2$. В общем случае суммарные веса верных и ошибочных равны $(1-\varepsilon)e^{-\alpha}/Z$ и $\varepsilon e^{\alpha}/Z$; условие оптимума $Z'(\alpha)=0$ делает их равными.

Решение 9.3

Остатки $(-1,1,2,4)$, средние по листьям $0,3$. При полном шаге прогноз $(1,1,4,4)$, SSE 4. При $\nu=0.1$ прогноз $(1,1,1.3,1.3)$, SSE 18.58, исходная SSE 22. Для log-loss по логиту $g_i=p_i-y_i$, $h_i=p_i(1-p_i)$, ньютоновская поправка листа равна $-\sum_i g_i/(\sum_i h_i+\lambda)$ при положительном знаменателе.

16.10 Нейронные сети

Решение 10.1

Две различные точки разделяются плоскостью через их середину с нормалью, равной разности точек. Три точки $-1, 0, 1$ с метками $-1, +1, -1$ неразделимы: положительность в нуле требует $b > 0$, а отрицательность на концах даёт $b + w < 0$, $b - w < 0$, откуда $2b < 0$. XOR является удобным двумерным примером, но не минимальным без запрета коллинеарности.

Решение 10.2

$h = p = 1/2$, потеря $\log 2$. Производные по (w, b, v, c) равны $(0, 0, -1/4, -1/2)$. Новый вектор $(0, 0, \eta/4, \eta/2)$. Градиент должен вычисляться в одной исходной точке; использование нового v меняет производную и перестаёт быть одновременным градиентным шагом.

Решение 10.3

При одинаковых параметрах активации совпадают. При одинаковых выходных весах совпадают и обратные сигналы, поэтому совпадают обновления; индукция сохраняет равенство на всех шагах. Направленная проверка сравнивает $[F(\theta+hv)-F(\theta-hv)]/(2h)$ с $\nabla F^{\mathsf{T}} v$. При гладкости ошибка аппроксимации $O(h^2)$, но округление растёт при слишком малом h. Нужно проверить несколько масштабов и исключить пересечение изломов ReLU.

16.11 Кластеризация

Решение 11.1

Начальная SSE 25. Первое присваивание даёт группы $\{0\}$, $\{1, 4, 5\}$, новые центры $0, 10/3$, SSE $26/3$. Следующее даёт $\{0, 1\}$, $\{4, 5\}$, центры $1/2, 9/2$, SSE 1. Для любой группы $\sum \|x_i - a\|^2 = \sum \|x_i - \overline{x}\|^2 + m \|a - \overline{x}\|^2$, поэтому среднее минимизирует ошибку.

Решение 11.2

Основные точки только -0.7 и 0.7: каждая видит три точки своей стороны и нуль. Точка 0 видит лишь себя и эти две точки, поэтому не основная. Все остальные граничные, шумовых нет. Основные компоненты раздельны; нуль может присоединяться к любой из них по соглашению обхода.

Решение 11.3

Стационарность даёт $2f_2 - f_3 = 0$, $2f_3 - f_2 = 1$, откуда $f_2 = 1/3, f_3 = 2/3$. Гессиан положительно определён; эквивалентно нулевая энергия возмущения с нулевыми концами вынуждает всё возмущение быть нулевым. Без меток любая константа имеет нулевую энергию, единственности нет.

16.12 Байесовские методы

Решение 12.1

Posterior $\mathrm{Beta}(9, 5)$, среднее и прогноз $9/14$, мода $8/12 = 2/3$. После первого блока параметры $(5, 3)$, после второго $(9, 5)$: показатели правдоподобия складываются независимо от разбиения на блоки.

Решение 12.2

Posterior precision $1 + 3/4 = 7/4$, дисперсия $4/7$, среднее $(4/7)(6/4) = 6/7$. Новый ответ имеет закон $\mathcal{N}(6/7, 32/7)$. Дополнительные 4 в дисперсии являются шумом нового измерения. Prior притягивает оценку среднего от обычного среднего 2 к нулю.

Решение 12.3

Вероятности наблюдения в классах равны $0.8 \cdot 0.3 = 0.24$ и $0.2 \cdot 0.7 = 0.14$. Posterior класса 1 равен $12/19$. Для точных копий правильный posterior при двух единицах равен 0.8; неверное независимое произведение даёт $0.8^2/(0.8^2 + 0.2^2) = 16/17$. Повторный учёт одной информации завышает уверенность.

Решение 12.4

$U \mid V \sim \mathcal{N}(\rho V, 1 - \rho^2)$, $V \mid U \sim \mathcal{N}(\rho U, 1 - \rho^2)$. После полного цикла $V_{t+1} = \rho^2 V_t + \rho\varepsilon_t + \eta_t$, где независимые шумы имеют дисперсию $1 - \rho^2$. Получается стационарная AR(1) с коэффициентом ρ^2. Лаговые корреляции ρ^{2k}, множитель дисперсии среднего $1 + 2\sum_{k \ge 1} \rho^{2k} = (1 + \rho^2)/(1 - \rho^2)$.

16.13 EM и KL

Решение 13.1

$\mathrm{KL}(p \| q) = \frac{1}{2}\log(4/3) \approx 0.143841$; обратная $\frac{3}{4}\log(3/2) + \frac{1}{4}\log(1/2) \approx 0.130812$. Для $p = (1, 0)$, $q = (1/2, 1/2)$ первая ориентация $\log 2$, обратная бесконечна из-за массы там, где $p = 0$. Симметрии нет.

Решение 13.2

Матрица ответственностей $\begin{pmatrix} a & 1-a \\ 1-a & a \end{pmatrix}$, $a = \sigma(2)$. Обе эффективные численности равны 1, новые веса $1/2$. Средние $1-2a$ и $2a-1$, то есть $\mp\tanh 1$. Обе дисперсии $1-(2a-1)^2 \approx 0.419974$. Это взвешенные вторые моменты минус квадрат новых средних.

Решение 13.3

При точном E-шаге граница равна текущему log-likelihood, M-шаг увеличивает границу, а новый log-likelihood не меньше новой границы. Для вырождения зафиксируем вес первой компоненты $\pi \in (0,1)$, её среднее в одной точке выборки и дисперсию $\varepsilon^2 \to 0$. Вторую невырожденную компоненту оставим с положительной плотностью на остальных наблюдениях. В выбранной точке плотность растёт как $1/\varepsilon$, а остальные вклады ограничены снизу положительными числами. Log-likelihood неограничен. Монотонность этому не противоречит. Произвольная добавка к ковариации не является точным M-шагом, поэтому требует отдельного обоснования для изменённой цели.

16.14 PCA и PPCA

Решение 14.1

Среднее нулевое, $X^\mathsf{T}X = \operatorname{diag}(8,2)$, сингулярные значения $2\sqrt{2}, \sqrt{2}$. Первое направление $(1,0)$, координаты $(2,-2,0,0)$, восстановление зануляет второй столбец. SSE 2, объяснённая доля $4/5$. После стандартизации ковариация единичная, все направления равноправны и единственного первого направления нет.

Решение 14.2

Разность $X - XVV^\mathsf{T}$ ортогональна по строкам подпространству V, а $(XV - Z)V^\mathsf{T}$ лежит в нём. Их скалярное произведение Фробениуса нулевое. Теорема Пифагора и $\|AV^\mathsf{T}\|_F = \|A\|_F$ дают тождество. При замене V на VR, $R^\mathsf{T}R = I$, код меняется на XVR, проектор остаётся $VRR^\mathsf{T}V^\mathsf{T} = VV^\mathsf{T}$.

Решение 14.3

$M = 2$, условная дисперсия $1/2$, средние $m = (1,-1,0,0)$. Вторые моменты $(3/2, 3/2, 1/2, 1/2)$, их сумма 4. Числитель обновления W равен $(4,0)^\mathsf{T}$, значит, W остаётся $(1,0)^\mathsf{T}$. Новая дисперсия $(10-8+4)/8 = 3/4$. Если выбросить условную

дисперсию из вторых моментов, знаменатель станет 2 и получится неверное $W = (2, 0)^{\mathsf{T}}$.

ГЛАВА A

Вычислительные ядра

Следующие функции используют NumPy. Они предназначены для конечных вещественных массивов согласованной формы. Бинарные метки кодируются числами $0, 1$; в `best_gini_split` предполагается одномерный числовой признак. Ridge штрафует все переданные координаты, поэтому нештрафуемый свободный член следует оценивать через предварительное центрирование.

В `em_fixed_variance` дисперсии компонент фиксированы и равны 1. Это намеренное ограничение позволяет проверять точную монотонность без произвольных добавок к ковариациям. В `mlp_loss_grad` параметры передаются как (W_1, b_1, W_2, b_2), выход имеет один столбец, скрытая активация tanh. Цель включает среднюю log-loss и указанный штраф.

```
import numpy as np


def ridge_fit(X, y, lam):
    n, d = X.shape
    A = np.vstack((X, np.sqrt(n * lam) * np.eye(d)))
    b = np.concatenate((y, np.zeros(d)))
    return np.linalg.lstsq(A, b, rcond=None)[0]


def logistic_loss_grad(w, X, y, lam=0.0):
    z = X @ w
    p = np.exp(-np.logaddexp(0.0, -z))
    loss = np.mean(np.logaddexp(0.0, z) - y * z)
    loss += 0.5 * lam * (w @ w)
    grad = X.T @ (p - y) / len(y) + lam * w
    return loss, grad


def best_gini_split(x, y, min_leaf=1):
    order = np.argsort(x, kind="stable")
    xs, ys = x[order], y[order]
    n = len(y)
    k = np.arange(1, n)
    left = np.cumsum(ys)[:-1]
    p_left = left / k
    p_right = (ys.sum() - left) / (n - k)
    impurity = (k * 2 * p_left * (1 - p_left)
                + (n - k) * 2 * p_right * (1 - p_right)) / n
```

```
    valid = ((xs[:-1] < xs[1:]) & (k >= min_leaf)
             & (n - k >= min_leaf))
    if not valid.any():
        return None
    j = np.argmin(np.where(valid, impurity, np.inf))
    threshold = xs[j] + (xs[j + 1] - xs[j]) / 2
    parent = 2 * ys.mean() * (1 - ys.mean())
    return threshold, parent - impurity[j]


def binary_curves(y, scores):
    order = np.argsort(-scores, kind="stable")
    s, y = scores[order], y[order]
    n_pos, n_neg = y.sum(), len(y) - y.sum()
    if n_pos == 0 or n_neg == 0:
        raise ValueError("Both classes are required")
    ends = np.r_[np.flatnonzero(s[:-1] != s[1:]), len(s) - 1]
    tp = np.cumsum(y)[ends]
    fp = ends + 1 - tp
    recall = np.r_[0.0, tp / n_pos]
    fpr = np.r_[0.0, fp / n_neg]
    precision = np.r_[1.0, tp / (tp + fp)]
    auc = np.trapezoid(recall, fpr)
    ap = np.sum(np.diff(recall) * precision[1:])
    return fpr, recall, precision, auc, ap


def wls_fit(X, y, sigma):
    return np.linalg.lstsq(X / sigma[:, None],
                           y / sigma, rcond=None)[0]


def mlp_loss_grad(params, X, y, lam=0.0):
    W1, b1, W2, b2 = params
    H = np.tanh(X @ W1 + b1)
    z = (H @ W2 + b2).ravel()
    p = np.exp(-np.logaddexp(0.0, -z))
    loss = np.mean(np.logaddexp(0.0, z) - y * z)
    loss += 0.5 * lam * (np.sum(W1**2) + np.sum(W2**2))
    D2 = ((p - y) / len(y))[:, None]
    D1 = (D2 @ W2.T) * (1 - H**2)
    grads = (X.T @ D1 + lam * W1, D1.sum(axis=0),
             H.T @ D2 + lam * W2, D2.sum(axis=0))
    return loss, grads, p


def em_fixed_variance(x, mu, pi, max_iter=100):
    mu, pi = mu.copy(), pi.copy()
    history = []
```

```
    for iteration in range(max_iter + 1):
        log_joint = (np.log(pi)[None, :]
                     - 0.5 * (x[:, None] - mu[None, :])**2
                     - 0.5 * np.log(2 * np.pi))
        log_norm = np.logaddexp.reduce(log_joint, axis=1)
        history.append(log_norm.sum())
        if iteration == max_iter:
            break
        resp = np.exp(log_joint - log_norm[:, None])
        counts = resp.sum(axis=0)
        if np.any(counts == 0):
            raise ValueError("Empty component")
        mu = (resp.T @ x) / counts
        pi = counts / len(x)
    return mu, pi, np.array(history)


def pca_fit(X, q):
    mean = X.mean(axis=0)
    U, s, Vt = np.linalg.svd(X - mean, full_matrices=False)
    V = Vt[:q].T
    return mean, V, s
```

A.1 Результаты контрольного выполнения

Максимальная абсолютная ошибка проверки координатного градиента логистической модели составила $8.31 \cdot 10^{-11}$, сети $1.31 \cdot 10^{-10}$ при центральных разностях с $h = 10^{-6}$. Для метрик с ничьими получены AUC $7/12$ и AP $34/45$, совпавшие с `roc_auc_score` и `average_precision_score`. Для WLS-константы получено $17/9$, для PCA ранга один SSE 2.

В контрольном EM минимальное приращение log-likelihood за 100 шагов равно примерно $-4.55 \cdot 10^{-13}$: это масштаб округления, согласующийся с теоретической монотонностью. Для XOR все четыре класса определены правильно. Эти проверки относятся к приведённым ядрам и контрольным данным; полный эксперимент каждой работы дополнительно проверяет выбранную процедуру на собственных данных.

ГЛАВА B

Маршрут по исходным заданиям

Источник	Тема	Раздел практикума
H01	NumPy и pandas	Работа 1, глава 1
H02	Логистическая регрессия, деревья	Главы 3--4, решения 3.1--4.3
H03	Реализация дерева	Работа 2
H04	Градиентные методы	Работа 3, глава 2
H05	Классификационное исследование	Работа 4
H06a	Орбитальные наблюдения	Работа 5: динамический вариант
H06b	Лазерная локация	Работа 5: полиномиальный вариант
H07	kNN, метрики и SVM	Главы 5--6 и 8
H08	Сеть на NumPy	Работа 6, глава 10
S08--S14	Остальные семинарские темы	Работы 7--9, главы 8--14

Упражнения переработаны для самостоятельного изучения и не сохраняют исходную балльную систему. Работа с внешним соревнованием заменена воспроизводимым протоколом исследования. Полные решения аналитических задач помещены отдельно, чтобы условия можно было использовать независимо от подсказок.

Источники и лицензия

Основной источник: открытый курс «Машинное обучение» МКН СПбГУ. Ссылки ниже ведут к использованному снимку исходных файлов. Обозначения L, S и H соответствуют лекциям, семинарам и домашним заданиям. Нумерация взята из имён каталогов; в заголовке файла H07 ошибочно указан номер 6.

Литература

[L01] Введение и постановки задач. Исходный файл.

[L02] Линейные модели, SGD и правдоподобие. Исходный файл.

[L03] Байесовский подход и логические методы. Исходный файл.

[L04] Метрические методы. Исходный файл.

[L05] Оценивание качества и отбор признаков. Исходный файл.

[L06] Взвешенный метод наименьших квадратов. Д. А. Павлов. Исходный файл.

[L07] Нелинейный метод наименьших квадратов. Д. А. Павлов. Исходный файл.

[L08] Метод опорных векторов. Исходный файл.

[L09] Композиции классификаторов. Исходный файл.

[L10] Нейронные сети и backpropagation. Исходный файл.

[L11] Кластеризация и частичное обучение. Исходный файл.

[L12] Введение в байесовские методы. Исходный файл.

[L13] EM-алгоритм и PPCA. Исходный файл.

[L14] Многомерная регрессия и PCA. Исходный файл.

[S01] Семинар 1. NumPy и pandas. Исходный файл.

[S02] Семинар 2. Матричное дифференцирование. Исходный файл.

[S03] Семинар 3. Линейные модели. Исходный файл.

[S04] Семинар 4. Метрические методы. Исходный файл.

[S05] Семинар 5. Оценивание качества и отбор признаков. Исходный файл.

[S08] Семинар 8. Метод опорных векторов. Исходный файл.

[S09] Семинар 9. Композиции классификаторов. Исходный файл.

[S10] Семинар 10. Нейронные сети и backpropagation. Исходный файл.

[S11] Семинар 11. Кластеризация и частичное обучение. Исходный файл.

[S12] Семинар 12. Введение в байесовские методы. Исходный файл.

[S13] Семинар 13. EM-алгоритм и PPCA. Исходный файл.

[S14] Семинар 14. Многомерная регрессия и PCA. Исходный файл.

[EXAM] Экзаменационные вопросы первого семестра. Исходный файл.

[H01] Домашнее задание. NumPy и pandas. Исходный файл.

[H02] Домашнее задание. Логические методы, теоретическое задание. Исходный файл.

[H03] Домашнее задание. Решающие деревья. Исходный файл.

[H04] Домашнее задание. Градиентный спуск своими руками. Исходный файл.

[H05] Домашнее задание. Бинарная классификация. Исходный файл.

[H06a] Домашнее задание. Определение орбиты 1I/Оумуамуа. Исходный файл.

[H06b] Домашнее задание. Лазерная локация Луны. Исходный файл.

[H07] Домашнее задание. kNN, SVM и оценка качества. Исходный файл.

[H08] Домашнее задание. Нейронная сеть на NumPy. Исходный файл.

[PLAN] План занятий и домашних заданий. Исходный файл.

Лицензия исходного репозитория

Исходный репозиторий распространяется по MIT License. Учебная переработка сохраняет следующее уведомление. Содержание ниже относится к исходным материалам.

MIT License

Copyright (c) 2021 spbu-math-cs

Permission is hereby granted, free of charge, to any person obtaining a copy of this software and associated documentation files (the ”Software”), to deal in the Software without restriction, including without limitation the rights to use, copy, modify, merge, publish, distribute, sublicense, and/or sell copies of the Software, and to permit persons to whom the Software is furnished to do so, subject to the following conditions:

The above copyright notice and this permission notice shall be included in all copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED ”AS IS”, WITHOUT WARRANTY OF ANY KIND, EXPRESS OR IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY, FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM, OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE SOFTWARE.