Машинное обучение

Книга I. Теория

Определения, математические модели,
теоремы и доказательства

Самостоятельное учебное изложение
по материалам `spbu-math-cs/ml-course`
Раздел `2021-fall-part-1`

Учебная редакция 1.0 · 29 октября 2026

Предисловие

Эта книга представляет собой связное математическое изложение первого семестра курса «Машинное обучение» МКН СПбГУ по открытому репозиторию `spbu-math-cs/ml-course`, разделу `2021-fall-part-1`. Она предназначена для читателя, знакомого с линейной алгеброй, математическим анализом и основами теории вероятностей. Вычислительные упражнения и самостоятельные задачи вынесены в книгу II.

Структура определяется содержанием лекций, семинаров, домашних заданий и экзаменационного списка. Порядок нескольких тем изменён: линейный МНК и его статистические свойства изучаются до нелинейного МНК, а логистическая регрессия отделена от общей оптимизации. Все 14 нумерованных учебных тем отражены в книге. Гостевая лекция, для которой в репозитории имеется лишь внешняя ссылка, не реконструируется. Материал второго семестра не включён.

Текст не является официальным учебником СПбГУ и не приписывается преподавателям курса. Определения, доказательства, примеры и редакционные уточнения подготовлены заново. Доказательства конечноклассовой оценки риска, свойства проекций, некоторые пояснения к обусловленности и графовому частичному обучению добавлены для математической связности. В конце приведены соответствие исходным материалам, редакционные уточнения и лицензия.

Как читать

Главы 1--7 образуют фундамент: постановка задачи, риск, оптимизация и линейные модели. Главы 8--14 описывают основные семейства алгоритмов. Главы 15--17 объединяют вероятностное моделирование, скрытые переменные и снижение размерности. В конце каждой главы помещены вопросы для проверки понимания. Их следует использовать для восстановления выводов, а не для заучивания формул без предпосылок.

Формула с обратной матрицей означает математическое описание решения. В численной реализации предпочтительно решать соответствующую систему или использовать QR/SVD. Утверждения о сходимости, несмещённости и оптимальности всегда относятся к явно указанным условиям; эвристика алгоритма сама по себе таким утверждением не является.

Происхождение материалов

Использован снимок репозитория с commit

`31773dc85ce30b55b93400dc835362b2b867e296`.

Дата фиксации материалов для этой редакции: 29 октября 2026 года. Команда курса, указанная во вводной лекции: Александр Авдюшенко, Екатерина Гащенко, Пётр Мостовский, Иван Долгов, Олег Кудашев, Дмитрий Павлов. Лекции о взвешенном и нелинейном МНК подписаны Д. А. Павловым. Права на исходные материалы сохраняются за их авторами; лицензия репозитория приведена полностью.

Оглавление

Предисловие **i**

1 Математический язык обучения **1**

1.1 Объекты, признаки и выборка 1

1.2 Линейная алгебра и нормы 2

1.3 Дифференцирование по вектору и матрице 2

1.4 Выпуклость и условная оптимизация 3

2 Риск и обобщающая способность **4**

2.1 Популяционный и эмпирический риск 4

2.2 Ошибки приближения, оценивания и оптимизации 5

2.3 Конечноклассовая гарантия 5

2.4 Смещение и разброс 6

2.5 Валидация как часть метода 6

3 Градиентные методы **7**

3.1 Градиентный шаг и гладкость 7

3.2 Стохастический градиент 8

3.3 Модификации и оценка прогресса 8

3.4 Регуляризация и устойчивость вычислений 9

4 Линейная регрессия и регуляризация **10**

4.1 Нормальные уравнения и проекция 10

4.2 SVD и минимальная норма 11

4.3 Гребневая регрессия 11

4.4 LASSO и разреженность 12

4.5 Несколько ответов 12

5 Взвешенный МНК и точность оценок **14**

5.1 Статистическая линейная модель 14

5.2 Гетероскедастичность и отбеливание 15

5.3 Остатки и оценка масштаба 15
5.4 Разложение Холецкого 16

6 Нелинейный МНК и динамические модели 17
6.1 Линеаризация невязки 17
6.2 Демпфирование и идентифицируемость 18
6.3 Пример: экспоненциальный отклик 18
6.4 Параметры дифференциального уравнения 18
6.5 Астрономические приложения и границы модели 19

7 Логистическая и многоклассовая регрессия 20
7.1 Отступ и суррогатная потеря 20
7.2 Модель Бернулли и правдоподобие 20
7.3 Градиент, выпуклость и достижимость минимума 21
7.4 Softmax и неидентифицируемость 21
7.5 Вероятностный смысл регуляризации 22

8 Логические правила и решающие деревья 24
8.1 Предикаты и закономерности 24
8.2 Дерево как разбиение пространства 24
8.3 Энтропия и индекс Джини 25
8.4 CART и стоимость поиска 26
8.5 Ограничение сложности и особенности данных 26

9 Метрические методы 28
9.1 Близость и взвешенное голосование 28
9.2 Окно Парзена и потенциальные функции 28
9.3 Непараметрическая регрессия 29
9.4 Локальная линейная регрессия и выбросы 29
9.5 Проклятие размерности 30

10 Метрики качества и отбор признаков 32
10.1 Матрица ошибок и цена решения 32
10.2 ROC, PR и равные оценки 32
10.3 Вероятностные прогнозы и регрессия 33

10.4 Отбор признаков как задача выбора модели 34

11 Метод опорных векторов и ядра 36

11.1 Геометрический зазор 36
11.2 Мягкий зазор и hinge loss 36
11.3 Двойственная задача и условия KKT 36
11.4 Допустимые ядра 37
11.5 Регрессия и другие штрафы 38

12 Композиции алгоритмов 39

12.1 Усреднение, бэггинг и случайные признаки 39
12.2 AdaBoost как минимизация экспоненциальной потери 40
12.3 Градиентный бустинг 41
12.4 Квадратичное приближение в деревьях 41

13 Нейронные сети и обратное распространение 42

13.1 Зачем нужна нелинейность 42
13.2 Прямой проход и размерности 42
13.3 Обратный проход 43
13.4 Стоимость, инициализация и симметрия 43
13.5 Регуляризация и проверка реализации 44

14 Кластеризация и частичное обучение 45

14.1 Постановка задачи и неоднозначность 45
14.2 K-means и алгоритм Ллойда 45
14.3 DBSCAN 46
14.4 Иерархическая кластеризация 46
14.5 Использование неразмеченных объектов 47

15 Байесовское обучение и моделирование 49

15.1 Формула Байеса и предсказание 49
15.2 Сопряжённость: Бернулли и нормальная модель 50
15.3 Байесовская линейная регрессия 50
15.4 Наивный байесовский классификатор 51
15.5 Монте-Карло и цепи Маркова 51

16 Скрытые переменные и EM **53**
16.1 KL-дивергенция . . . 53
16.2 Нижняя граница правдоподобия . . . 53
16.3 Два шага и монотонность . . . 54
16.4 Смесь нормальных распределений . . . 54
16.5 Вероятностный PCA . . . 55

17 Главные компоненты и низкий ранг **57**
17.1 Центрирование и постановка . . . 57
17.2 Основная теорема PCA . . . 57
17.3 Связь с SVD и теорема о низком ранге . . . 58
17.4 Шкалирование, отбеливание и регрессия . . . 58
17.5 Связь с PPCA и неполными матрицами . . . 59

A Карта курса и редакционные уточнения **60**
A.1 Соответствие лекциям . . . 60
A.2 Навигация по экзаменационным блокам . . . 60
A.3 Что уточнено по сравнению со слайдами . . . 61
A.4 Границы охвата . . . 62

Источники и лицензия **63**
Лицензия исходного репозитория . . . 65

ГЛАВА 1

Математический язык обучения

Материалы курса: лекция 1; семинар 2 [L01, S02]..

1.1 Объекты, признаки и выборка

Пусть $\mathcal{X}$ есть измеримое пространство объектов, $\mathcal{Y}$ есть пространство ответов. Наблюдение есть пара $Z = (X, Y)$ с распределением P на $\mathcal{X} \times \mathcal{Y}$. Обучающая выборка

$$D_n = ((x_1, y_1), \dots, (x_n, y_n))$$

обычно моделируется независимыми одинаково распределёнными копиями Z. Независимость является предположением о механизме получения данных: последовательные измерения одного пациента или значения временного ряда могут ему не удовлетворять.

Признак есть измеримая функция $\phi_j : \mathcal{X} \to \mathbb{R}$. После выбора d признаков объект представляется вектором $\phi(x) = (\phi_1(x), \dots, \phi_d(x))^\mathsf{T}$. Ниже для краткости пишем $x \in \mathbb{R}^d$. Матрица данных $X \in \mathbb{R}^{n \times d}$ имеет строки x_i^T. Вектор ответов обозначается $y \in \mathbb{R}^n$. Один и тот же символ X может обозначать случайный объект или матрицу; его смысл определяется контекстом и размерностью.

Определение 1.1. Моделью назовём семейство функций $\mathcal{F} = \{f_\theta : \theta \in \Theta\}$. Метод обучения есть отображение $A : D_n \mapsto \hat{f}$. Параметр θ оценивается по обучающим данным. Гиперпараметр задаёт семейство моделей или процедуру обучения: например, глубину дерева, число соседей или коэффициент регуляризации.

Различие не сводится к тому, «число» это или «вектор»: сохранённая выборка является частью обученной модели kNN, хотя k лишь один гиперпараметр.

При регрессии $\mathcal{Y} \subseteq \mathbb{R}$; при классификации $\mathcal{Y} = \{1, \dots, K\}$. В бинарной классификации применяются кодировки $\{0, 1\}$ и $\{-1, +1\}$; переход между ними задаётся $t = 2y - 1$. При ранжировании требуется упорядочивать объекты, поэтому существенны сравнения оценок, а не только их абсолютные значения. В кластеризации ответы не заданы, и сама цель зависит от выбранного понятия близости.

1.2 Линейная алгебра и нормы

Все векторы по умолчанию являются столбцами. Скалярное произведение равно $u^{\mathsf T}v$, евклидова норма $\|u\|_2 = (u^{\mathsf T}u)^{1/2}$. Для матрицы

$$\|A\|_F^2 = \sum_{ij} a_{ij}^2 = \operatorname{tr}(A^{\mathsf T}A), \qquad \|A\|_2 = \sup_{\|u\|_2=1} \|Au\|_2 .$$

Симметричная матрица A положительно полуопределена, $A \succeq 0$, если $u^{\mathsf T}Au \ge 0$ для всех u, и положительно определена, $A \succ 0$, если неравенство строго при $u \neq 0$. Для $A \succeq 0$ существует ортогональное разложение $A = V\Lambda V^{\mathsf T}$ с $\Lambda_{jj} \ge 0$.

Предложение 1.2. Для любой матрицы X матрица $X^{\mathsf T}X$ положительно полуопределена. Она положительно определена тогда и только тогда, когда столбцы X линейно независимы.

Доказательство. $u^{\mathsf T}X^{\mathsf T}Xu = \|Xu\|^2$. Это выражение равно нулю тогда и только тогда, когда $u \in \ker X$. Поэтому строгое неравенство для всех $u \neq 0$ эквивалентно $\ker X = \{0\}$. $\square$

Для $A \succ 0$ положим $\|u\|_A^2 = u^{\mathsf T}Au$. Позднее такая норма возникнет при учёте неодинаковой точности измерений.

1.3 Дифференцирование по вектору и матрице

Дифференциал скалярной функции $f : \mathbb{R}^d \to \mathbb{R}$ записывается как

$$df(w)[h] = \nabla f(w)^{\mathsf T} h.$$

Для $f : \mathbb{R}^{a\times b} \to \mathbb{R}$ градиент определяется равенством $df(W)[H] = \operatorname{tr}((\nabla_W f)^{\mathsf T}H)$. Это определение устраняет неоднозначность ориентации матричной производной.

Предложение 1.3. При согласованных размерностях

$$\nabla_w (a^{\mathsf T}w) = a, \qquad \nabla_w (w^{\mathsf T}Aw) = (A + A^{\mathsf T})w,$$
$$\nabla_w \tfrac12 \|Xw - y\|^2 = X^{\mathsf T}(Xw - y), \qquad \nabla_W \tfrac12 \|XW - Y\|_F^2 = X^{\mathsf T}(XW - Y).$$

Доказательство. Например, для $r = Xw - y$ имеем $d(\tfrac12 r^{\mathsf T}r) = r^{\mathsf T}dr = r^{\mathsf T}X\,dw$. В матричном случае $d\tfrac12 \operatorname{tr}(R^{\mathsf T}R) = \operatorname{tr}(R^{\mathsf T}X\,dW)$; сравнение с определением даёт формулу. Для квадратичной формы дифференциал равен $(dw)^{\mathsf T}Aw + w^{\mathsf T}A\,dw = w^{\mathsf T}(A + A^{\mathsf T})\,dw$. $\square$

Если $g : \mathbb{R}^d \to \mathbb{R}^m$, то $J_g \in \mathbb{R}^{m \times d}$ имеет элементы $\partial g_i / \partial w_j$. Цепное правило принимает вид $\nabla (f \circ g) = J_g^{\mathsf{T}} \nabla f$. Именно это равенство лежит в основе обратного распространения ошибки.

1.4 Выпуклость и условная оптимизация

Функция f на выпуклом множестве выпукла, если $f(tu + (1-t)v) \le t f(u) + (1-t) f(v)$ для $t \in [0,1]$. Для дифференцируемой выпуклой функции

$$f(v) \ge f(u) + \nabla f(u)^{\mathsf{T}} (v - u).$$

Если f дважды непрерывно дифференцируема на открытом выпуклом множестве, выпуклость эквивалентна $\nabla^2 f \succeq 0$. Сильная выпуклость с параметром $\mu > 0$ означает добавление $\frac{\mu}{2}\|v-u\|^2$ к правой части первого неравенства. Она обеспечивает не более одного минимума.

Для выпуклой, но негладкой функции вектор g называется субградиентом в u, если $f(v) \ge f(u) + g^{\mathsf{T}}(v-u)$ для всех v. В частности,

$$\partial |t| = \begin{cases} \{1\}, & t > 0, \\ [-1, 1], & t = 0, \\ \{-1\}, & t < 0. \end{cases}$$

Условие $0 \in \partial f(u)$ необходимо и достаточно для глобальной минимальности выпуклой функции.

Контроль понимания

Почему $X^{\mathsf{T}} X$ может быть вырожденной при большом n? Какова размерность $J_g^{\mathsf{T}} \nabla f$? Чем метод обучения отличается от полученной модели? Почему свободный член можно включить в матрицу данных столбцом единиц?

ГЛАВА 2

Риск и обобщающая способность

Материалы курса: лекции 1 и 5 [L01, L05]; конечноклассовая оценка и её доказательство добавлены..

2.1 Популяционный и эмпирический риск

Функция потерь $\ell : \mathcal{Y} \times \mathcal{A} \to [0, \infty)$ измеряет ошибку решения. Пространство решений $\mathcal{A}$ может отличаться от пространства меток: например, вероятностный классификатор возвращает число в $[0, 1]$.

Определение 2.1. Риск модели f и её эмпирический риск равны

$$R(f) = \mathbb{E}\ell(Y, f(X)), \qquad \widehat{R}_n(f) = \frac{1}{n}\sum_{i=1}^{n} \ell(y_i, f(x_i)).$$

Принцип минимизации эмпирического риска состоит в выборе $\hat{f} \in \arg\min_{f \in \mathcal{F}} \widehat{R}_n(f)$, если минимум достигается.

R зависит от неизвестного распределения. Малость $\widehat{R}_n$ характеризует согласие с уже наблюдавшейся выборкой и сама по себе не контролирует $R(\hat{f})$, поскольку $\hat{f}$ выбран по этой же выборке.

Теорема 2.2 (Оптимальный прогноз при квадратичной потере)**.** Если $\mathbb{E}Y^2 < \infty$, то среди всех измеримых функций с конечным квадратичным риском минимум достигается на $m(x) = \mathbb{E}[Y \mid X = x]$, определённой почти всюду. Более того,

$$R(f) = \mathbb{E}\,\mathrm{Var}(Y \mid X) + \mathbb{E}(f(X) - m(X))^2.$$

Доказательство. Запишем $Y - f(X) = (Y - m(X)) + (m(X) - f(X))$. Смешанный член имеет нулевое ожидание, поскольку $\mathbb{E}[Y - m(X) \mid X] = 0$. Два оставшихся слагаемых дают формулу. Второе неотрицательно и обращается в нуль при $f = m$ почти наверное. $\square$

Аналогично для абсолютной потери оптимальна условная медиана. Для ошибки классификации $\ell(y, a) = \mathbf{1}\{y \neq a\}$ оптимален байесовский классификатор

$$f^*(x) \in \arg\max_{k} \mathbb{P}(Y = k \mid X = x).$$

Действительно, условный риск выбора класса k равен $1 - \mathbb{P}(Y = k \mid X = x)$. При равенстве вероятностей выбор может быть неоднозначен.

2.2 Ошибки приближения, оценивания и оптимизации

Пусть $R^* = \inf_f R(f)$, а $f^*_{\mathcal{F}}$ минимизирует риск в классе $\mathcal{F}$. Тогда

$$R(\hat{f}) - R^* = \underbrace{R(f^*_{\mathcal{F}}) - R^*}_{\text{ошибка приближения}} + \underbrace{R(\hat{f}) - R(f^*_{\mathcal{F}})}_{\text{ошибка оценивания}}.$$

Алгоритм обычно возвращает лишь приближённый минимум эмпирического риска. Если $\widehat{R}_n(\tilde{f}) \le \inf_{f \in \mathcal{F}} \widehat{R}_n(f) + \varepsilon_{\text{opt}}$, то

$$R(\tilde{f}) - \inf_{f \in \mathcal{F}} R(f) \le 2 \sup_{f \in \mathcal{F}} |R(f) - \widehat{R}_n(f)| + \varepsilon_{\text{opt}}. \tag{2.1}$$

Это получается добавлением и вычитанием эмпирических рисков $\tilde{f}$ и произвольного почти оптимального f. Слишком точная оптимизация не устраняет ошибку выбора класса или недостаток данных.

2.3 Конечноклассовая гарантия

Теорема 2.3. Пусть D_n состоит из независимых одинаково распределённых наблюдений, $0 \le \ell \le 1$, а класс $\mathcal{F}$ конечен и выбран независимо от D_n. Для любого $\delta \in (0, 1)$ с вероятностью не менее $1 - \delta$

$$\sup_{f \in \mathcal{F}} |\widehat{R}_n(f) - R(f)| \le \sqrt{\frac{\log(2|\mathcal{F}|/\delta)}{2n}}.$$

Доказательство. Для фиксированного f неравенство Хёффдинга даёт $\mathbb{P}(|\widehat{R}_n(f) - R(f)| > \varepsilon) \le 2e^{-2n\varepsilon^2}$. Объединяя события по всем f, получаем верхнюю границу $2|\mathcal{F}|e^{-2n\varepsilon^2}$. Приравнивание её к δ завершает доказательство. $\square$

Подстановка в (2.1) показывает, как размер класса влияет на избыточный риск. Для бесконечных классов число функций заменяют подходящими характеристиками сложности. В бинарной классификации одна из них есть VC-размерность: максимальное число точек, на которых класс реализует все 2^m разметок. Для аффинных полупространств в $\mathbb{R}^d$ она равна $d + 1$. Число гиперпараметров не является заменой этой характеристики.

2.4 Смещение и разброс

Пусть $\hat{f}_D$ построена по случайной обучающей выборке D, а (x, Y) есть независимое новое наблюдение при фиксированном x. Обозначим $\overline{f}(x) = \mathbb{E}_D \hat{f}_D(x)$ и $\sigma^2(x) = \mathrm{Var}(Y \mid X = x)$. Тогда

$$\mathbb{E}_{D,Y}(Y - \hat{f}_D(x))^2 = \sigma^2(x) + (\overline{f}(x) - m(x))^2 + \mathbb{E}_D(\hat{f}_D(x) - \overline{f}(x))^2. \tag{2.2}$$

Доказательство повторяет ортогональное разложение предыдущей теоремы, после чего добавляется и вычитается $\overline{f}(x)$. Все смешанные члены имеют нулевое ожидание.

Смещение выражает систематическое отличие среднего прогноза от $m(x)$. Разброс выражает чувствительность к выборке. Регуляризация нередко увеличивает первое и уменьшает второе, но это не универсальное монотонное утверждение для любого алгоритма и распределения.

2.5 Валидация как часть метода

Обучающая часть служит для оценки параметров, валидационная для выбора гиперпараметров, тестовая для окончательной оценки. Любая операция, использующая данные для настройки, является частью обучения: нормировка, отбор признаков, заполнение пропусков, выбор порога и число итераций.

В K-блочной кросс-валидации выборку делят на блоки I_k. На шаге k всю процедуру обучают на дополнении I_k и оценивают на I_k:

$$\widehat{R}_{\mathrm{CV}} = \frac{1}{n} \sum_{k=1}^{K} \sum_{i \in I_k} \ell(y_i, A(D_n \setminus I_k)(x_i)).$$

Это оценка качества процедуры, обученной на меньшей выборке; независимость оценок по блокам не гарантируется. Если те же значения CV многократно используются для подбора, их минимум оптимистичен. Внешняя кросс-валидация оценивает всю процедуру выбора, а внутренняя настраивает её.

Контроль понимания

Где использована независимость тестовой точки от обучения? Почему оценка Хёффдинга для одной фиксированной модели не переносится без изменения на лучшую из миллиона? Как различить ошибку оптимизации и переобучение?

ГЛАВА 3

Градиентные методы

Материалы курса: лекция 2, семинар 2, домашнее задание 4 [L02, S02, H04]..

3.1 Градиентный шаг и гладкость

Рассмотрим $F(w) = \frac{1}{n}\sum_i f_i(w) + \lambda\Omega(w)$. Для дифференцируемой F полный градиентный шаг имеет вид $w_{t+1} = w_t - \eta_t \nabla F(w_t)$. Число $\eta_t > 0$ задаёт длину шага, но допустимый масштаб зависит от геометрии F.

Лемма 3.1 (Лемма о спуске)**.** Если $\|\nabla F(u) - \nabla F(v)\| \le L\,\|u - v\|$ для всех u, v, то

$$F(v) \le F(u) + \nabla F(u)^{\mathsf{T}}(v-u) + \frac{L}{2}\,\|v-u\|^2 .$$

Доказательство. Положим $h = v - u$. По формуле Ньютона--Лейбница $F(v) - F(u) = \int_0^1 \nabla F(u+th)^{\mathsf{T}} h\,dt$. После вычитания $\nabla F(u)^{\mathsf{T}}h$ подынтегральное выражение по неравенству Коши--Буняковского не превосходит $Lt\,\|h\|^2$. Интеграл равен $L\,\|h\|^2/2$. □

Следовательно,

$$F(w_{t+1}) \le F(w_t) - \eta_t(1 - L\eta_t/2)\,\|\nabla F(w_t)\|^2 .$$

При $0 < \eta_t < 2/L$ шаг уменьшает значение функции, если градиент ненулевой. Это ещё не означает сходимости к глобальному минимуму невыпуклой функции.

Теорема 3.2 (Квадратичная задача)**.** Пусть $F(w) = \frac{1}{2}w^{\mathsf{T}}Aw - b^{\mathsf{T}}w$, где $A \succ 0$ имеет собственные значения в $[\mu, L]$. При постоянном шаге $0 < \eta < 2/L$

$$\|w_t - w^*\| \le q^t\,\|w_0 - w^*\|, \qquad q = \max_j |1 - \eta\lambda_j(A)| < 1.$$

Доказательство. $Aw^* = b$, поэтому ошибка удовлетворяет $e_{t+1} = (I - \eta A)e_t$. В ортонормированном собственном базисе каждая координата умножается на $1 - \eta\lambda_j$. Итерация и оценка операторной нормы дают результат. □

При $\eta = 2/(L+\mu)$ получаем $q = (\kappa - 1)/(\kappa + 1)$, где $\kappa = L/\mu$. Плохая обусловленность замедляет сходимость. Масштабирование признаков меняет эту геометрию.

3.2 Стохастический градиент

Если индекс i_t выбирается равномерно и независимо от прошлого при фиксированном w_t, то

$$g_t = \nabla f_{i_t}(w_t) + \lambda \nabla \Omega(w_t), \qquad \mathbb{E}[g_t \mid w_t] = \nabla F(w_t).$$

Для мини-батча из b независимо выбранных индексов используется средний градиент. Его условная ковариация в b раз меньше ковариации одного слагаемого. При выборе без возвращения возникает дополнительная поправка конечной совокупности.

Предложение 3.3 (Базовая оценка SGD)**.** Пусть F выпукла, w^* является её минимумом, стохастические градиенты условно несмещённы и $\mathbb{E}\,\|g_t\|^2 \le G^2$. Для T шагов с постоянным η и $\overline{w}_T = T^{-1}\sum_{t=0}^{T-1} w_t$

$$\mathbb{E}F(\overline{w}_T) - F(w^*) \le \frac{\|w_0 - w^*\|^2}{2\eta T} + \frac{\eta G^2}{2}.$$

Доказательство. Раскрыв квадрат в $w_{t+1} = w_t - \eta g_t$ и взяв ожидание, получим

$$2\eta\mathbb{E}(F(w_t) - F(w^*)) \le \mathbb{E}\,\|w_t - w^*\|^2 - \mathbb{E}\,\|w_{t+1} - w^*\|^2 + \eta^2 G^2.$$

Использованы выпуклость и условная несмещённость. Просуммируем по t, отбросим последний неотрицательный квадрат и применим выпуклость к среднему $\overline{w}_T$. □

Выбор $\eta \asymp T^{-1/2}$ даёт оценку порядка $T^{-1/2}$. Условия $\sum_t \eta_t = \infty$, $\sum_t \eta_t^2 < \infty$ часто входят в теоремы о сходимости стохастической аппроксимации, но без предположений о градиентах, шуме и целевой функции сами по себе ничего не гарантируют.

3.3 Модификации и оценка прогресса

Momentum хранит накопленное направление:

$$v_{t+1} = \beta v_t + g_t, \qquad w_{t+1} = w_t - \eta_t v_{t+1}, \quad 0 \le \beta < 1.$$

В AdaGrad накопление покоординатное:

$$s_{t+1} = s_t + g_t \odot g_t, \qquad w_{t+1} = w_t - \eta_t \frac{g_t}{\sqrt{s_{t+1}} + \varepsilon}.$$

Деление и корень здесь покоординатны; $\varepsilon > 0$. Эти соглашения могут отличаться от помещения ε под корень, поэтому реализации нужно сравнивать вместе с точной формулой.

SAG хранит последний вычисленный градиент каждого f_i и использует их среднее. Это среднее включает устаревшие градиенты и в общем случае не является условно несмещённым градиентом в текущей точке. Теорему для SGD нельзя механически переносить на SAG.

Экспоненциальное среднее потерь $q_t = (1-\alpha)q_{t-1} + \alpha f_{i_t}(w_t)$ удобно для наблюдения за ходом обучения. Оно смешивает ошибки разных моделей w_t и не заменяет вычисления полного функционала. Малость $\|w_{t+1} - w_t\|$ при очень малом шаге также не гарантирует близости к минимуму.

3.4 Регуляризация и устойчивость вычислений

При $\Omega(w) = \frac{1}{2}\|w\|^2$ шаг записывается

$$w_{t+1} = (1 - \eta_t\lambda)w_t - \eta_t \nabla \widehat{R}_n(w_t).$$

Если свободный член не штрафуется, множитель применяется только к коэффициентам признаков. В невыпуклой задаче ранняя остановка по валидации является дополнительным способом ограничения сложности, но не теоремой о глобальной оптимальности.

Для линейной регрессии с $F = \|Xw - y\|^2/(2n)$ имеем $L = \|X\|_2^2/n$. Для проверки производных полезна центральная разность

$$\frac{F(w + he_j) - F(w - he_j)}{2h} = \partial_j F(w) + O(h^2)$$

при достаточной гладкости. Слишком малое h усиливает ошибку округления; конечная разность служит проверкой, а не основным алгоритмом дифференцирования большой модели.

Контроль понимания

Почему сумма вместо среднего меняет допустимый шаг? В какой точке доказательства SGD нужна несмещённость? Почему один шаг SGD может увеличить полный функционал? Что должно быть одинаковым при сравнении времени двух оптимизаторов?

ГЛАВА 4

Линейная регрессия и регуляризация

Материалы курса: лекции 2 и 14; семинар 3 [L02, L14, S03]..

4.1 Нормальные уравнения и проекция

Линейная модель имеет вид $f_w(x) = x^\mathsf{T} w$. Свободный член включается в x координатой 1. Слово «линейная» относится к параметрам: модель $w_0 + w_1 t + w_2 t^2$ остаётся линейной, хотя зависит от исходного аргумента нелинейно.

Метод наименьших квадратов решает

$$\min_{w \in \mathbb{R}^d} \frac{1}{2} \|Xw - y\|^2 .$$

Теорема 4.1. Множество МНК-решений непусто и совпадает с множеством решений нормальных уравнений

$$X^\mathsf{T} X w = X^\mathsf{T} y. \tag{4.1}$$

Вектор $\hat{y} = X\widehat{w}$ единственен и равен ортогональной проекции y на $\operatorname{col} X$. Если $\operatorname{rank} X = d$, то $\widehat{w} = (X^\mathsf{T} X)^{-1} X^\mathsf{T} y$ единственен.

Доказательство. Подпространство $\operatorname{col} X$ конечномерно и замкнуто, поэтому проекция существует и единственна. Условие ортогональности остатка $r = y - X\widehat{w}$ всем столбцам X равносильно (4.1). Для любого h имеем

$$\|y - X(\widehat{w} + h)\|^2 = \|r\|^2 + \|Xh\|^2 ,$$

поскольку $X^\mathsf{T} r = 0$. Это доказывает достаточность; необходимость следует из нулевого градиента. При полном столбцовом ранге $X^\mathsf{T} X \succ 0$, а значит, обратима. $\square$

Если ранг неполон, $\widehat{w} + h$ также является решением для каждого $h \in \ker X$. Одинаковые предсказания на обучении не означают одинаковых предсказаний вне него.

4.2 SVD и минимальная норма

Пусть $r = \operatorname{rank} X$. Компактное сингулярное разложение имеет вид

$$X = U_r \Sigma_r V_r^{\mathsf{T}}, \quad U_r^{\mathsf{T}} U_r = V_r^{\mathsf{T}} V_r = I_r, \quad \Sigma_r = \operatorname{diag}(\sigma_1, \dots, \sigma_r),$$

где $\sigma_1 \geq \cdots \geq \sigma_r > 0$, $U_r \in \mathbb{R}^{n \times r}$ и $V_r \in \mathbb{R}^{d \times r}$. Нулевые сингулярные направления в компактную запись не входят.

Предложение 4.2. МНК-решение минимальной евклидовой нормы равно

$$\widehat{w} = X^{+} y = V_r \Sigma_r^{-1} U_r^{\mathsf{T}} y = \sum_{j=1}^{r} \frac{u_j^{\mathsf{T}} y}{\sigma_j} v_j.$$

При этом $\widehat{y} = U_r U_r^{\mathsf{T}} y$ и $\|\widehat{w}\|^2 = \sum_{j=1}^{r} (u_j^{\mathsf{T}} y)^2 / \sigma_j^2$.

Доказательство. Разложим $w = V_r a + h$, где $h \in \ker X$. Функционал зависит только от a и минимизируется при $a = \Sigma_r^{-1} U_r^{\mathsf{T}} y$. Норма равна $\|a\|^2 + \|h\|^2$, поэтому минимальна при $h = 0$. □

Малое σ_j усиливает компоненту шума вдоль u_j. При полном столбцовом ранге $\kappa_2(X^{\mathsf{T}} X) = \kappa_2(X)^2$. Поэтому явное формирование нормальных уравнений может ухудшить численную точность по сравнению с QR- или SVD-решением.

4.3 Гребневая регрессия

Зафиксируем соглашение

$$F_\lambda(w) = \frac{1}{2n} \|Xw - y\|^2 + \frac{\lambda}{2} \|w\|^2, \quad \lambda > 0. \tag{4.2}$$

Гессиан равен $X^{\mathsf{T}} X / n + \lambda I \succ 0$. Следовательно, минимум единственен:

$$\widehat{w}_\lambda = (X^{\mathsf{T}} X + n\lambda I)^{-1} X^{\mathsf{T}} y = \sum_{j=1}^{r} \frac{\sigma_j}{\sigma_j^2 + n\lambda} (u_j^{\mathsf{T}} y) v_j.$$

Матрица прогнозов и её след равны

$$H_\lambda = X(X^{\mathsf{T}} X + n\lambda I)^{-1} X^{\mathsf{T}}, \qquad \operatorname{df}(\lambda) = \operatorname{tr} H_\lambda = \sum_j \frac{\sigma_j^2}{\sigma_j^2 + n\lambda}.$$

Последняя величина есть эффективное число степеней свободы этого линейного сглаживателя. При $\lambda \downarrow 0$ она стремится к r, при $\lambda \to \infty$ к нулю. Если свободный член не штрафуется, формулы применяются к центрированным признакам и ответам, а свободный член восстанавливается отдельно.

При модели $y = Xw^* + \varepsilon$, $\mathbb{E}\varepsilon = 0$, $\operatorname{Cov}\varepsilon = \sigma^2 I$, смещение ridge равно

$$\mathbb{E}\widehat{w}_\lambda - w^* = -n\lambda(X^\mathsf{T}X + n\lambda I)^{-1}w^*,$$

а ковариация

$$\sigma^2(X^\mathsf{T}X + n\lambda I)^{-1}X^\mathsf{T}X(X^\mathsf{T}X + n\lambda I)^{-1}.$$

Уменьшение дисперсии получается ценой смещения. Оптимальную λ нельзя определить из этих формул, не зная w^*; на практике её подбирают по валидации.

4.4 LASSO и разреженность

LASSO минимизирует $F(w) = \|Xw - y\|^2/(2n) + \lambda\|w\|_1$. Условие оптимальности:

$$0 \in X^\mathsf{T}(Xw - y)/n + \lambda\partial\|w\|_1.$$

Таким образом, нулевой коэффициент $w_j = 0$ допустим при $|x_j^\mathsf{T}(y - Xw)/n| \le \lambda$. Именно интервал субградиентов в нуле позволяет получать точные нули.

Предложение 4.3 (Ортонормированный случай)**.** Если $X^\mathsf{T}X/n = I$, а $z = X^\mathsf{T}y/n$, то LASSO имеет единственное решение

$$\widehat{w}_j = S_\lambda(z_j), \qquad S_\lambda(z) = \operatorname{sign}(z)\max\{|z| - \lambda, 0\}.$$

Доказательство. С точностью до константы задача распадается на минимизацию $\frac{1}{2}(w_j - z_j)^2 + \lambda|w_j|$. При $w_j > 0$ стационарность даёт $w_j = z_j - \lambda$, при $w_j < 0$ даёт $w_j = z_j + \lambda$. Нулевой ответ удовлетворяет субградиентному условию ровно при $|z_j| \le \lambda$. □

Для общей матрицы этот покоординатный ответ уже неверен без итерационной схемы. Elastic Net объединяет L_1- и L_2-штрафы. Масштаб признаков влияет на все эти штрафы, поэтому параметры нормировки оценивают на обучающей части.

4.5 Несколько ответов

Если $Y \in \mathbb{R}^{n\times m}$, то многомерная линейная регрессия решает задачу

$$\min_W \|XW - Y\|_F^2.$$

При отсутствии ограничений столбцы W оцениваются независимо, и минимальное по норме решение равно X^+Y. Общая информация между ответами появляется лишь после введения связующих ограничений, например ограничения ранга или общего априорного распределения.

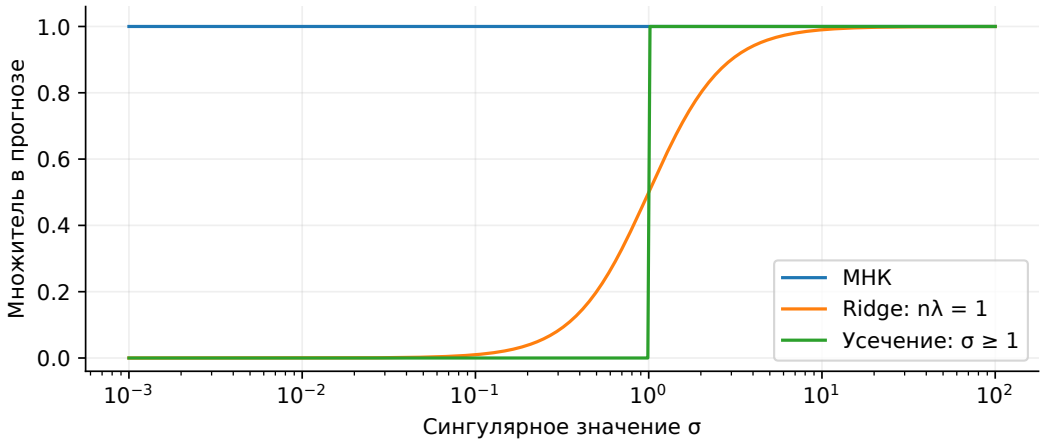


Рис. 4.1: Спектральные множители в обучающем прогнозе для МНК, ridge и усечения спектра.

Контроль понимания

Почему прогноз единственен при неединственных весах? Где в ridge возникает множитель n? Почему полиномиальная регрессия является линейной моделью? Что именно сокращается при L_2-штрафе: число признаков или эффективные степени свободы?

ГЛАВА 5

Взвешенный МНК и точность оценок

Материалы курса: лекция Д. А. Павлова о взвешенном МНК [L06]..

5.1 Статистическая линейная модель

Условно на фиксированной матрице $X \in \mathbb{R}^{n\times d}$ полного столбцового ранга предположим

$$y = X\beta + \varepsilon, \quad \mathbb{E}[\varepsilon \mid X] = 0, \quad \operatorname{Cov}(\varepsilon \mid X) = \sigma^2 I_n.$$

Здесь β фиксирован, а случайность оценки вызвана ε. Тогда

$$\mathbb{E}[\hat\beta \mid X] = \beta, \qquad \operatorname{Cov}(\hat\beta \mid X) = \sigma^2 (X^{\mathsf T}X)^{-1}.$$

Нормальность ошибок для этих двух равенств не требуется.

Теорема 5.1 (Гаусса--Маркова)**.** При указанных условиях МНК-оценка имеет минимальную ковариационную матрицу в классе линейных по y несмещённых оценок. То есть для любой $\tilde\beta = By$, несмещённой при всех β, разность $\operatorname{Cov}(\tilde\beta \mid X) - \operatorname{Cov}(\hat\beta \mid X)$ положительно полуопределена.

Доказательство. Несмещённость эквивалентна $BX = I_d$. Положим $B = (X^{\mathsf T}X)^{-1}X^{\mathsf T} + D$. Тогда $DX = 0$. При раскрытии $BB^{\mathsf T}$ смешанные члены равны нулю, поскольку $X^{\mathsf T}D^{\mathsf T} = 0$. Значит,

$$\operatorname{Cov}(By \mid X) = \sigma^2 (X^{\mathsf T}X)^{-1} + \sigma^2 DD^{\mathsf T}.$$

Последнее слагаемое положительно полуопределено. $\square$

«Лучшая» здесь не означает лучшую среди всех, в том числе смещённых и нелинейных, оценок. Состоятельность также требует отдельного асимптотического условия. Например, при $X_n^{\mathsf T}X_n/n \to Q \succ 0$ и фиксированном d ковариация стремится к нулю, а несмещённость даёт сходимость по вероятности по неравенству Чебышёва.

5.2 Гетероскедастичность и отбеливание

Пусть теперь $\operatorname{Cov}(\varepsilon \mid X) = \Sigma \succ 0$ известна. Обобщённый МНК решает

$$\min_{\beta} (y - X\beta)^{\mathsf{T}} \Sigma^{-1} (y - X\beta).$$

Если $\Sigma = LL^{\mathsf{T}}$, положим $\tilde{y} = L^{-1}y$, $\widetilde{X} = L^{-1}X$. Ковариация преобразованного шума равна I_n. Применяя обычный МНК, получаем

$$\hat{\beta} = (X^{\mathsf{T}}\Sigma^{-1}X)^{-1} X^{\mathsf{T}}\Sigma^{-1} y, \quad \operatorname{Cov}(\hat{\beta} \mid X) = (X^{\mathsf{T}}\Sigma^{-1}X)^{-1}. \tag{5.1}$$

Теорема Гаусса--Маркова переносится на эту задачу после отбеливания.

При независимых ошибках с дисперсиями σ_i^2 имеем $W = \operatorname{diag}(\sigma_i^{-2})$ и $\Sigma^{-1} = W$. Это взвешенный МНК. Вес равен обратной *дисперсии*; множитель строки при отбеливании равен обратному *стандартному отклонению*. Смешение этих двух величин приводит к неверной задаче.

Пример 5.2. При оценке одной константы $y_i = \beta + \varepsilon_i$

$$\hat{\beta} = \frac{\sum_i y_i/\sigma_i^2}{\sum_i 1/\sigma_i^2}, \qquad \operatorname{Var}\hat{\beta} = \frac{1}{\sum_i 1/\sigma_i^2}.$$

Два наблюдения со стандартными отклонениями 1 и 3 входят с отношением весов $9 : 1$, а не $3 : 1$.

5.3 Остатки и оценка масштаба

Пусть $H = X(X^{\mathsf{T}}X)^{-1}X^{\mathsf{T}}$. Тогда $H^{\mathsf{T}} = H$, $H^2 = H$ и $\operatorname{tr} H = d$. Остаток $r = (I - H)\varepsilon$ удовлетворяет

$$\mathbb{E}\,\|r\|^2 = \operatorname{tr}((I - H)\sigma^2 I) = \sigma^2 (n - d).$$

Следовательно, при $n > d$ оценка $\hat{\sigma}^2 = \|r\|^2 / (n - d)$ несмещённа. Если ε нормальна, то дополнительно $\|r\|^2 / \sigma^2 \sim \chi^2_{n-d}$, поскольку в ортонормированном базисе остаточного подпространства остаются $n - d$ независимых стандартных нормальных координат.

При $\Sigma = \tau^2 \Sigma_0$ известной с точностью до масштаба

$$\hat{\tau}^2 = \frac{r^{\mathsf{T}}\Sigma_0^{-1} r}{n - d}.$$

Если абсолютные дисперсии заданы верно, приведённый хи-квадрат имеет математическое ожидание 1. Значение существенно выше 1 может указывать на недооценку шума или систематическую ошибку модели. Значение ниже 1 может возникать из-за переоценки шума. Само по себе одно отклонение от 1 ничего не доказывает: необходимо учитывать случайные колебания и число степеней свободы.

5.4 Разложение Холецкого

Теорема 5.3. Для всякой симметричной положительно определённой матрицы A существует единственная нижнетреугольная матрица L с положительной диагональю, такая что $A = LL^{\mathsf{T}}$.

Доказательство. Используем индукцию по размеру. Представим $A = \begin{pmatrix} a & b^{\mathsf{T}} \\ b & C \end{pmatrix}$, где $a > 0$. Положительность A на векторах $(-b^{\mathsf{T}}z/a, z)$ означает положительность дополнения Шура $S = C - bb^{\mathsf{T}}/a$. По индукции $S = MM^{\mathsf{T}}$. Тогда

$$L = \begin{pmatrix} \sqrt{a} & 0 \\ b/\sqrt{a} & M \end{pmatrix}$$

даёт требуемое разложение. Его первый столбец вынужден равенствами $LL^{\mathsf{T}} = A$, а оставшийся блок единственен по индукции. $\square$

Для решения $A\beta = b$ последовательно решают $Lz = b$ и $L^{\mathsf{T}}\beta = z$. Явно вычислять A^{-1} не требуется. Холецкий эффективен для хорошо обусловленной положительно определённой системы; при почти линейной зависимости столбцов предпочтительно работать с исходной отбеленной матрицей через QR или SVD.

Контроль понимания

Какие предположения теоремы Гаусса--Маркова не включают нормальность? Почему знаменатель остаточной дисперсии равен $n - d$? Когда формула ковариации требует дополнительного множителя τ^2?

ГЛАВА 6

Нелинейный МНК и динамические модели

Материалы курса: лекция Д. А. Павлова о нелинейном МНК и астрономическое задание [L07, H06a, H06b]..

6.1 Линеаризация невязки

Пусть наблюдения описываются моделью $y_i = f(x_i;\theta) + \varepsilon_i$, $\theta \in \mathbb{R}^p$. Зафиксируем знак невязки

$$r_i(\theta) = f(x_i;\theta) - y_i, \quad F(\theta) = \tfrac{1}{2} r(\theta)^{\mathsf{T}} W r(\theta), \quad W \succ 0.$$

Матрица $J \in \mathbb{R}^{n\times p}$ содержит $J_{ij} = \partial r_i / \partial \theta_j$. Для постоянной W

$$\nabla F = J^{\mathsf{T}} W r, \qquad \nabla^2 F = J^{\mathsf{T}} W J + \sum_{i=1}^{n} (W r)_i \nabla^2 r_i.$$

Второе слагаемое отсутствует у линейной модели и может быть малым при малых невязках. Его отбрасывание приводит к методу Гаусса--Ньютона.

Определение 6.1. Шаг Гаусса--Ньютона есть решение линеаризованной задачи

$$\Delta \in \arg\min_{h} \tfrac{1}{2} \left\| W^{1/2}(r + J h) \right\|^2, \qquad \theta_{\text{new}} = \theta + \Delta.$$

Если J имеет полный столбцовый ранг, то $(J^{\mathsf{T}} W J)\Delta = -J^{\mathsf{T}} W r$.

При обратном соглашении $r = y - f$ изменяется и знак якобиана. Смешение разных соглашений в одной формуле обращает направление шага.

Предложение 6.2. Если $J^{\mathsf{T}} W J \succ 0$ и $\nabla F \neq 0$, то шаг Гаусса--Ньютона является направлением строгого спуска: $\nabla F^{\mathsf{T}} \Delta < 0$.

Доказательство. Из нормальной системы следует $\nabla F^{\mathsf{T}} \Delta = -\Delta^{\mathsf{T}} J^{\mathsf{T}} W J \Delta < 0$, поскольку $\Delta \neq 0$. $\square$

Это гарантирует уменьшение $F(\theta + \alpha\Delta)$ для достаточно малого $\alpha > 0$, но не для полного шага $\alpha = 1$. На практике применяют поиск шага или доверительную область.

6.2 Демпфирование и идентифицируемость

Метод Левенберга--Марквардта в одной распространённой форме решает

$$(J^{\mathsf{T}}WJ + \mu I)\Delta = -J^{\mathsf{T}}Wr, \qquad \mu > 0.$$

При большом μ направление близко к отрицательному градиенту, при малом к шагу Гаусса--Ньютона. Параметр μ изменяют по согласованности предсказанного и фактического уменьшения ошибки. При различном масштабе параметров вместо I применяют соответствующую диагональную матрицу масштабов.

Если столбцы J линейно зависимы, различные малые изменения параметров дают одинаковые изменения прогнозов в первом порядке. Это локальная неидентифицируемость. Численная стабилизация делает шаг определённым, но не создаёт отсутствующую информацию в данных.

При малом шуме и локально корректной модели линейное приближение ковариации оценки имеет вид $\operatorname{Cov}(\widehat{\theta}) \approx (J^{\mathsf{T}}\Sigma^{-1}J)^{-1}$. Это приближение около найденного решения, а не точная формула несмещённой нелинейной оценки. Несмещённость МНК из линейного случая в общем случае не сохраняется.

6.3 Пример: экспоненциальный отклик

Для $f(t; a, b) = ae^{bt}$

$$r_i = ae^{bt_i} - y_i, \quad J_{i1} = e^{bt_i}, \quad J_{i2} = at_i e^{bt_i}.$$

Если все $t_i = 0$, второй столбец равен нулю и параметр b не определяется. Если диапазон t_i слишком узок, столбцы могут быть почти зависимы. Логарифмирование наблюдений y_i меняет вероятностную модель ошибок: аддитивный гауссовский шум на y не становится аддитивным гауссовским шумом на $\log y$. Поэтому линейная регрессия логарифма и исходный нелинейный МНК решают разные задачи.

6.4 Параметры дифференциального уравнения

Пусть состояние $s(t) \in \mathbb{R}^q$ удовлетворяет

$$\dot{s} = F(s, t, p), \qquad s(t_0) = s_0,$$

а наблюдения имеют вид $y_i = g_i(s(t_i), q_0) + \varepsilon_i$. Вектор оцениваемых параметров включает начальные условия, динамические параметры p и параметры наблюдения q_0.

Обозначим $P = (s_0, p)$ и $S(t) = \partial s(t)/\partial P$. Дифференцируя уравнение по параметрам при достаточной гладкости, получаем вариационную систему

$$\dot{S} = F_s S + F_P, \qquad S(t_0) = (I_q \; 0). \tag{6.1}$$

Здесь F_P содержит явные производные по p и нулевые столбцы для начальных условий. Производная наблюдения равна $\partial g_i/\partial P = (g_i)_s S(t_i)$; прямые зависимости от параметров добавляются отдельно. Эту систему интегрируют совместно с исходной.

6.5 Астрономические приложения и границы модели

В задаче определения орбиты оцениваются шесть начальных координат состояния. Модель наблюдения включает не только динамику: положение наблюдателя, время распространения света, преобразование координат и согласование шкал времени также влияют на невязку. Их пропуск может дать систематические остатки, которые ошибочно интерпретируются как новый физический эффект.

В задаче лазерной локации Луны по серии остаточных времён выделяется полезный сигнал, аппроксимируемый полиномом, и формируется нормальная точка. Итерационное удаление по правилу $|r_i| > 3s$ является эвристикой. При сильном загрязнении первоначальное s может быть завышено; устойчивые начальные оценки и анализ чувствительности к порогу необходимы. RMS отдельных измерений и стандартная ошибка среднего предсказания в выбранный момент имеют разный смысл.

Контроль понимания

Почему направление спуска не гарантирует успех полного шага? Как обнаружить неидентифицируемость по SVD якобиана? Какие производные входят в (6.1)? Почему систематический остаток ещё не доказывает неполноту физической теории?

ГЛАВА 7

Логистическая и многоклассовая регрессия

Материалы курса: лекции 2 и 3, теоретическое задание 2 [L02, L03, H02]..

7.1 Отступ и суррогатная потеря

Для бинарных меток $t \in \{-1, +1\}$ линейная оценка $s_w(x) = w^{\mathsf{T}}x + b$ задаёт классификатор по знаку. Отступ объекта есть $M = ts_w(x)$. Положительный отступ означает правильную классификацию; при $M = 0$ результат зависит от соглашения о ничьей. Поэтому индикатор $\mathbf{1}\{M \le 0\}$ удобно считать верхней оценкой ошибки при произвольном разрешении ничьей.

Минимизировать число ошибок трудно из-за разрывности. Вместо него вводят функции отступа:

$$\ell_{\log}(M) = \log(1 + e^{-M}), \quad \ell_{\text{hinge}}(M) = (1 - M)_+, \quad \ell_{\exp}(M) = e^{-M}.$$

Суррогат определяет не только гладкость оптимизации, но и то, как сильно наказываются отрицательные и малые положительные отступы. Натуральная логистическая потеря сама по себе не всюду мажорирует индикатор; деление на $\log 2$ даёт такую мажоранту для $M \le 0$.

7.2 Модель Бернулли и правдоподобие

Пусть $y \in \{0, 1\}$ и

$$p_w(x) = \sigma(s_w(x)), \qquad \sigma(s) = \frac{1}{1 + e^{-s}}.$$

Условная модель $Y \mid X = x \sim \text{Bernoulli}(p_w(x))$ даёт при условной независимости ответов

$$p(y_1, \dots, y_n \mid X, w) = \prod_i p_i^{y_i}(1 - p_i)^{1 - y_i}.$$

Отрицательный логарифм правдоподобия равен

$$\sum_i \left[-y_i \log p_i - (1 - y_i)\log(1 - p_i)\right] = \sum_i \left[\log(1 + e^{s_i}) - y_i s_i\right].$$

При $t_i = 2y_i - 1$ каждое слагаемое равно $\log(1 + e^{-t_i s_i})$. Логистическая потеря таким образом выводится из модели распределения, а не выбирается только ради удобного графика.

7.3 Градиент, выпуклость и достижимость минимума

Включим b в w и X столбцом единиц. Для среднего log-loss

$$\nabla F(w) = \frac{1}{n} X^{\mathsf{T}}(p - y), \qquad \nabla^2 F(w) = \frac{1}{n} X^{\mathsf{T}} D X, \quad D = \operatorname{diag}(p_i(1 - p_i)).$$

Так как $0 < p_i < 1$ при конечном w, $D \succ 0$. Следовательно, F выпукла, а при полном столбцовом ранге X строго выпукла. Но строгая выпуклость обеспечивает единственность минимума *при его существовании*, а не существование.

Предложение 7.1. Если выборка строго линейно разделима, то нерегуляризованная логистическая потеря не имеет конечного минимизатора.

Доказательство. Существует v с $t_i x_i^{\mathsf{T}} v > 0$ для всех i. При $c \to \infty$ каждое слагаемое $\log(1 + e^{-c t_i x_i^{\mathsf{T}} v})$ стремится к нулю, поэтому инфимум равен нулю. При любом конечном w каждое слагаемое строго положительно; инфимум не достигается. □

Добавление $\lambda \|w\|^2 / 2$ при $\lambda > 0$ ко всем координатам создаёт непрерывную коэрцитивную строго выпуклую функцию и тем самым единственный минимум. Если свободный член не штрафуется, это доказательство напрямую не действует; например, при всех метках 1 он может уходить в $+\infty$.

Шаг для квадратичной потери с сигмоидным выходом иной. Для $\ell_i(w) = \frac{1}{2}(\sigma(x_i^{\mathsf{T}} w) - y_i)^2$

$$\nabla \ell_i = (p_i - y_i) p_i (1 - p_i) x_i.$$

У log-loss дополнительный множитель $p_i(1 - p_i)$ сокращается. Эти две задачи нельзя смешивать, хотя их предсказательная функция одинакова.

7.4 Softmax и неидентифицируемость

Для K классов и оценок $s_k = w_k^{\mathsf{T}} x$ определим

$$p_k(x) = \frac{e^{s_k}}{\sum_{j=1}^{K} e^{s_j}}, \qquad F(W) = -\frac{1}{n} \sum_i \log p_{y_i}(x_i).$$

Если $P \in \mathbb{R}^{n\times K}$ содержит вероятности, а Y является матрицей индикаторов классов, то $\nabla_W F = X^{\mathsf{T}}(P-Y)/n$. Гессиан по оценкам одного объекта равен $\operatorname{diag}(p) - pp^{\mathsf{T}} \succeq 0$, поскольку его квадратичная форма есть дисперсия величины, принимающей значения координат тестового вектора с вероятностями p.

Добавление одного и того же вектора a ко всем w_k не изменяет вероятности. Поэтому без фиксации калибровки или регуляризации веса неединственны. При $K = 2$

$$p_1(x) = \sigma((w_1 - w_2)^{\mathsf{T}} x),$$

то есть softmax совпадает с бинарной логистической моделью по разности весов.

Для устойчивого вычисления используют $m = \max_j s_j$:

$$\log \sum_j e^{s_j} = m + \log \sum_j e^{s_j - m}.$$

Это тождество предотвращает переполнение экспоненты и не изменяет математический результат.

7.5 Вероятностный смысл регуляризации

При априорной плотности $\pi(w)$

$$p(w \mid D) \propto \pi(w) \prod_i p(y_i \mid x_i, w).$$

$$\widehat{w}_{\text{MAP}} \in \arg\min_w \left\{ -\sum_i \log p(y_i \mid x_i, w) - \log \pi(w) \right\}.$$

Гауссовский prior $\mathcal{N}(0, \tau^2 I)$ даёт штраф $\|w\|^2/(2\tau^2)$, независимые лапласовские координаты дают $\|w\|_1/a$. При переходе от суммы потерь к среднему коэффициент штрафа делится на n. Априорная плотность входит *один раз* для всего вектора параметров, а не по одному разу на наблюдение.

Контроль понимания

Почему строгая выпуклость не исключает ухода весов в бесконечность? Как различаются кодировки меток в формуле потерь? Почему softmax имеет избыточную параметризацию? Как меняется штраф при использовании среднего log-loss?

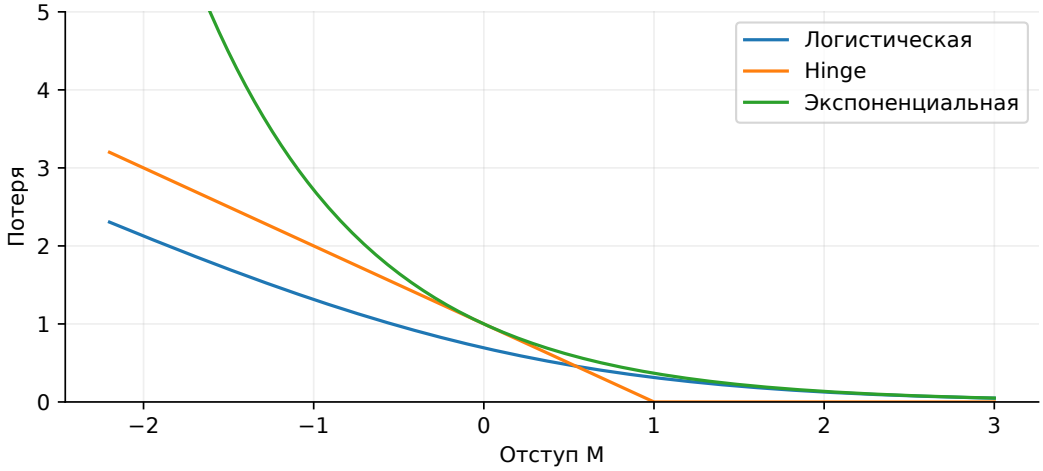


Рис. 7.1: Три суррогатные функции потери от отступа; натуральный логарифм.

ГЛАВА 8

Логические правила и решающие деревья

Материалы курса: лекции 3 и 4, задания 2 и 3 [L03, L04, H02, H03]..

8.1 Предикаты и закономерности

Предикат $b : \mathcal{X} \to \{0, 1\}$ выделяет подмножество объектов. Примеры: порог $\mathbf{1}\{x_j \le t\}$, интервал $\mathbf{1}\{a \le x_j < b\}$, проверка принадлежности категории множеству. Конъюнкция предикатов задаёт пересечение областей, дизъюнкция их объединение.

Логическое правило для класса k имеет форму «если $b(x) = 1$, предсказать k». На выборке оно характеризуется числом покрытых положительных и отрицательных примеров:

$$p(b) = \sum_i \mathbf{1}\{b(x_i) = 1, y_i = k\}, \quad n(b) = \sum_i \mathbf{1}\{b(x_i) = 1, y_i \ne k\}.$$

Нулевое число ошибок при покрытии одного объекта не делает правило полезным. Отбор должен учитывать и чистоту, и объём покрытия; окончательное качество проверяется на независимых данных.

Бинаризация вещественного признака заменяет его набором индикаторов порогов или интервалов. Линейная модель на таких признаках задаёт ступенчатую оценку. Пороги, найденные с использованием меток, следует подбирать внутри обучающей части каждого разбиения.

8.2 Дерево как разбиение пространства

Внутренний узел бинарного дерева содержит предикат, его ветви соответствуют двум исходам, лист содержит прогноз. Каждый лист задаёт конъюнкцию условий на пути от корня. Совокупность листьев образует разбиение пространства при детерминированном разрешении равенств и пропусков.

Для выборки U в узле определим наилучшую константную ошибку

$$I(U) = \min_c \frac{1}{|U|} \sum_{i \in U} \ell(y_i, c).$$

Разбиение $U = U_L \sqcup U_R$ оценивается выигрышем

$$\Delta I = I(U) - \frac{|U_L|}{|U|} I(U_L) - \frac{|U_R|}{|U|} I(U_R). \tag{8.1}$$

Нельзя опускать веса дочерних узлов: иначе маленький чистый лист получает несоразмерное влияние.

Предложение 8.1 (Константа в листе)**.** Для квадратичной потери оптимален средний ответ; для абсолютной потери любая медиана; для классификационной log-loss оптимален вектор эмпирических частот классов.

Доказательство. Производная $\sum_i (y_i - c)^2$ равна $2|U|(c - \overline{y})$, а вторая производная положительна. Для суммы модулей субградиент содержит нуль ровно тогда, когда с каждой стороны от c находится не более половины наблюдений. Для log-loss минимизируется $-\sum_k p_k \log q_k$ на симплексе. Разность со значением при $q = p$ равна $\mathrm{KL}(p\|q) \geq 0$. При $p_k = 0$ используется соглашение $0 \log 0 = 0$. □

Таким образом, для регрессии $I(U)$ равна дисперсии с делителем $|U|$, а для log-loss энтропии $H(p) = -\sum_k p_k \log p_k$.

8.3 Энтропия и индекс Джини

Индекс Джини определяется как $G(p) = 1 - \sum_k p_k^2 = \sum_k p_k(1 - p_k)$. Он равен вероятности несовпадения двух независимых меток с распределением p. Также это сумма дисперсий индикаторов принадлежности классам.

Предложение 8.2. Для энтропийного критерия выигрыш (8.1) равен эмпирической взаимной информации между меткой класса и исходом выбранного разбиения. В частности, он неотрицателен.

Доказательство. Случайно равновероятно выберем объект из узла и обозначим через B его ветвь. Тогда $\mathbb{P}(B = L) = |U_L|/|U|$ и $H(Y \mid B) = \sum_b \mathbb{P}(B = b) H(Y \mid B = b)$. Разность $H(Y) - H(Y \mid B) = I(Y; B)$ есть KL-дивергенция совместного распределения и произведения маргинальных, поэтому неотрицательна. □

Неотрицательность обучающего выигрыша не гарантирует улучшения тестового качества: поиск среди большого числа предикатов способен находить случайные зависимости.

8.4 CART и стоимость поиска

CART строит дерево жадно: в каждом узле перебирает допустимые признаки и пороги, выбирает максимальный выигрыш, затем рекурсивно обрабатывает потомков. Рассматривают только пороги между *различными* соседними значениями отсортированного признака; разделять равные значения нельзя.

Для квадратичной ошибки достаточно префиксных сумм $S_j = \sum_{i \le j} y_{(i)}$ и $Q_j = \sum_{i \le j} y_{(i)}^2$. Сумма квадратов ошибок слева равна

$$Q_j - \frac{S_j^2}{j},$$

аналогично справа. После сортировки все пороги проверяются за линейное время. Если один раз отсортировать каждый признак и поддерживать порядок при разбиениях, стоимость построения близкого к сбалансированному дерева составляет $O(dn \log n)$. Повторная сортировка в каждом узле может добавить ещё один логарифмический множитель.

«Оптимальный порог в каждом узле» не означает «глобально оптимальное дерево заданной глубины». Так, для XOR ни один одиночный порог не уменьшает энтропию, хотя дерево глубины два решает задачу без ошибок.

8.5 Ограничение сложности и особенности данных

Глубину и минимальное число объектов в листе можно ограничить заранее. Другой подход выбирает поддерево по критерию

$$R_\alpha(T) = \widehat{R}(T) + \alpha |\operatorname{Leaves}(T)|.$$

Для фиксированного полного дерева cost-complexity pruning строит вложенную последовательность поддеревьев; параметр α подбирается по валидации.

Кодирование неупорядоченных категорий целыми числами создаёт искусственный порядок. Возможны one-hot-кодирование или специальные разбиения множеств категорий. Для пропусков нужны явные правила: отдельная категория, заполнение внутри обучения, суррогатный предикат или обучаемое направление пропуска. Неопределённое поведение на таких данных не является частью математической модели дерева.

Деревья не требуют одинакового масштаба признаков и описывают нелинейные взаимодействия. Однако они чувствительны к изменениям выборки, а кусочно-постоянная регрессия плохо экстраполирует. Усреднение деревьев в ансамбле уменьшает часть этого разброса.

Контроль понимания

Откуда выводится энтропия в листе? Почему нужно учитывать размеры дочерних узлов? Чем локальная оптимальность отличается от глобальной? Как сохранить оценку $O(dn \log n)$?

ГЛАВА 9

Метрические методы

Материалы курса: лекция и семинар 4, теоретическое задание 7 [L04, S04, H07]..

9.1 Близость и взвешенное голосование

Метрика ρ удовлетворяет неотрицательности, тождеству неразличимых, симметрии и неравенству треугольника. Для $p \geq 1$ стандартный пример есть $\rho_p(x,z) = (\sum_j |x_j - z_j|^p)^{1/p}$. При $A \succ 0$ расстояние Махаланобиса равно $\rho_A(x,z) = ((x-z)^\mathsf{T} A (x-z))^{1/2}$.

Метрическая классификация основывается на предположении, что близкие объекты чаще имеют одинаковые ответы. Обобщённое правило записывается

$$a(x) \in \arg\max_k \sum_{i=1}^{n} w_i(x) \mathbf{1}\{y_i = k\}, \qquad w_i(x) \geq 0.$$

Пусть $x_{(1)}(x), \ldots, x_{(n)}(x)$ отсортированы по расстоянию до x. Метод kNN использует $w_{(i)} = \mathbf{1}\{i \leq k\}$, а взвешенный kNN дополнительно уменьшает вес далёких соседей. Ничьи расстояний и голосов требуют заранее заданного правила.

При $k = 1$ граница может очень точно повторять шум; увеличение k сглаживает оценку. Для евклидовых данных при соответствующих вероятностных предпосылках режим $k \to \infty$, $k/n \to 0$ лежит в основе состоятельности kNN. Один фиксированный k не удовлетворяет обоим требованиям: локальная область должна сужаться, но число наблюдений в ней расти.

9.2 Окно Парзена и потенциальные функции

Для неотрицательного профиля K и ширины $h > 0$ можно положить $w_i(x) = K(\rho(x, x_i)/h)$. Компактный носитель ограничивает число влияющих объектов; гауссовское окно оставляет всем положительный вес. При переменной ширине $h(x)$ её часто связывают с расстоянием до k-го соседа. Если оно нулевое, необходимо отдельно обработать совпадающие объекты.

В оценивании плотности на $\mathbb{R}^d$ обычно используется многомерное ядро K_d, интеграл которого равен единице:

$$\hat{p}_h(x) = \frac{1}{n h^d} \sum_i K_d\left(\frac{x - x_i}{h}\right).$$

Множитель h^{-d} необходим для нормировки плотности, хотя общий множитель может сокращаться в классификационном сравнении.

Метод потенциальных функций вводит коэффициенты $\gamma_i \geq 0$ и ширины h_i: $w_i(x) = \gamma_i K(\rho(x, x_i)/h_i)$. В пространстве признаков $\psi_i(x) = K(\rho(x, x_i)/h_i)$ это линейное голосование с настраиваемыми весами. Выбор прототипов и весов снижает стоимость предсказания, но добавляет задачу обучения.

9.3 Непараметрическая регрессия

Предложение 9.1 (Формула Надарая--Ватсона)**.** Для фиксированного x и весов $w_i(x) \geq 0$ с положительной суммой единственный минимум по a функции $\sum_i w_i(x)(y_i - a)^2$ равен

$$\widehat{m}(x) = \frac{\sum_i w_i(x) y_i}{\sum_i w_i(x)}.$$

Доказательство. Производная равна $2\sum_i w_i(a - y_i)$, а вторая производная $2\sum_i w_i > 0$. Решение линейного уравнения для первой производной даёт формулу. □

При нулевом знаменателе формула не определена: нужно расширить окно или задать явный резервный прогноз. Неотрицательность весов даёт $\min_i y_i \leq \widehat{m}(x) \leq \max_i y_i$ по наблюдениям с ненулевыми весами.

При гладких плотности и регрессионной функции, симметричном ядре с конечным вторым моментом и внутренних точках области типичные порядки квадрата смещения и дисперсии равны h^4 и $(nh^d)^{-1}$. Это локальная асимптотическая оценка при дополнительных условиях, а не универсальная формула на границе или в разреженной области. Баланс даёт $h \asymp n^{-1/(d+4)}$ и демонстрирует ухудшение скорости с ростом размерности.

9.4 Локальная линейная регрессия и выбросы

Вместо константы в окрестности x можно подгонять $a + b^{\mathsf{T}}(x_i - x)$:

$$\min_{a,b} \sum_i K(\rho(x, x_i)/h)(y_i - a - b^{\mathsf{T}}(x_i - x))^2, \qquad \widehat{m}(x) = \hat{a}.$$

Локальная линейная модель воспроизводит аффинную функцию при достаточном ранге и без шума, в том числе у края области. Её эквивалентные веса могут быть отрицательными; свойство попадания между минимумом и максимумом ответов уже не обязательно.

Устойчивый вариант LOWESS/LOESS итеративно умножает геометрические веса на вес, убывающий с модулем остатка. Например, бисквадратный вес $B(u) = (1-u^2)^2\mathbf{1}\{|u| < 1\}$ уменьшает влияние больших ошибок. Однако «выброс» определяется относительно принятой модели: систематический режим с иной зависимостью не следует автоматически удалять как шум.

9.5 Проклятие размерности

Предложение 9.2. Пусть n точек независимы и равномерны в единичном шаре $\mathbb{R}^d$, а $R_{\min}$ есть расстояние ближайшей из них до центра. Тогда для $0 \le r \le 1$

$$\mathbb{P}(R_{\min} > r) = (1-r^d)^n, \quad \operatorname{med}(R_{\min}) = (1-2^{-1/n})^{1/d}.$$

Доказательство. Доля объёма шара радиуса r равна r^d. Каждая точка не попадает в него с вероятностью $1-r^d$, а независимость даёт степень n. Медиана определяется равенством вероятности $1/2$. □

При фиксированном n медиана стремится к 1 при $d \to \infty$. Чтобы медиана не превосходила фиксированного $r < 1$, требуется $n \ge \log(1/2)/\log(1-r^d) \asymp (\log 2) r^{-d}$. Шумовые признаки поэтому способны разрушить полезную геометрию.

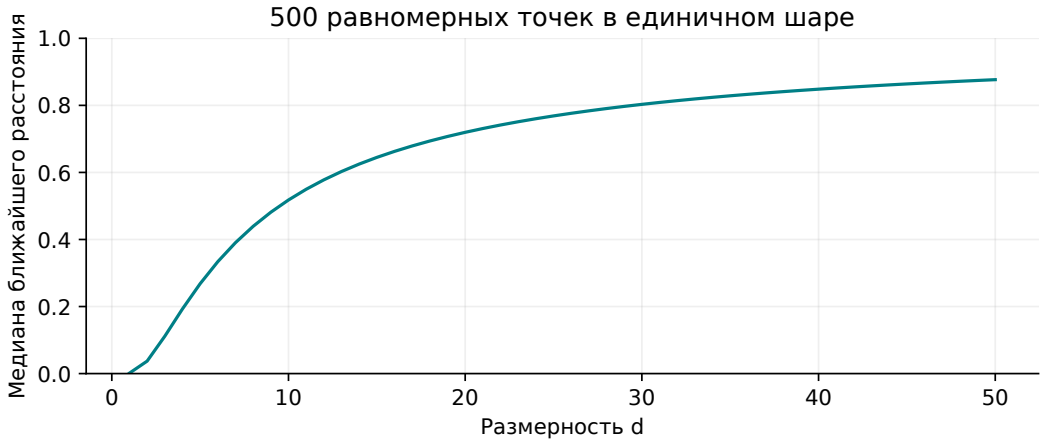


Рис. 9.1: Рост типичного расстояния до ближайшего объекта при фиксированном размере выборки.

Контроль понимания

Почему нормировку плотности нельзя опустить? Чем нулевой знаменатель отличается от малого? Что в большей степени определяет локальность: вид ядра

или ширина? Почему ядро сглаживания не обязано быть допустимым ядром SVM?

ГЛАВА 10

Метрики качества и отбор признаков

Материалы курса: лекция и семинар 5; теоретическое задание 7 [L05, S05, H07]..

10.1 Матрица ошибок и цена решения

Для бинарной классификации положительный класс фиксируют заранее. Обозначим через TP и FN число верно и неверно распознанных положительных объектов, через TN и FP аналогичные числа для отрицательных. Тогда

$$\text{accuracy} = \frac{TP + TN}{n}, \qquad \text{precision} = \frac{TP}{TP + FP},$$
$$\text{recall} = \frac{TP}{TP + FN}, \qquad F_\beta = \frac{(1+\beta^2)TP}{(1+\beta^2)TP + \beta^2 FN + FP}.$$

При нулевом знаменателе метрика математически не определена; библиотечное соглашение о нуле нужно указывать. Accuracy может скрывать полный провал на редком классе.

Если $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$ известна, стоимость ложноположительного ответа равна c_{FP}, ложноотрицательного c_{FN}, а верные ответы бесплатны, то оптимально предсказывать 1, когда

$$c_{FP}(1 - \eta(x)) \le c_{FN}\eta(x) \quad \Longleftrightarrow \quad \eta(x) \ge \frac{c_{FP}}{c_{FP} + c_{FN}}.$$

Порог $1/2$ является частным случаем равных стоимостей. Этот вывод требует интерпретации оценки как вероятности, а не произвольного ранжирующего балла.

10.2 ROC, PR и равные оценки

Для оценки $s(x)$ и порога t предсказываем 1 при $s(x) \ge t$. ROC-кривая состоит из точек $(FPR(t), TPR(t))$, где $FPR = FP/(FP+TN)$ и $TPR = recall$. При понижении порога обе координаты не убывают. Равные значения оценки проходят порог одновременно; разбиение такой группы в произвольном порядке меняет кривую без оснований.

Предложение 10.1 (Парная формула ROC AUC)**.** При наличии обоих классов и линейном соединении ROC-точек между группами равных оценок

$$\mathrm{AUC} = \frac{1}{n_+ n_-} \sum_{i:y_i=1} \sum_{j:y_j=0} \left(\mathbf{1}\{s_i > s_j\} + \tfrac{1}{2}\mathbf{1}\{s_i = s_j\} \right).$$

Доказательство. Проход отрицательного объекта увеличивает FPR на $1/n_-$. Если его оценка отлична от положительных, площадь добавленного прямоугольника равна доле уже пройденных положительных, делённой на n_-. Это даёт по $1/(n_+ n_-)$ за правильно упорядоченную пару. Группа из a положительных и b отрицательных добавляет трапецию; её треугольная часть равна $ab/(2n_+ n_-)$, то есть половине вклада каждой связанной пары. □

Следовательно, AUC не меняется при строго возрастающем преобразовании s. Она характеризует ранжирование и не измеряет калибровку вероятностей.

PR-кривая использует координаты $(recall, precision)$. Полнота не убывает при снижении порога, точность может как расти, так и падать. Конечная точка при предсказании всем класса 1 равна $(1, \pi)$, где $\pi = n_+/n$, а не $(1, 0)$. Начальная точность при отсутствии положительных прогнозов требует соглашения.

В этой книге average precision определяется ступенчатым правилом

$$AP = \sum_k (R_k - R_{k-1}) P_k,$$

где k пробегает пороги по различным оценкам. Трапецеидальная площадь под ломаной PR-кривой является другой величиной. Они совпадают не всегда.

При фиксированных TPR, FPR и распространённости класса π

$$precision = \frac{\pi\, TPR}{\pi\, TPR + (1-\pi) FPR}.$$

Поэтому PR особенно чувствительна к доле редкого класса. Сравнивать PR на выборках с различной распространённостью нужно с учётом этой зависимости.

10.3 Вероятностные прогнозы и регрессия

Для истинной условной вероятности η математическое ожидание log-loss при прогнозе p равно

$$-\eta \log p - (1-\eta)\log(1-p) = H(\eta) + \mathrm{KL}(\mathrm{Ber}(\eta) \,\|\, \mathrm{Ber}(p)).$$

Минимум достигается при $p = \eta$, что выражает строго собственный характер log-loss. У MAE для бинарной метки

$$\mathbb{E}|Y - p| = \eta(1-p) + (1-\eta)p = \eta + p(1-2\eta).$$

Минимум достигается в 0 или 1 в зависимости от знака $1 - 2\eta$. Значит, MAE не поощряет восстановление условной вероятности.

Калибровка означает $\mathbb{E}[Y \mid p(X)] = p(X)$ почти наверное. Даже калиброванный прогноз может иметь слабую различающую способность, например константа, равная доле класса. Для многоклассовых метрик macro-усреднение даёт равный вес классам, micro объединяет счётчики всех классов. В однозначной полной многоклассовой классификации micro-precision и micro-recall совпадают с accuracy.

В регрессии используют $MSE = n^{-1} \sum_i (y_i - \hat{y}_i)^2$, $RMSE = \sqrt{MSE}$, $MAE = n^{-1} \sum_i |y_i - \hat{y}_i|$ и

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \overline{y})^2}.$$

На тесте R^2 может быть отрицателен; при постоянных истинных ответах знаменатель равен нулю. Логарифмическое преобразование ответа меняет смысл ошибки. В общем случае $\exp(\mathbb{E}[\log Y \mid X]) \neq \mathbb{E}[Y \mid X]$.

10.4 Отбор признаков как задача выбора модели

Пусть $J \subseteq \{1, \dots, d\}$, а $Q(J)$ есть валидационная оценка всей процедуры с признаками J. Полный перебор рассматривает все 2^d множеств. Если перебор останавливается после нескольких размеров без улучшения, он уже не гарантирует полного поиска.

Жадное добавление последовательно выбирает лучший одиночный признак для расширения текущего набора. Удаление начинает со всех признаков; Add-Del чередует эти операции. Поиск с шириной B сохраняет несколько лучших наборов каждого размера, удаляя дубликаты. В терминологии исходной лекции это поиск в ширину; при ограниченном B точнее говорить об ограниченном поиске по уровням. При $B = 1$ он сводится к жадному добавлению.

Генетический алгоритм кодирует набор двоичным вектором, выполняет отбор, скрещивание и мутацию. Это эвристический поиск; конечная популяция и ограниченное число поколений не гарантируют глобального оптимума. Для XOR каждый признак по отдельности неинформативен, а пара достаточна: такой пример объясняет слабость одномерных фильтров и ранней остановки жадного поиска.

Любой поиск по признакам необходимо включать во внутреннюю часть валидации. Отбор на всей выборке перед CV позволяет меткам тестового блока влиять на модель и завышает оценку качества.

Контроль понимания

Почему AP не равно любой «площади под PR»? Что происходит с precision при уменьшении π? Может ли AUC быть отличной при плохом log-loss? Где возникает утечка при отборе признаков до CV?

ГЛАВА 11

Метод опорных векторов и ядра

Материалы курса: лекция и семинар 8; теоретическое задание 7 [L08, S08, H07]..

11.1 Геометрический зазор

Для гиперплоскости $w^{\mathsf{T}}x + b = 0$, $w \neq 0$, расстояние точки x до неё равно $|w^{\mathsf{T}}x+b|/\|w\|$. При метке $y \in \{-1, +1\}$ знаковое расстояние равно $y(w^{\mathsf{T}}x+b)/\|w\|$.

Для строго разделимой выборки параметры можно масштабировать так, чтобы минимальный функциональный отступ был равен 1. Тогда максимизация минимального геометрического отступа эквивалентна

$$\min_{w,b} \frac{1}{2}\|w\|^2 \quad \text{при} \quad y_i(w^{\mathsf{T}}x_i + b) \geq 1.$$

Ширина полосы между плоскостями с уровнями -1 и 1 равна $2/\|w\|$.

11.2 Мягкий зазор и hinge loss

Введём переменные $\xi_i \geq 0$ и $C > 0$:

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_i \xi_i, \quad y_i(w^{\mathsf{T}}x_i + b) \geq 1 - \xi_i. \tag{11.1}$$

При фиксированных w, b наименьшее допустимое ξ_i равно $(1 - y_i(w^{\mathsf{T}}x_i + b))_+$. Следовательно, задача эквивалентна минимизации нормы и суммы hinge-потерь. Большое C увеличивает относительную цену нарушений зазора. Если использовать среднюю потерю $\lambda\|w\|^2/2 + n^{-1}\sum_i \ell_i$, то соответствие равно $C = 1/(n\lambda)$.

11.3 Двойственная задача и условия KKT

Для ограничений $1 - \xi_i - y_i(w^{\mathsf{T}}x_i + b) \leq 0$ введём множители $\alpha_i \geq 0$, для $-\xi_i \leq 0$ множители $\nu_i \geq 0$. Лагранжиан:

$$\mathcal{L} = \tfrac{1}{2}\|w\|^2 + C\sum_i \xi_i + \sum_i \alpha_i(1 - \xi_i - y_i(w^{\mathsf{T}}x_i + b)) - \sum_i \nu_i\xi_i.$$

Стационарность по w, b, ξ даёт

$$w = \sum_i \alpha_i y_i x_i, \qquad \sum_i \alpha_i y_i = 0, \qquad \alpha_i + \nu_i = C.$$

Подставляя в лагранжиан, получаем двойственную задачу

$$\max_{\alpha} \left\{ \sum_i \alpha_i - \frac{1}{2} \sum_{ij} \alpha_i \alpha_j y_i y_j x_i^{\mathsf{T}} x_j \right\}, \quad 0 \le \alpha_i \le C, \quad \sum_i \alpha_i y_i = 0. \tag{11.2}$$

Задача выпукла; существует строго допустимая точка, например $w = 0$, $b = 0$, $\xi_i = 2$. Условие Слейтера обеспечивает сильную двойственность. Условия KKT необходимы и достаточны для оптимальности.

Дополняющая нежёсткость выражается равенствами

$$\alpha_i (1 - \xi_i - y_i (w^{\mathsf{T}} x_i + b)) = 0, \qquad (C - \alpha_i)\xi_i = 0.$$

Если $0 < \alpha_i < C$, то $\xi_i = 0$ и отступ равен 1. Если $\alpha_i = C$, точка может лежать внутри полосы, на её границе или быть ошибочно классифицированной. Если $\alpha_i = 0$, она не входит в двойственное представление; возможны вырожденные случаи с точкой на границе и нулевым множителем.

Для свободного опорного вектора $0 < \alpha_i < C$ можно восстановить $b = y_i - w^{\mathsf{T}} x_i$. Если таких векторов нет, b выбирают из интервала, задаваемого условиями KKT; деление на отсутствующее множество опорных векторов недопустимо.

11.4 Допустимые ядра

Определение 11.1. Вещественное ядро $K : \mathcal{X}^2 \to \mathbb{R}$ называется положительно полуопределённым, если оно симметрично и для любых $x_1, \dots, x_m$ и $c \in \mathbb{R}^m$ $\sum_{ij} c_i c_j K(x_i, x_j) \ge 0$.

Если $K(x, z) = \langle \phi(x), \phi(z) \rangle$ в гильбертовом пространстве, условие выполнено, поскольку сумма равна $\left\| \sum_i c_i \phi(x_i) \right\|^2$. Обратное представление можно построить, взяв формальные линейные комбинации символов K_x, задав им скалярное произведение через K, факторизовав нулевую норму и пополнив пространство.

Замена $x_i^{\mathsf{T}} x_j$ на $K(x_i, x_j)$ сохраняет выпуклость двойственной задачи. Прогноз принимает вид

$$s(x) = \sum_i \alpha_i y_i K(x_i, x) + b.$$

Симметрии и неотрицательности значений функции недостаточно: нужна положительная полуопределённость всех конечных матриц Грама.

Предложение 11.2. Неотрицательные линейные комбинации и поточечные произведения допустимых ядер допустимы. Полиномиальное ядро $(x^{\mathsf{T}} z + c)^m$ допустимо при целом $m \ge 1$ и $c \ge 0$.

Доказательство. Сумме отвечает прямое суммирование пространств признаков с множителями $\sqrt{a}$. Произведению отвечает тензорное произведение признаков. Функция $x^{\mathsf{T}}z + c$ задаётся признаком $(x, \sqrt{c})$; её целая степень есть повторное произведение. □

Гауссовское ядро $e^{-\gamma\|x-z\|^2}$, $\gamma > 0$, также допустимо: разложение $e^{2\gamma x^{\mathsf{T}}z}$ в ряд даёт неотрицательную сумму полиномиальных ядер, а внешние множители $e^{-\gamma\|x\|^2} e^{-\gamma\|z\|^2}$ сохраняют положительность.

Ядро сглаживания в методе Парзена описывает веса соседей и обычно неотрицательно и интегрируемо. Ядро SVM описывает скалярное произведение; оно может принимать отрицательные значения и не обязано интегрироваться в единицу. Общая терминология не означает одинаковых аксиом.

11.5 Регрессия и другие штрафы

SVR использует ε-нечувствительную потерю $\ell_\varepsilon(y, s) = \max\{|y-s|-\varepsilon, 0\}$. Внутри полосы ширины 2ε ошибка не штрафуется. В двойственном представлении коэффициенты становятся разностями двух неотрицательных множителей.

Замена $\|w\|^2$ на $\|w\|_1$ даёт другую задачу, способствующую отбору признаков. Стандартная квадратичная двойственная формула (11.2) к ней не относится. Kernel SVM удобен на умеренных выборках, но хранение полной матрицы Грама требует $O(n^2)$ памяти. Его оценка $s(x)$ не является вероятностью без дополнительной калибровки.

Контроль понимания

Где в выводе появляется ограничение $\sum_i \alpha_i y_i = 0$? Почему $\alpha_i = C$ не равносильно ошибке? Как проверить недопустимость ядра одним конечным контрпримером? Как связаны C и λ при средней потере?

ГЛАВА 12

Композиции алгоритмов

Материалы курса: лекция и семинар 9 [L09, S09]..

12.1 Усреднение, бэггинг и случайные признаки

Композиция строится из базовых оценок $h_1, \dots, h_B$ корректирующей операцией, например $F(x) = B^{-1} \sum_b h_b(x)$, а итоговое решение получается порогом или максимумом по классам. Усреднять классовые номера нельзя: для классификации усредняют голоса или вероятности.

Предложение 12.1. Если при фиксированном x случайные прогнозы имеют дисперсию σ^2 и одинаковую попарную корреляцию ρ, то

$$\operatorname{Var}\left(\frac{1}{B}\sum_b h_b(x)\right) = \sigma^2\left(\rho + \frac{1-\rho}{B}\right).$$

Доказательство. В дисперсии суммы имеется B диагональных слагаемых σ^2 и $B(B-1)$ внедиагональных $\rho\sigma^2$. Деление на B^2 даёт формулу. □

Число моделей уменьшает только некоррелированную часть разброса. Бэггинг обучает модели на bootstrap-выборках из n извлечений с возвращением. Вероятность не попасть в одну такую выборку равна $(1-1/n)^n \to e^{-1}$. Объекты вне подвыборки можно использовать для out-of-bag-оценивания соответствующей модели.

Метод случайных подпространств выбирает разные подмножества признаков. В случайном лесе случайный набор кандидатов выбирают обычно в каждом узле дерева, сочетая это с bootstrap-обучением. Уменьшение корреляции деревьев может компенсировать некоторое ослабление отдельного дерева.

12.2 AdaBoost как минимизация экспоненциальной потери

Пусть $y_i, h_t(x_i) \in \{-1, +1\}$ и $F_t = F_{t-1} + \alpha_t h_t$. Рассмотрим $L(F) = \sum_i e^{-y_i F(x_i)}$. Нормированные веса на шаге t:

$$D_t(i) = \frac{e^{-y_i F_{t-1}(x_i)}}{\sum_j e^{-y_j F_{t-1}(x_j)}}.$$

Для заданного h_t обозначим взвешенную долю ошибок через $\varepsilon_t = \sum_i D_t(i)\mathbf{1}\{h_t(x_i) \neq y_i\}$. Тогда отношение нового функционала к прежнему равно

$$Z_t(\alpha) = (1 - \varepsilon_t)e^{-\alpha} + \varepsilon_t e^{\alpha}.$$

При $0 < \varepsilon_t < 1/2$ дифференцирование даёт

$$\alpha_t = \frac{1}{2}\log\frac{1-\varepsilon_t}{\varepsilon_t}, \qquad Z_t = 2\sqrt{\varepsilon_t(1-\varepsilon_t)}.$$

Веса обновляются по формуле $D_{t+1}(i) = D_t(i)e^{-\alpha_t y_i h_t(x_i)}/Z_t$. Правильно классифицированные объекты получают меньший относительный вес, ошибочные больший. Это и формализует две эвристики: усиливать внимание к ошибкам и больше доверять точному базовому алгоритму.

Теорема 12.2 (Оценка обучающей ошибки AdaBoost)**.** При $F_0 = 0$ и $\varepsilon_t = 1/2 - \gamma_t \in (0, 1/2)$

$$\frac{1}{n}\sum_i \mathbf{1}\{y_i F_T(x_i) \leq 0\} \leq \prod_{t=1}^{T} Z_t \leq \exp\left(-2\sum_{t=1}^{T}\gamma_t^2\right).$$

Доказательство. Индикатор не превосходит $e^{-y_i F_T(x_i)}$. Последовательная нормировка весов даёт $n^{-1}L(F_T) = \prod_t Z_t$. Далее $Z_t = \sqrt{1-4\gamma_t^2} \leq e^{-2\gamma_t^2}$ вследствие $\log(1-u) \leq -u$. □

Это оценка *обучающей*, а не тестовой ошибки. При $\varepsilon_t = 0$ формальная формула даёт бесконечный вес: алгоритм нужно остановить или применить явно указанное ограничение. При $\varepsilon_t \geq 1/2$ полезность шага с положительным весом не обеспечена.

12.3 Градиентный бустинг

Рассмотрим вектор оценок $F = (F(x_1), \dots, F(x_n)) \in \mathbb{R}^n$ и функционал $\sum_i \ell(y_i, F_i)$. Отрицательный градиент в этом пространстве имеет координаты

$$r_{it} = -\left.\frac{\partial \ell(y_i, z)}{\partial z}\right|_{z=F_{t-1}(x_i)}.$$

Сначала приближают r_t базовой моделью h_t, обычно решая $\min_h \sum_i (r_{it} - h(x_i))^2$. Затем находят длину шага $\alpha_t \in \arg\min_\alpha \sum_i \ell(y_i, F_{t-1}(x_i) + \alpha h_t(x_i))$ и обновляют $F_t = F_{t-1} + \nu \alpha_t h_t$, где $0 < \nu \leq 1$.

Для $\ell(y, z) = \frac{1}{2}(y - z)^2$ псевдоостатки совпадают с обычными остатками $y_i - F_i$. Для бинарного log-loss по логиту они равны $y_i - \sigma(F_i)$. Бустинг таким образом подгоняет поправку к текущей модели, а не независимо переобучает модели с нуля на разных выборках.

12.4 Квадратичное приближение в деревьях

Если $g_i = \partial_F \ell_i$ и $h_i = \partial_F^2 \ell_i \geq 0$, то вторая поправка Тейлора для дерева с постоянным значением v_j в листе I_j даёт

$$\sum_j \left(G_j v_j + \frac{1}{2}(H_j + \lambda) v_j^2 \right) + \gamma J, \quad G_j = \sum_{i \in I_j} g_i,\ H_j = \sum_{i \in I_j} h_i.$$

При $H_j + \lambda > 0$ оптимум $v_j = -G_j / (H_j + \lambda)$. Выигрыш разбиения по этому приближению равен

$$\frac{1}{2}\left(\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right) - \gamma.$$

Это объясняет один из механизмов регуляризованного бустинга над деревьями. Квадратичное приближение не совпадает с исходной потерей для произвольного большого шага.

Бэггинг прежде всего уменьшает разброс нестабильных моделей. Бустинг последовательно расширяет класс приближений и уменьшает ошибку текущей композиции. Его экспоненциальный вариант особенно чувствителен к ошибочным меткам, которые долго получают растущий вес. Глубину базовых деревьев, число шагов и темп обучения выбирают совместно по валидации.

Контроль понимания

Почему независимые случайные числа не делают прогнозы деревьев независимыми? Откуда возникает $1/2$ в весе AdaBoost? Почему доказанная экспоненциальная оценка не является гарантией обобщения?

ГЛАВА 13

Нейронные сети и обратное распространение

Материалы курса: лекция и семинар 10; домашнее задание 8 [L10, S10, H08]..

13.1 Зачем нужна нелинейность

Нейрон МакКаллока--Питтса можно описать пороговой функцией $\mathbf{1}\{w^{\mathsf{T}}x+b\geq 0\}$. Несколько линейных слоёв без нелинейностей не расширяют класс аффинных отображений: $W_2(W_1x+b_1)+b_2=(W_2W_1)x+(W_2b_1+b_2)$.

Предложение 13.1. Разметка XOR на вершинах единичного квадрата не реализуется аффинным бинарным классификатором со строгими отступами.

Доказательство. Пусть $(0,0)$ и $(1,1)$ отрицательны, а $(1,0)$ и $(0,1)$ положительны. Положительные отступы требуют $w_1+b>0$, $w_2+b>0$, откуда $w_1+w_2+2b>0$. Отрицательные требуют $b<0$ и $w_1+w_2+b<0$, откуда та же сумма меньше нуля. Противоречие. $\square$

Два скрытых пороговых нейрона позволяют реализовать XOR: $h_1=\mathbf{1}\{x_1+x_2\geq 1/2\}$, $h_2=\mathbf{1}\{x_1+x_2\geq 3/2\}$, выход $\mathbf{1}\{h_1-h_2\geq 1/2\}$. Для градиентного обучения используют функции с производной почти всюду.

13.2 Прямой проход и размерности

Для батча из b объектов будем хранить строки. Пусть $H_0=X\in\mathbb{R}^{b\times d_0}$. Для слоя $l=1,\dots,L$

$$Z_l=H_{l-1}W_l+\mathbf{1}_b b_l^{\mathsf{T}},\qquad H_l=\phi_l(Z_l),$$

где $W_l\in\mathbb{R}^{d_{l-1}\times d_l}$, $b_l\in\mathbb{R}^{d_l}$, а ϕ_l действует покоординатно, кроме специального вероятностного выходного слоя. Потеря усредняется по объектам батча.

Сигмоида имеет производную $\sigma(z)(1-\sigma(z))\leq 1/4$; $\tanh'(z)=1-\tanh^2 z$. ReLU равна $\max(0,z)$ и имеет производную $\mathbf{1}\{z>0\}$ вне нуля. В нуле выбирают соглашение, например 0. Leaky ReLU имеет малый положительный наклон на отрицательной полуоси. Насыщение сигмоиды и тангенса уменьшает градиенты, а ReLU может навсегда давать нулевой градиент у неактивного нейрона.

13.3 Обратный проход

Определим $\Delta_l = \partial F / \partial Z_l$, имеющую ту же форму, что Z_l. Цепное правило даёт

$$\nabla_{W_l} F = H_{l-1}^{\mathsf{T}} \Delta_l, \qquad \nabla_{b_l} F = \Delta_l^{\mathsf{T}} \mathbf{1}_b, \tag{13.1}$$

$$\Delta_{l-1} = (\Delta_l W_l^{\mathsf{T}}) \odot \phi'_{l-1}(Z_{l-1}). \tag{13.2}$$

Множитель $1/b$ должен присутствовать ровно один раз: удобно включать его в выходную Δ_L.

Предложение 13.2. Для softmax-выхода с cross-entropy по среднему батча $\Delta_L = (P - Y)/b$. Для сигмоидного бинарного выхода с log-loss справедлива та же формула с одним столбцом.

Доказательство. Для одного объекта потеря по логитам равна $-z_y + \log \sum_k e^{z_k}$. Её производная по z_j равна $-\mathbf{1}\{j = y\} + p_j$. Усреднение добавляет множитель $1/b$. □

Для вывода (13.1) запишем $dF = \operatorname{tr}(\Delta_l^{\mathsf{T}} dZ_l)$ и $dZ_l = dH_{l-1} W_l + H_{l-1} dW_l + \mathbf{1}_b (db_l)^{\mathsf{T}}$. Сбор коэффициентов при dW_l, db_l и dH_{l-1} даёт обе формулы. Это доказательство показывает, что backpropagation является эффективным применением цепного правила к графу вычислений, а не отдельным правилом приближённого дифференцирования.

13.4 Стоимость, инициализация и симметрия

Обратный проход использует сохранённые промежуточные значения прямого прохода. Его вычислительная стоимость имеет тот же порядок, что и стоимость прямого прохода; память зависит от числа сохранённых активаций. Градиент по каждому весу отдельно конечными разностями потребовал бы существенно больше проходов.

Если все нейроны одного скрытого слоя инициализированы одинаково, их выходы и градиенты одинаковы, поэтому симметрия сохраняется при детерминированном обучении. Разные случайные начальные веса нарушают её. Масштаб инициализации выбирают с учётом числа входов; для ReLU распространена дисперсия порядка $2/d_{l-1}$. Это аргумент о сохранении масштаба при упрощающих предположениях о независимости и распределении, а не гарантия сходимости произвольной сети.

Произведение якобианов в глубокой сети может уменьшать или увеличивать норму градиента во много раз. Масштабирование, подходящие активации,

инициализация и ограничение нормы градиента решают разные части этой проблемы. Выпуклость потери по последним логитам не означает выпуклости по всем весам сети.

13.5 Регуляризация и проверка реализации

При добавлении $\lambda \sum_l \|W_l\|_F^2 / 2$ градиент каждого веса получает слагаемое λW_l. Dropout во время обучения случайно обнуляет активации; в варианте inverted dropout оставшиеся активации делятся на вероятность сохранения. На этапе применения эта случайность отключается. Само совпадение среднего выхода отдельного слоя ещё не доказывает совпадение среднего выхода всей нелинейной сети.

Для малой сети полезна проверка направленной производной:

$$\frac{F(\theta + hv) - F(\theta - hv)}{2h} \approx \nabla F(\theta)^{\mathsf{T}} v.$$

Следует избегать точек недифференцируемости ReLU, фиксировать случайность и включать в проверку все члены регуляризации. Умение переобучить несколько точек является диагностикой реализации, но не оценкой обобщения.

Контроль понимания

Почему обновление весов нельзя выполнять посередине вычисления градиентов всех слоёв? Где находится деление на размер батча? Почему два линейных слоя эквивалентны одному? Что проверяет тест на XOR, а чего он не проверяет?

ГЛАВА 14

Кластеризация и частичное обучение

Материалы курса: лекция и семинар 11 [L11, S11]; графовое гармоническое продолжение добавлено..

14.1 Постановка задачи и неоднозначность

В кластеризации известны только объекты $x_1, \dots, x_n$; требуется разбиение на группы. Без выбора метрики, числа групп, допустимой формы и критерия качества задача не имеет единственного определённого смысла. Один набор точек может отражать несколько содержательных группировок.

Внутренний критерий использует только данные и разбиение. Внешний сравнивает с известной разметкой, которая не должна применяться для обучения. Минимизация внутрикластерного расстояния без ограничения числа кластеров вырождается в отдельный кластер для каждого объекта. Минимизация суммы весов межкластерных рёбер без ограничений допускает один общий кластер. Поэтому ограничения являются частью постановки.

Для объекта i силуэт определяют через среднее расстояние a_i до своего кластера и минимальное среднее расстояние b_i до другого: $s_i = (b_i - a_i)/\max(a_i, b_i)$. Для одноэлементного кластера обычно полагают $s_i = 0$. Этот критерий также зависит от метрики и не является универсальной истиной о кластерах.

14.2 K-means и алгоритм Ллойда

Задано число кластеров K. Минимизируется

$$J(c, \mu) = \sum_{i=1}^{n} \left\| x_i - \mu_{c_i} \right\|^2, \quad c_i \in \{1, \dots, K\}.$$

Алгоритм чередует присвоение ближайшего центра и пересчёт каждого непустого центра как среднего назначенных объектов.

Предложение 14.1. Один полный шаг Ллойда не увеличивает J.

Доказательство. При фиксированных центрах каждое слагаемое независимо минимизируется выбором ближайшего центра. При фиксированных назначениях среднее является минимизатором суммы квадратов в каждом непустом кластере. Обе операции поэтому не увеличивают один и тот же функционал. □

Монотонность даёт сходимость значений снизу ограниченного функционала. Конечное завершение разметок требует аккуратного обращения с ничьими и пустыми кластерами; можно сохранять прежнее назначение при равенстве. Достижение глобального минимума не гарантируется.

Инициализация k-means++ выбирает первый центр среди наблюдений, а следующий с вероятностью, пропорциональной квадрату расстояния до уже выбранных центров. Она уменьшает вероятность явно неудачного начала, но несколько запусков всё ещё могут давать разные локальные решения. K-means естественен для компактных групп в евклидовой геометрии; он плохо соответствует вложенным окружностям или вытянутым нелинейным структурам.

14.3 DBSCAN

Зафиксируем $\varepsilon > 0$ и целое m. Точка является основной, если её замкнутая ε-окрестность содержит не менее m наблюдений, включая саму точку. Соединим основные точки ребром, если их расстояние не превосходит ε. Компоненты связности этого графа образуют основы кластеров; соседние неосновные точки являются граничными, оставшиеся шумовыми.

DBSCAN не требует задавать K и допускает невыпуклые кластеры. Однако единственный масштаб ε плохо подходит для резко различной плотности групп. Граничная точка может соседствовать с несколькими компонентами; её присвоение тогда зависит от соглашения или порядка обхода. Основные компоненты при этом определены однозначно.

Поиск всех соседей напрямую требует $O(n^2)$ сравнений. Пространственные индексы иногда ускоряют его, но их эффективность ухудшается в большой размерности; безусловной оценки $O(n \log n)$ для произвольных данных нет.

14.4 Иерархическая кластеризация

Агломеративный алгоритм начинает с одноэлементных кластеров и последовательно объединяет ближайшую пару. Single linkage использует минимальное расстояние между точками двух кластеров, complete linkage максимальное, average linkage среднее по всем межкластерным парам.

Обновления часто записываются формулой Ланса--Уильямса:

$$d(A \cup B, C) = \alpha_A d(A, C) + \alpha_B d(B, C) + \beta d(A, B) + \gamma |d(A, C) - d(B, C)|.$$

Для single linkage $\alpha_A = \alpha_B = 1/2$, $\beta = 0$, $\gamma = -1/2$; для complete linkage знак γ положителен; для average linkage $\alpha_A = |A|/(|A| + |B|)$, $\alpha_B = 1 - \alpha_A$, $\beta = \gamma = 0$.

Критерий Уорда объединяет пару с минимальным ростом суммы квадратов:

$$\Delta(A, B) = \frac{|A||B|}{|A| + |B|} \left\| \mu_A - \mu_B \right\|^2.$$

Формула следует из разложения суммы квадратов относительно общего среднего. Дендрограмма изображает вложенную историю слияний. У плоского разбиения без истории такая дендрограмма не определяется однозначно. Некоторые варианты связи допускают инверсии высот; интерпретировать все высоты как монотонные расстояния нельзя без проверки метода.

14.5 Использование неразмеченных объектов

В частичном обучении известны метки лишь для $\ell < n$ объектов. Дополнительные объекты полезны только при предположениях, связывающих распределение X с метками: например, о постоянстве метки в плотной области. Без такой связи неразмеченные данные могут не дать информации об условном распределении $Y \mid X$.

Self-training добавляет в обучение уверенные псевдометки; ошибки модели могут закрепляться. Co-training использует несколько представлений объектов и опирается на предположения об их информативности и совместимости. В модификации k-means размеченные объекты закрепляют за соответствующими центрами или добавляют штраф за нарушение меток.

Графовый вариант строит симметричные веса $w_{ij} \geq 0$ и лапласиан $L = D - W$, где $D_{ii} = \sum_j w_{ij}$. Для числовых оценок f_i

$$f^{\mathsf{T}} L f = \frac{1}{2} \sum_{ij} w_{ij} (f_i - f_j)^2 \geq 0.$$

При жёстко фиксированных метках $f_L = y_L$ минимум по неразмеченным координатам удовлетворяет $L_{UU} f_U = -L_{UL} y_L$. Если каждая компонента графа содержит размеченную вершину, $L_{UU} \succ 0$ и решение единственно. Действительно, нулевая энергия заставляет функцию быть постоянной на каждой компоненте, а нулевые граничные значения вынуждают эту константу быть нулевой.

Контроль понимания

Почему уменьшение J не доказывает глобальную оптимальность? Может ли граничная точка DBSCAN иметь неоднозначный кластер? Что исключает тривиальные решения графового критерия? При каких предположениях неразмеченные данные полезны?

ГЛАВА 15

Байесовское обучение и моделирование

Материалы курса: лекции 3 и 12, семинар 12 [L03, L12, S12]..

15.1 Формула Байеса и предсказание

Для совместной плотности или вероятностной массы $p(x, y) = p(x \mid y)p(y) = p(y \mid x)p(x)$. Маргинализация суммирует или интегрирует по ненаблюдаемым переменным. При $p(x) > 0$

$$p(y \mid x) = \frac{p(x \mid y)p(y)}{\int p(x \mid u)p(u)\,du}.$$

Для дискретной переменной интеграл заменяется суммой. Цепное правило полной совместной плотности имеет вид $p(x_1, \dots, x_m) = p(x_1)\prod_{j=2}^{m} p(x_j \mid x_1, \dots, x_{j-1})$.

В параметрической модели prior $\pi(\theta)$ и правдоподобие $p(D \mid \theta)$ задают posterior

$$p(\theta \mid D) = \frac{p(D \mid \theta)\pi(\theta)}{p(D)}, \qquad p(D) = \int p(D \mid \theta)\pi(\theta)\,d\theta.$$

Необходимо $0 < p(D) < \infty$. Собственный prior не устраняет автоматически неверную спецификацию модели.

Байесовский предсказательный закон равен

$$p(y_* \mid x_*, D) = \int p(y_* \mid x_*, \theta)p(\theta \mid D)\,d\theta.$$

Подстановка MAP-оценки вместо интеграла в общем случае даёт иной прогноз и теряет часть параметрической неопределённости. Частотный подход не ограничивается точечными оценками: доверительные интервалы и тесты также принадлежат ему. Байесовский интервал вероятности и частотный доверительный интервал имеют разные определения.

15.2 Сопряжённость: Бернулли и нормальная модель

Семейство priors сопряжено правдоподобию, если posterior остаётся в том же семействе для любой допустимой выборки.

Предложение 15.1. Если $Y_i \mid \theta$ независимы с законом Бернулли, $s = \sum_i Y_i$, а $\theta \sim \mathrm{Beta}(a, b)$, $a, b > 0$, то

$$\theta \mid D \sim \mathrm{Beta}(a + s, b + n - s), \qquad \mathbb{P}(Y_{n+1} = 1 \mid D) = \frac{a + s}{a + b + n}.$$

Доказательство. Произведение prior и likelihood пропорционально $\theta^{a+s-1}(1-\theta)^{b+n-s-1}$, то есть ядру указанной бета-плотности. Предсказательная вероятность равна апостериорному среднему θ. $\square$

MAP для бета-распределения с обоими параметрами больше 1 равна $(a+s-1)/(a+b+n-2)$ и не совпадает со средним. При параметрах не больше 1 максимум может находиться на границе, поэтому эту формулу нельзя применять без условий.

Если $Y_i \mid \mu \sim \mathcal{N}(\mu, \sigma^2)$ с известной σ^2, а $\mu \sim \mathcal{N}(m_0, \tau_0^2)$, то завершение квадрата даёт

$$\tau_n^{-2} = \tau_0^{-2} + n\sigma^{-2}, \qquad m_n = \tau_n^2(\tau_0^{-2} m_0 + \sigma^{-2} \sum_i y_i).$$

Posterior равен $\mathcal{N}(m_n, \tau_n^2)$, предсказательное распределение $\mathcal{N}(m_n, \sigma^2 + \tau_n^2)$. Последняя дисперсия включает шум нового измерения и неопределённость среднего.

15.3 Байесовская линейная регрессия

При $y \mid w \sim \mathcal{N}(Xw, \sigma^2 I)$ и $w \sim \mathcal{N}(m_0, S_0)$, $S_0 \succ 0$, имеем

$$S_n = (S_0^{-1} + X^{\top}X/\sigma^2)^{-1}, \qquad m_n = S_n(S_0^{-1} m_0 + X^{\top} y/\sigma^2).$$

Это следует из раскрытия квадратичных форм в логарифме совместной плотности. В данной гауссовской задаче posterior симметричен и его мода совпадает со средним. При $m_0 = 0$, $S_0 = \tau^2 I$ MAP совпадает с ridge с коэффициентом при ненормированной сумме квадратов σ^2/τ^2.

Для нового x_* $Y_* \mid x_*, D \sim \mathcal{N}(x_*^{\top} m_n, \sigma^2 + x_*^{\top} S_n x_*)$. Низкая неопределённость в наблюдавшихся направлениях не означает низкой неопределённости во всех направлениях пространства признаков.

15.4 Наивный байесовский классификатор

Предполагается условная независимость признаков при заданном классе:

$$p(x \mid Y = k) = \prod_{j=1}^{d} p_j(x_j \mid k).$$

Правило классификации максимизирует $\log \pi_k + \sum_j \log p_j(x_j \mid k)$. Независимость требуется *условно на класс*, а не в безусловном распределении. Для категориальных признаков сглаживание Дирихле предотвращает нулевые частоты. Для вещественных признаков часто используют условные гауссовские плотности. Нарушение независимости не обязательно разрушает границу решений, но может сильно ухудшить калибровку вероятностей.

15.5 Монте-Карло и цепи Маркова

Для независимых $\theta_t \sim p(\theta \mid D)$ оценка $\hat{I} = T^{-1} \sum_t g(\theta_t)$ имеет среднее $I = \mathbb{E} g(\theta)$ и дисперсию $\mathrm{Var}(g(\theta))/T$, если она конечна. Для интеграла по области с равномерным распределением необходимо учитывать объём области; для общего распределения нужна соответствующая плотность.

MCMC строит цепь с инвариантным распределением posterior. В алгоритме Метрополиса--Гастингса из текущего θ предлагается $\theta' \sim q(\cdot \mid \theta)$ и принимается с вероятностью

$$a(\theta, \theta') = \min\left(1, \frac{\tilde{\pi}(\theta') q(\theta \mid \theta')}{\tilde{\pi}(\theta) q(\theta' \mid \theta)}\right).$$

Нормировочная константа $\tilde{\pi}$ сокращается. Для различных состояний $\pi(\theta) q(\theta' \mid \theta) a(\theta, \theta')$ равно минимуму двух встречных потоков, откуда детальный баланс и инвариантность. Достижение стационарного режима из начальной точки требует дополнительных условий неприводимости и эргодичности.

Gibbs последовательно генерирует каждую координату из её полного условного распределения при остальных текущих координатах. Последовательные выборки зависимы. При стационарности и суммируемой автокорреляции асимптотическая дисперсия среднего содержит множитель $1 + 2\sum_{k \ge 1} \rho_k$. Поэтому число итераций не равно эффективному числу независимых наблюдений. Фиксированный «разогрев» не является доказательством перемешивания; полезны несколько цепей и диагностика автокорреляции.

В rejection sampling предложение q и константа M удовлетворяют $\tilde{\pi}(\theta) \le M q(\theta)$. Точку принимают с вероятностью $\tilde{\pi}(\theta)/(M q(\theta))$. Плотность принятой точки пропорциональна $q \cdot \tilde{\pi}/(Mq) = \tilde{\pi}/M$, что доказывает правильность. Большое M снижает эффективность.

Контроль понимания

Когда MAP совпадает со средним posterior? Почему в предсказательной дисперсии два слагаемых? Что именно независимо в наивном Байесе? Почему инвариантность MCMC не доказывает быстрое перемешивание?

ГЛАВА 16

Скрытые переменные и EM

Материалы курса: лекция и семинар 13 [L13, S13]..

16.1 KL-дивергенция

Для плотностей p, q относительно общей меры определим

$$\mathrm{KL}(p\|q) = \int p(z) \log \frac{p(z)}{q(z)}\, dz.$$

Используется $0 \log(0/q) = 0$; если $q = 0$ на множестве положительной p-меры, дивергенция равна $+\infty$.

Теорема 16.1 (Неравенство Гиббса)**.** $\mathrm{KL}(p\|q) \geq 0$, и равенство имеет место тогда и только тогда, когда $p = q$ почти всюду.

Доказательство. При конечной дивергенции применим $-\log u \geq 1 - u$ к $u = q/p$ на множестве $\{p > 0\}$:

$$\mathrm{KL}(p\|q) \geq \int_{p>0} (p - q) = 1 - \int_{p>0} q \geq 0.$$

Равенство требует $q/p = 1$ почти всюду относительно p и отсутствия массы q вне носителя p, то есть равенства распределений. Случай бесконечной дивергенции очевиден. $\square$

KL не является метрикой: в общем случае она несимметрична и не удовлетворяет неравенству треугольника. Выражение «расстояние Кульбака--Лейблера» следует понимать только как неформальное название.

16.2 Нижняя граница правдоподобия

Пусть x наблюдается, а z скрыта. Плотность наблюдения равна $p_\theta(x) = \int p_\theta(x, z)\, dz$. Для любой подходящей плотности $q(z)$ определим

$$\mathcal{F}(q, \theta) = \int q(z) \log \frac{p_\theta(x, z)}{q(z)}\, dz.$$

Когда выражения определены, справедливо точное тождество

$$\log p_\theta(x) = \mathcal{F}(q, \theta) + \mathrm{KL}(q \| p_\theta(z \mid x)). \tag{16.1}$$

Оно получается подстановкой $p_\theta(x, z) = p_\theta(z \mid x) p_\theta(x)$ и интегрированием. Следовательно, $\mathcal{F}$ есть нижняя граница, достигающая логарифма правдоподобия при $q = p_\theta(z \mid x)$.

Для независимых наблюдений удобно использовать сумму таких границ с отдельными $q_i(z_i)$. В более общей модели можно рассматривать совместную скрытую переменную Z для всей выборки, не предполагая её покоординатной независимости.

16.3 Два шага и монотонность

При текущем параметре θ_t E-шаг устанавливает $q_t(Z) = p(Z \mid X, \theta_t)$. M-шаг максимизирует

$$Q(\theta \mid \theta_t) = \mathbb{E}_{q_t} \log p(X, Z \mid \theta)$$

по θ. Энтропия q_t на этом шаге постоянна.

Теорема 16.2 (Монотонность EM)**.** Если E-шаг вычислен точно, а M-шаг не уменьшает Q, то $\log p(X \mid \theta_{t+1}) \geq \log p(X \mid \theta_t)$.

Доказательство. Из (16.1) и неотрицательности KL

$$\log p(X \mid \theta_{t+1}) \geq \mathcal{F}(q_t, \theta_{t+1}) \geq \mathcal{F}(q_t, \theta_t) = \log p(X \mid \theta_t).$$

Последнее равенство использует точный posterior на E-шаге. □

Возрастание правдоподобия не доказывает сходимость параметров к глобальному максимуму. Возможны локальные максимумы, седловые точки, неидентифицируемость и неограниченность функционала. При приближённом E-шаге отдельно проверяют свойства используемой нижней границы.

16.4 Смесь нормальных распределений

Пусть

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad \pi_k > 0, \quad \sum_k \pi_k = 1, \quad \Sigma_k \succ 0.$$

Скрытая переменная z_i указывает компоненту. На E-шаге вычисляют ответственности

$$r_{ik} = \mathbb{P}(z_i = k \mid x_i) = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}.$$

Положим $N_k = \sum_i r_{ik}$. При $N_k > 0$ М-шаг имеет вид

$$\pi_k^{\text{new}} = N_k/n, \qquad \mu_k^{\text{new}} = \frac{1}{N_k}\sum_i r_{ik} x_i,$$

$$\Sigma_k^{\text{new}} = \frac{1}{N_k}\sum_i r_{ik}(x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^{\mathsf{T}}.$$

Для весов эти формулы следуют из множителя Лагранжа при $\sum \pi_k = 1$. Для средних из нулевого градиента взвешенной квадратичной формы, для ковариации из дифференцирования $\log\det\Sigma_k + \operatorname{tr}(\Sigma_k^{-1} S_k)$.

Гауссовская смесь с произвольными ковариациями может иметь неограниченное правдоподобие: одну компоненту можно сжать вокруг одного наблюдения, направляя её определитель к нулю, а другие оставить для остальных точек. Ограничение минимальных собственных значений или корректный prior устраняют конкретный вырожденный путь. Произвольное добавление εI после М-шага меняет алгоритм и не автоматически сохраняет точную монотонность исходного likelihood.

Вычислять ответственности нужно через логарифмы и log-sum-exp. Перестановка номеров компонент не меняет плотность; сравнение параметров двух запусков требует согласования этой перестановки.

16.5 Вероятностный PCA

Модель PPCA имеет вид

$$z \sim \mathcal{N}(0, I_q), \quad x \mid z \sim \mathcal{N}(\mu + Wz, \sigma^2 I_d), \quad q < d.$$

Маргинально $x \sim \mathcal{N}(\mu, WW^{\mathsf{T}} + \sigma^2 I_d)$. Здесь матрица W не обязана иметь ортонормированные столбцы. Предположим, что $\mu = \overline{x}$ зафиксировано, $\tilde{x}_i = x_i - \mu$, и $\sigma^2 > 0$.

Завершение квадрата по z даёт при $M = W^{\mathsf{T}}W + \sigma^2 I_q$

$$m_i = \mathbb{E}[z_i \mid x_i] = M^{-1}W^{\mathsf{T}}\tilde{x}_i, \quad C = \operatorname{Cov}(z_i \mid x_i) = \sigma^2 M^{-1}, \quad S_i = C + m_i m_i^{\mathsf{T}}.$$

Это Е-шаг. На М-шаге

$$W^{\text{new}} = \left(\sum_i \tilde{x}_i m_i^{\mathsf{T}}\right)\left(\sum_i S_i\right)^{-1},$$

$$(\sigma^2)^{\text{new}} = \frac{1}{nd}\sum_i \left[\|\tilde{x}_i\|^2 - 2m_i^{\mathsf{T}}(W^{\text{new}})^{\mathsf{T}}\tilde{x}_i + \operatorname{tr}((W^{\text{new}})^{\mathsf{T}}W^{\text{new}}S_i)\right].$$

Все m_i, S_i берутся из старого E-шага, а в формуле дисперсии используется уже новое W. Замена S_i на $m_i m_i^\top$ теряет неопределённость скрытой переменной и даёт другой алгоритм.

При пропусках на E-шаге учитывают только наблюдаемые координаты и интегрируют по отсутствующим. Заполнение нулём без учёта неопределённости не эквивалентно этому вероятностному выводу. Число компонент и размер скрытого пространства выбирают по заранее заданному критерию качества, а не по одному росту обучающего правдоподобия.

Контроль понимания

Почему E-шаг делает границу точной в текущей точке? Какое условие нужно для обобщённого M-шага? Почему смесь может сжиматься в точку? Где в PPCA присутствует второй момент, а не квадрат первого?

ГЛАВА 17

Главные компоненты и низкий ранг

Материалы курса: лекция и семинар 14; связь с лекцией 13 [L14, S14, L13]..

17.1 Центрирование и постановка

Пусть $X \in \mathbb{R}^{n \times d}$ содержит признаки по строкам, $\overline{x} = n^{-1} \sum_i x_i$, а $X_c = X - \mathbf{1}_n \overline{x}^{\mathsf{T}}$. Центрирование требуется, если цель состоит в приближении аффинным подпространством. Для любого ортонормированного $V \in \mathbb{R}^{d \times q}$, $V^{\mathsf{T}} V = I_q$, код и восстановление имеют вид

$$Z = X_c V, \qquad \widehat{X}_c = Z V^{\mathsf{T}} = X_c V V^{\mathsf{T}}.$$

Метод главных компонент выбирает V, минимизирующее $\|X_c - X_c V V^{\mathsf{T}}\|_F^2$.

Для фиксированного V этот код оптимален среди всех Z: строки $z_i V^{\mathsf{T}}$ являются ортогональными проекциями строк X_c на пространство столбцов V. Поэтому PCA одновременно выбирает подпространство и координаты в нём.

17.2 Основная теорема PCA

Теорема 17.1. Пусть собственные значения $X_c^{\mathsf{T}} X_c$ упорядочены как $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$. Минимум ошибки восстановления в размерности q равен $\sum_{j=q+1}^{d} \lambda_j$ и достигается на собственных векторах, соответствующих q наибольшим собственным значениям.

Доказательство. Поскольку $V V^{\mathsf{T}}$ ортогональный проектор,

$$\|X_c - X_c V V^{\mathsf{T}}\|_F^2 = \|X_c\|_F^2 - \operatorname{tr}(V^{\mathsf{T}} X_c^{\mathsf{T}} X_c V).$$

Пусть Q содержит ортонормированные собственные векторы. Для $B = Q^{\mathsf{T}} V$ имеем $B^{\mathsf{T}} B = I_q$ и

$$\operatorname{tr}(B^{\mathsf{T}} \Lambda B) = \sum_{j=1}^{d} \lambda_j a_j, \qquad a_j = \sum_{k=1}^{q} B_{jk}^2.$$

Из того, что $B B^{\mathsf{T}}$ является проектором, следуют $0 \leq a_j \leq 1$ и $\sum_j a_j = q$. Максимум линейной формы при этих условиях не превосходит $\lambda_1 + \cdots + \lambda_q$: перенос веса

с меньшего собственного значения на большее не уменьшает сумму. Он достигается при первых q собственных векторах. Вычитая из $\|X_c\|_F^2 = \sum_j \lambda_j$, получаем требуемое. □

Если $\lambda_q > \lambda_{q+1}$, оптимальное подпространство единственно. Базис внутри него всё равно можно повернуть ортогонально; знаки отдельных собственных векторов произвольны. При кратности на границе даже подпространство может быть неединственным.

17.3 Связь с SVD и теорема о низком ранге

Пусть $X_c = U\Sigma V^\mathsf{T}$ есть компактная SVD. Тогда главные направления являются столбцами V, главные координаты $Z_q = U_q\Sigma_q$, а $\lambda_j = \sigma_j^2$. Ковариационная матрица с делителем $n-1$ имеет собственные значения $\lambda_j/(n-1)$; выбор делителя не меняет направления.

Следствие 17.2 (Наилучшее приближение по норме Фробениуса)**.** Среди всех матриц B ранга не выше q минимум $\|X_c - B\|_F^2$ достигается на $B = U_q\Sigma_q V_q^\mathsf{T}$.

Доказательство. Строки всякой такой B лежат в некотором подпространстве размерности не выше q. Ортогональная проекция строк X_c на это подпространство не хуже любой другой матрицы с тем же пространством строк. Теперь применима теорема PCA. Подпространство меньшей размерности можно дополнить до q, не увеличивая ошибку. □

Доля объяснённой дисперсии первыми q компонентами равна $\sum_{j\le q}\sigma_j^2 / \sum_j \sigma_j^2$, если знаменатель положителен. При нулевой дисперсии эта доля не определена. Выбор «95 процентов» задаёт точность восстановления признаков, но не гарантирует сохранения информации об ответе.

17.4 Шкалирование, отбеливание и регрессия

PCA ковариационной матрицы зависит от единиц измерения. Если один признак умножить на 1000, его вклад в сумму квадратов увеличится в миллион раз. Стандартизация меняет саму задачу: PCA стандартизованных признаков соответствует корреляционной структуре. Она полезна не всегда; выбор должен отражать смысл данных.

Отбеливание ненулевых главных координат делит каждую на её стандартное отклонение. При $Z_q = U_q\Sigma_q$ матрица $\sqrt{n-1}U_q$ имеет единичную выборочную

ковариацию. Нулевые и очень малые сингулярные значения делают отбеливание неопределённым или неустойчивым.

Регрессия на первых q компонентах, PCR, даёт при центрированном ответе

$$\widehat{w}_q = \sum_{j=1}^{q} \frac{u_j^{\mathsf{T}} y_c}{\sigma_j} v_j.$$

Это жёсткое отсечение спектра. Ridge вместо отсечения использует плавный множитель $\sigma_j/(\sigma_j^2 + n\lambda)$. Оба метода подавляют неустойчивые направления, но PCA выбирает их без использования y. Направление малой дисперсии может быть единственным полезным для прогноза.

При применении к новым данным вычитают *обучающее* среднее и используют *обученные* направления. Повторная подгонка PCA на тестовом наборе меняет преобразование и нарушает независимость оценки.

17.5 Связь с PPCA и неполными матрицами

В PPCA ковариация имеет структуру $WW^{\mathsf{T}} + \sigma^2 I$. При полной наблюдаемости её главные направления согласуются с обычным PCA; однако скрытые координаты вычисляются как условные средние и включают регуляризацию через шум. В пределе малого шума восстанавливается соответствующее главное подпространство при невырожденном спектре.

Для неполной матрицы наблюдений M с известным множеством индексов Ω низкоранговая модель может минимизировать

$$\sum_{(i,j)\in\Omega} (M_{ij} - u_i^{\mathsf{T}} v_j)^2 + \lambda \left(\sum_i \|u_i\|^2 + \sum_j \|v_j\|^2 \right).$$

Нули вне Ω не являются наблюдениями. Обычная SVD матрицы с нулевым заполнением решает другую задачу. При фиксированных v_j оптимизация по u_i есть ridge, и наоборот, что приводит к чередующимся наименьшим квадратам. Совместно задача невыпукла; эквивалентность преобразований $U \mapsto UA, V \mapsto VA^{-\mathsf{T}}$ без штрафа показывает неидентифицируемость факторизации.

Контроль понимания

Где в доказательстве нужна ортонормированность? Что единственно при разрыве спектра? Почему PCA может ухудшить классификацию? Чем восстановление пропущенных значений отличается от SVD с нулевым заполнением?

ГЛАВА A

Карта курса и редакционные уточнения

A.1 Соответствие лекциям

Обозначения источников относятся к списку в конце книги. Нумерация глав этой книги намеренно отличается от исходной: темы сгруппированы по математическим зависимостям.

Источник	Тема исходного курса	Главы книги I
L01	Постановки задач, обучение, переобучение	1--2
L02	Линейные модели, SGD, правдоподобие	3--4, 7
L03	MAP, логистическая регрессия, логические методы	7--8, 15
L04	CART, kNN, Парзен, LOWESS	8--9
L05	Метрики, обобщение, отбор признаков	2, 10
L06	Взвешенный МНК, Гаусс--Марков, Холецкий	5
L07	Нелинейный МНК, динамические системы	6
L08	SVM, двойственность, ядра, SVR	11
L09	Бэггинг, AdaBoost, градиентный бустинг	12
L10	Нейронные сети, обратный проход	13
L11	Кластеризация, частичное обучение	14
L12	Байесовский вывод, сопряжённость, MCMC	15
L13	KL, EM, смеси, PPCA	16
L14	SVD, многомерная регрессия, PCA	4, 17

A.2 Навигация по экзаменационным блокам

Линейная классификация и регрессия.

Постановки и штрафы: главы 4 и 7. Нейрон и сигмоидный градиент: главы 7 и 13. SGD: глава 3. MAP: главы 7 и 15. Многомерная регрессия и SVD: глава 4. Взвешивание и Холецкий: глава 5. SVM: глава 11.

Нелинейные модели.
Гаусс--Ньютон и нелинейный МНК: глава 6. Ядра, допустимость, полиномиальные поверхности: глава 11.

Композиции.
Общая форма, бэггинг, случайные признаки, AdaBoost, градиентный бустинг и сравнение подходов: глава 12.

Логические алгоритмы.
Закономерности, семейства правил, бинаризация, дерево, энтропия и Джини, CART, ограничение сложности: глава 8.

Метрические методы.
Обобщённое голосование, kNN, Парзен, потенциалы, Надарая--Ватсона, ширина окна и выбросы: глава 9. Различие двух смыслов ядра: глава 11.

Качество.
Accuracy, precision, recall, PR, ROC, AP, log-loss и вероятности: глава 10. Вероятностный смысл регуляризации: глава 7. Смещение и разброс: глава 2.

Признаки.
Полный и жадный поиск, добавление и удаление, ограниченная ширина поиска и генетический алгоритм: глава 10. SVD и основная теорема PCA: главы 4 и 17.

Кластеризация и частичное обучение.
Постановки, неоднозначность, критерии, k-means и модификации, DBSCAN, дендрограмма, использование меток: глава 14.

Нейронные сети.
Линейная неразделимость, XOR, функции активации, mini-batch и backpropagation: глава 13. Минимальный контрпример разделимости и градиентная проверка: книга II, глава 10.

Байес и EM.
Правила суммы и произведения, наивный Байес: глава 15. KL, нижняя граница, E/M-шаги и смысл латентных переменных: глава 16.

A.3 Что уточнено по сравнению со слайдами

1. В MAP-записи prior относится ко всему вектору параметров и входит один раз. Градиент L_2-штрафа равен λw; градиент полной цели есть сумма градиентов, а не сумма значения функции и вектора.
2. Состоятельность МНК требует асимптотических условий на матрицу плана. Теорема Гаусса--Маркова доказывает оптимальность в классе линейных несмещённых оценок и не требует нормальности.

3. В SVD-формуле квадрата нормы коэффициентов используется $1/\sigma_j^2$. Обращаются только положительные сингулярные значения. Размерности компактной SVD явно указаны.
4. Функционал SGD нормирован последовательно: среднее и сумма различаются множителем n. Условия на шаг не заменяют предположений о шуме и целевой функции.
5. Строгая выпуклость логистической потери не обеспечивает достижимость минимума на разделимой выборке. Одна лишь неразделимость без дополнительных условий также не служит универсальной гарантией существования и идентифицируемости.
6. Average precision отделена от трапецеидальной площади под PR-кривой. Равные оценки группируются. PR-кривая в общем случае не монотонна по точности и заканчивается на доле положительного класса.
7. Отбор признаков с досрочной остановкой не называется гарантированно полным перебором. В дереве «оптимальное разбиение узла» отделено от глобальной оптимальности всего дерева.
8. KL равна нулю при равенстве распределений почти всюду; она не является метрикой. В цепном правиле вероятностей сохранены все множители. При Монте-Карло явно указано распределение выборок и нужная нормировка.
9. Сравнение частотного и байесовского подходов не сводится к «только точечным оценкам» против «всегда применимого метода». Асимптотические свойства максимального правдоподобия требуют регулярности и не используются без условий.
10. Квадратичный критерий графовой кластеризации без ограничений допускает тривиальные решения. В частичном обучении явно указаны условия единственности продолжения.

A.4 Границы охвата

Книга охватывает основные математические темы указанного семестра и экзаменационный список. Она не воспроизводит организационные сроки 2021 года, биографические вставки, внешние видеолекции и все графические демонстрации из ноутбуков. Дополнительные методы второго семестра упоминаются лишь там, где они непосредственно объясняют линейные или вероятностные конструкции первого.

Источники и лицензия

Основной источник: открытый курс «Машинное обучение» МКН СПбГУ. Ссылки ниже ведут к использованному снимку исходных файлов. Обозначения L, S и H соответствуют лекциям, семинарам и домашним заданиям. Нумерация взята из имён каталогов; в заголовке файла H07 ошибочно указан номер 6.

Литература

[L01] Введение и постановки задач. Исходный файл.

[L02] Линейные модели, SGD и правдоподобие. Исходный файл.

[L03] Байесовский подход и логические методы. Исходный файл.

[L04] Метрические методы. Исходный файл.

[L05] Оценивание качества и отбор признаков. Исходный файл.

[L06] Взвешенный метод наименьших квадратов. Д. А. Павлов. Исходный файл.

[L07] Нелинейный метод наименьших квадратов. Д. А. Павлов. Исходный файл.

[L08] Метод опорных векторов. Исходный файл.

[L09] Композиции классификаторов. Исходный файл.

[L10] Нейронные сети и backpropagation. Исходный файл.

[L11] Кластеризация и частичное обучение. Исходный файл.

[L12] Введение в байесовские методы. Исходный файл.

[L13] EM-алгоритм и PPCA. Исходный файл.

[L14] Многомерная регрессия и PCA. Исходный файл.

[S01] Семинар 1. NumPy и pandas. Исходный файл.

[S02] Семинар 2. Матричное дифференцирование. Исходный файл.

[S03] Семинар 3. Линейные модели. Исходный файл.

[S04] Семинар 4. Метрические методы. Исходный файл.

[S05] Семинар 5. Оценивание качества и отбор признаков. Исходный файл.

[S08] Семинар 8. Метод опорных векторов. Исходный файл.

[S09] Семинар 9. Композиции классификаторов. Исходный файл.

[S10] Семинар 10. Нейронные сети и backpropagation. Исходный файл.

[S11] Семинар 11. Кластеризация и частичное обучение. Исходный файл.

[S12] Семинар 12. Введение в байесовские методы. Исходный файл.

[S13] Семинар 13. EM-алгоритм и PPCA. Исходный файл.

[S14] Семинар 14. Многомерная регрессия и PCA. Исходный файл.

[EXAM] Экзаменационные вопросы первого семестра. Исходный файл.

[H01] Домашнее задание. NumPy и pandas. Исходный файл.

[H02] Домашнее задание. Логические методы, теоретическое задание. Исходный файл.

[H03] Домашнее задание. Решающие деревья. Исходный файл.

[H04] Домашнее задание. Градиентный спуск своими руками. Исходный файл.

[H05] Домашнее задание. Бинарная классификация. Исходный файл.

[H06a] Домашнее задание. Определение орбиты 1I/Оумуамуа. Исходный файл.

[H06b] Домашнее задание. Лазерная локация Луны. Исходный файл.

[H07] Домашнее задание. kNN, SVM и оценка качества. Исходный файл.

[H08] Домашнее задание. Нейронная сеть на NumPy. Исходный файл.

[PLAN] План занятий и домашних заданий. Исходный файл.

Лицензия исходного репозитория

Исходный репозиторий распространяется по MIT License. Учебная переработка сохраняет следующее уведомление. Содержание ниже относится к исходным материалам.

MIT License

Copyright (c) 2021 spbu-math-cs

Permission is hereby granted, free of charge, to any person obtaining a copy of this software and associated documentation files (the ”Software”), to deal in the Software without restriction, including without limitation the rights to use, copy, modify, merge, publish, distribute, sublicense, and/or sell copies of the Software, and to permit persons to whom the Software is furnished to do so, subject to the following conditions:

The above copyright notice and this permission notice shall be included in all copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED ”AS IS”, WITHOUT WARRANTY OF ANY KIND, EXPRESS OR IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY, FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM, OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE SOFTWARE.